

2025 공공부문 데이터 분석·활용 우수사례집



행정안전부

NIA 한국지능정보사회진흥원

Contents

PART 1

국민 안전

- 식중독 발생 신속대응을 위한 원인균 및 원인식품 예측 모델 개발 06
식품의약품안전처
- 조류생태·환경 데이터를 활용한 공항 조류충돌 위험 평가 모델 개발 20
한국공항공사
- 농산물 중점 수거·검사대상 선별 모델 개발 34
식품의약품안전처
- 자율운항선박의 안전 확보를 위한 최적화된 운항 경로 및 패턴 분석 46
해양경찰청
- 딥페이크 범죄 대응을 위한 AI 탐지 모델 개발 60
국립과학수사연구원

PART 2

공공행정

- 국가보훈 상이등급 기준 정비 및 등급 판정 예측을 위한 데이터 분석 74
국가보훈부
- 부동산 거래 데이터를 활용한 이상거래 탐지 모델 개발 88
국토교통부
- 조달물품 유사 구매실례 추천 및 입찰 참여 가능성 분석 모델 개발 102
조달청



PART 3 재난안전

- 상수도 유량 데이터를 활용한 화재진압 소화전 사용 최적 활용 지원 모델 개발 118
대구광역시
- 야생멧돼지 아프리카돼지열병(ASF) 위험도 관리 및 방역 의사결정 지원 모델 개발 132
국립야생동물질병관리원
- 교량 잠재위험지수 산정 및 선제적 안전관리 지원 모델 개발 146
국토안전관리원

PART 4 산업경제

- 에너지 다소비 사업장 사용량 예측 및 수요관리 최적화 모델 개발 162
한국에너지공단

PART 5 교통안전

- 운수종사자 인지적 특성에 기반한 교통사고 위험도 예측 178
한국교통안전공단
- 교통사고 위험 예측 및 실시간 안전정보 제공 지원 모델 개발 192
한국도로교통공단

2025

공공부문 데이터 분석·활용

우수사례집

Part •

국민 안전



- 1.1 식중독 발생 신속대응을 위한 원인균 및 원인식품 예측 모델 개발**
식품의약품안전처
- 1.2 조류생태 · 환경 데이터를 활용한 공항 조류충돌 위험 평가 모델 개발**
한국공항공사
- 1.3 농산물 중점 수거 · 검사대상 선별 모델 개발**
식품의약품안전처
- 1.4 자율운항선박의 안전 확보를 위한 최적화된 운항 경로 및 패턴 분석**
해양경찰청
- 1.5 딥페이크 범죄 대응을 위한 AI 탐지 모델 개발**
국립과학수사연구원



1-1

식중독 발생 신속대응을 위한 원인균 및 원인식품 예측 모델 개발



Part 1-1

식중독 발생 신속대응을 위한 원인균 및 원인식품 예측 모델 개발

식품의약품안전처

식중독 발생 즉시 원인 예측 모델을 활용하여 식중독 대량 확산 방지

분석 배경	분석 방법	분석 결과
식중독이 발생하면 조사관의 경험에 의존한 초기 조사 진행	초기 사건정보와 증상 기상정보를 활용한 원인 병원체 10종 및 원인식품 23종의 타깃별 예측	Top3 후보와 상대위험점수, 유사사례를 제공해 검사·검체·현장점검의 우선순위를 지원

과제 한눈에 보기

식중독이 발생하면 원인병원체와 원인식품이 확정되기 전부터 검체 채취와 현장점검을 신속히 시작해야 한다. 그러나 초기에는 정보가 제한되어 조사자의 경험을 중심으로 넓은 범위의 검체와 검사항목을 확인해야 한다. 발생 특성을 바탕으로 가능성이 높은 원인 후보를 먼저 좁히는 지원체계가 필요했다.

이에 식품의약품안전처는 발생 시기와 지역, 시설, 환자 규모, 잠복기와 증상정보에 검사·기상·식품정보를 결합했다. 과거 식중독 사건의 패턴을 학습해 원인병원체와 원인식품 후보를 각각 Top3로 제시하고, 유사사건과 위험점수 및 입력 근거를 함께 확인하는 예측모델을 구축했다.

분석 결과는 사건정보를 입력하면 원인병원체와 원인식품 후보, 관련 통계를 한 화면에서 보여주는 시스템으로 구현했다. 이를 통해 조사 초기 검체와 검사항목, 점검 범위를 신속히 정해 원인 규명 시간을 줄이고 추가 확산을 차단하는 현장 대응력을 높일 기반을 마련했다.

연번	원인시설	발생 건수(건)		환자수(명)	
		2024년	2025년	2024년	2025년
1	학교	29	36	36	1,691
2	학교 외 집단급식	35	47	47	1,865
3	음식점	154	192	192	3,850
4	가정집	3	3	3	11
5	기타	33	32	32	2,296
6	불명	11	9	9	67
7	합계	265	319	319	9,780

표 1-1. 원인시설별 식중독 발생 및 환자 수

이렇게 바뀌었습니다!

경험 중심의 초기 가설 수립에서 데이터 기반 후보 발굴로 개선

이번 과제는 흩어진 기록을 하나의 분석체계로 연결하고 결과를 현장의 행동정보로 바꾸었다.

약 3만 건의 사건자료와 검사·기상·식품분류 정보를 연결했다. 원인식품 23종과 원인 병원체 10종에 대해 타깃별 모델을 개발하고 검증했다. 원인균과 원인식품 Top3, 상대 위험점수와 유사한 식중독 사건을 한 화면에 제공하고, 결과는 검체 채취, 검사 항목과 현장점검의 우선순위를 정하는 데 활용하도록 했다.

데이터 수집에서 분석과 활용까지 이어진 이 흐름은 유사한 공공업무로 확산할 수 있는 기반이 되었다.

AS-IS	TO-BE
• 원인 확정 전에는 현장 경험을 중심으로 조사 범위를 정하여 식중독 담당자의 경력에 따른 편차 심화 • 검체와 검사 항목을 넓게 확인해 시간과 자원이 많이 소요 • 사건·검사·기상·식품 정보가 분리되어 업무에 어려움 존재	• 원인병원체·원인식품 Top3 후보를 제시하여 경험에 따른 편차 완화 • 후보별 우선순위로 검체·검사·점검 범위를 조정하여 초기 대응의 효율 향상 • 식중독 보고 후 현장 조사, 신속 검사, 원인추정 및 차단의 처리시간 개선

1.1 현황 및 배경

식중독 증가에 비해 원인 규명은 여전히 어려움 존재

최근 수년간 식중독 발생 건수는 상승했다. 계절적 추이도 차이가 있었으며, 학교, 음식점 등 시설별 발생도 증가 추세이다. 원인균 규명률은 과거에 비해 증가하였지만 식중독 원인규명을 위해 더 높여야할 필요성이 있다.

신고 직후에는 정보가 충분하지 않고 현장조사와 검체 채취, 검사 후에 원인균과 원인식품을 확정할 수 있어 초기 판단은 식중독 역학조사관의 경험에 의존하는 경향이 있었다.

왜 초기 대응이 중요했나?

식중독 발생 후 초기 대응이 늦어지면 단기간 내에 식중독이 빠르게 확산될 수 있기 때문에 원인 후보를 빨리 좁힐수록 추가 확산을 막을 수 있다. 특히 여름에 식중독 사건이 많이 발생하므로 집중적인 대응이 필요하다.




그림 1-1. 계절별 식중독 사건 발생 추이

1.2 분석 필요성

식중독 원인 단계에서 검사와 현장조사의 방향이 필요

현황을 확인한 뒤에는 무엇을 데이터로 설명하고 어떤 판단을 지원할 것인지 분석의 질문을 분명히 해야 한다.

식중독 업무는 신고 접수 직후 역학조사를 시작하고 현장조치, 검체 채취, 조사와 검사를 거쳐 원인을 확정한다. 초기 정보만으로 원인병원체와 원인식품 Top3 후보를 제시하면 인체·식품·환경 검체의 범위와 검사 패널의 우선순위를 조정할 수 있다. 단순 모델 개발에 그치지 않고 결과 시각화, 유사사례, 입력 품질관리와 재학습까지 연결한 운영체계가 필요하다.

분석 결과는 현장 식중독 원인조사 담당자가 바로 활용할 수 있도록 발생 가능성이 높은 원인 식품과 병원체를 순서대로 볼 수 있는 방식으로 구현할 필요가 있다. 이와 함께 원인으로 판명된 실제 음식도 함께 보여주어 역학조사의 성공 가능성을 높이는 것이 중점이었다. 세부 분석은 핵심 분석 질문에 답하면서 현장에서 우선 확인해야 할 대상을 구체화하는 방향으로 설계했다.

핵심 분석 질문

- ① 초기 증상과 잠복기로 볼 때 가능성이 높은 병원체는 무엇인가?
- ② 발생시설과 섭취정보로 볼 때 의심식품은 무엇인가?
- ③ 어떤 검체와 검사항목을 먼저 확인해야 하는가?

1.3 데이터 목록

사건·검사·기상·식품분류 정보를 발생번호로 연결

식품의약품안전처 식중독 발생자료에는 발생번호, 발생 시기, 주소, 최종 원인식품과 원인병원체 등이 포함되었다. 2002~2025년 범위의 사건·보완자료를 활용했다.

역학조사 자료와 검사 확정결과를 발생번호 단위로 연계하고, 기상청 자료에서 평균·최고기온, 강수량과 평균 상대습도를 결합했다. 또한, 자유롭게 입력된 추정원인식품은 전국통합식품영양정보 표준 분류와 단어사전을 이용해 정규화했다. 이를 통해 모델 활용자 입장에서 일관성있는 추정원인식품 예측 결과를 도출할 수 있었다.

최종적으로 하나의 식중독 사건과 관련 자료를 고유번호를 통해 연결하였다. 이를 기준으로 사건 상태(조사중/종결) 및 확정 정보(검사 결과)의 관계 검증 등을 수행하였다. 추가로 원신식품 및 원인균이 없거나 ‘불명/미확정’인 사건은 학습에 제외하여 적용하였다.

분석 대상과 범위

발생 시기·지역·시설·환자 규모·잠복기·증상에 검사·기상·식품정보를 결합하고 원인병원체와 원인식품을 각각 Top3 후보로 분석했다.

연번	데이터명	주요 활용 속성정보	출처
1	식중독균 발생원인 관련 데이터	식중독 발생 데이터 고유 발생 번호, 발생 월, 발생 계절, 상세주소, 최종원인식품, 최종원인병원체 등	식품의약품안전처
2	식중독균 실태조사 데이터	검체명, 결과, 검출균, 제조일자, 제조도로명주소	식품의약품안전처
3	전국통합식품 영양성분정보_음식_표준데이터	식품코드, 데이터구분명, 식품대분류명, 식품중분류명, 식품소분류명, 대표식품명, 식품명	식품의약품안전처
4	전국통합식품 영양성분정보_가공 식품_표준데이터	식품코드, 데이터구분명, 식품대분류명, 식품중분류명, 식품소분류명, 대표식품명, 식품명	식품의약품안전처

표 1-2. 주요 활용 데이터

1.4 EDA : 발생 시기·지역·시설

여름과 8월에 사건이 집중되고 지역별 차이 확인

모델을 만들기 전에는 데이터의 분포와 차이, 결측과 이상값을 충분히 살펴야 한다. 이 탐색과정은 모델의 방향을 정하는 기초가 된다.

1년간 전체 식중독 발생 사건의 규모는 약 3만 건이고 월별 및 지역별로 발생량이 달랐다. 월별로 발생량 추이를 봤을 때는 8월이 가장 높았고, 지역별로는 경기도의 사건 발생이 가장 많았다.

식중독 발생 시설유형 중 음식점이 56%로 가장 많았고 기타와 학교가 뒤를 이었다.




그림 1-2. 월별 식중독 발생 빈도(2022년~2025년 기준, 결측 제외)




그림 1-3. 시설유형별 발생 현황(2022년~2025년 기준, 결측 제외)

1.5 EDA : 증상·원인균·원인식품

증상과 기상조건에서 원인별 특징 확인

식중독 증상은 설사가 21,201건으로 가장 많았고, 구토는 14,372건, 복통은 11,473건이었다. 근육통·마비·호흡곤란 등은 상대적으로 드물었다.

원인균과 원인식품별로 발생 빈도도 차이가 있었다. 원인균은 바실러스 세레우스 10,554건, 클로스트리디움 퍼프린젠스 4,241건, 장염비브리오 3,913건, 병원성대장균 3,857건 순으로 많았다.

원인식품 분류는 육류 4,226건, 어패류 및 기타 수산물 3,881건, 식육가공품 및 포장육 3,795건 순이었다.




그림 1-4. 주요 증상별 발생 빈도

기온·습도와 증상의 분포도 원인별로 달랐다. 각 원인균과 평균 기온 사이의 교차 분석을 진행한 결과, 장염비브리오(21.0°C), 살모넬라(17.0°C), 캄필로박터 제주니(16.5°C)의 경우 평균 기온 높을 때 주로 발생하였다. 특히 장염비브리오의 경우 발생 평균 온도가 가장 높으며 사분위범위도 좁아 뚜렷한 여름철 발생 양상을 보였다. 이와 달리 노로바이러스(7.2°C)는 다른 균들에 비해 식중독 발생 평균 기온이 낮은 경향을 보였다.




그림 1-5. 평균 기온에 따른 원인균 교차 분석

1.6 빅데이터 모델링 : 사건 단위 학습

하나의 식중독 사건을 분석단위로 구성하고 복수의 원인을 함께 반영

식중독 발생자료에는 하나의 사건과 관련된 여러 조사·파생정보가 포함되어 있었다. 동일한 발생번호가 여러 행에 반복되면 한 사건이 여러 사례처럼 학습될 수 있고, 특정 사건의 특징이 모델에 과도하게 반영될 가능성이 있었다. 따라서 개별 기록이 아닌 ‘식중독 발생사건’을 기준으로 학습자료를 구성했다.

발생번호를 기준으로 중복자료를 정리하고 하나의 사건이 하나의 행에 대응하는 1:1 구조로 재구성했다. 동일 사건에 포함된 초기 사건정보와 증상·기상정보는 사건별 특성으로 통합했다. 이를 통해 여러 행에 흩어진 정보를 하나의 분석단위로 모으고 사건별 발생 양상을 일관된 기준으로 학습하도록 했다.

하나의 식중독 사건에서는 복수의 원인식품이나 병원체가 확인될 수 있었다. 이에 하나의 원인만을 정답으로 선택하지 않고, 원인식품 23종과 원인 병원체 10종에 대해 사건별 관련 여부를 각각 학습하도록 설계했다. 초기 조사정보만으로 가능한 원인 후보를 폭넓게 제시하기 위한 구조였다.

확인 사례가 지나치게 적은 원인은 안정적인 학습과 평가가 어려웠다. 이에 양성사건이 10건 미만인 타깃은 학습과 성능평가에서 제외했다. 또한 같은 발생번호의 파생자료가 학습자료와 평가자료에 동시에 포함되지 않도록 사건 단위로 분할해, 처음 접하는 사건에서도 원인 후보를 구분할 수 있는지를 확인했다.

사건 단위 분할이 필요한 이유

동일 사건의 자료가 학습과 평가에 나뉘면 모델이 이미 접한 사건을 다시 맞히게 되어 성능이 실제보다 높게 나타날 수 있다. 따라서 같은 발생번호의 자료는 반드시 하나의 분할에만 포함했다.

1.7 빅데이터 모델링 : 알고리즘과 불균형 대응

정상사건이 많은 데이터에서도 희귀 원인을 놓치지 않도록 Recall값을 우선적으로 검토

원인식품과 병원체는 타깃마다 확인된 사건 수가 크게 달랐다. 발생빈도가 높은 원인은 학습자료가 충분했지만, 희귀 원인은 양성사건이 적어 모델이 특징을 학습하기 어려웠다. 이러한 불균형 자료에서 단순 정확도만 높이면 대부분을 ‘해당 없음’으로 예측하고도 성능이 좋아 보일 수 있었다.

이에 전체 정확도보다 실제 원인사건을 얼마나 놓치지 않고 찾아내는지를 나타내는 재현율(Recall)을 우선 평가했다. 초기 조사단계에서는 가능한 원인 후보를 넓게 제시하는 것이 중요하므로, 소수 원인의 양성사건을 탐지하는 능력을 모델 선정의 핵심 기준으로 삼았다.

후보 알고리즘은 Logistic Regression, Random Forest 등으로 구성했다. 선형관계를 설명하는 모델부터 비선형 패턴과 변수 간 상호작용을 학습하는 트리 기반 모델까지 같은 학습자료에서 비교했다. 하나의 알고리즘을 모든 원인에 일괄 적용하지 않고, 원인식품과 병원체의 타깃별 성능을 비교해 최적 모델을 선정했다.

불균형의 영향을 줄이기 위해 클래스 가중치와 오버샘플링을 검토했다. 클래스 가중치는 희귀한 양성사건의 오분류에 더 큰 손실을 부여하는 방식이며, 오버샘플링은 학습과정에서 소수사례의 영향력을 보완하는 방법이다. 각 방법은 무조건 적용하지 않고 타깃별 성능 변화를 비교해 Recall 개선에 도움이 되는 방향을 검토했다.

왜 Recall을 우선했을까?

Recall은 실제 원인사건 가운데 모델이 찾아낸 비율이다. 식중독 초기 조사에서는 가능성이 있는 희귀 원인을 놓치지 않는 것이 중요하므로, 단순 정확도보다 Recall을 중심으로 후보모델을 비교했다.

1.8 모델 성능과 해석 : 원인식품

23개 식품 타겟에서 대부분 높은 Recall값 확인 가능

원인식품은 23개 분류를 타겟으로 평가했다. 타겟별로 CatBoost, Random Forest 등에서 최적 모델을 선택했다. 원인식품의 그룹 분류는 식품분류 엔진 및 단어사전 맵핑을 통해 이루어졌다.

원인식품의 Recall값은 빵 및 과자류와 어패류 및 기타 수산물 0.95 이상, 식육가공품 및 포장육과 유가공품류는 0.99 이상, 수산가공식품류는 0.9 이상 나타났고 각각 최적의 성능을 나타내는 모델을 활용하였다.

원인식품 Target	Recall
빵 및 과자류_tg	0.95 이상
식육가공품 및 포장육_tg	0.99 이상
수산가공식품류_tg	0.9 이상
유가공품류_tg	0.99 이상
어패류 및 기타 수산물_tg	0.95 이상

표 1-3. 주요 원인식품별 최종 모델 및 recall값

1.9 모델 성능과 해석 : 원인병원체

10개 병원체는 모델 결합으로 안정성 상승

원인병원체는 10개 타겟을 평가했다. 서로 다른 모델의 장점을 결합해 앙상블 결과를 산출했다.

병원성대장균 및 살모넬라, 캄필로박터 제주니와 노로바이러스의 Recall 값은 0.7 이상, 장염비브리오 0.85 이상을 나타냈다. 각각 가장 좋은 성능을 내는 모델을 활용하여 최종 결과를 산출하였다.

원인병원체 Target	Recall
병원성대장균_tg	0.7 이상
장염비브리오_tg	0.85 이상
살모넬라_tg	0.7 이상
캄필로박터 제주니_tg	0.7 이상
노로바이러스_tg	0.7 이상

표 1-4. 원인병원체별 최종 모델 및 recall값

1.10 모델 시각화

Top3와 상대위험점수, 다른 지표까지 함께 확인 가능하도록 구성

분석결과 도출 화면은 발생일, 지역, 시설유형, 환자 수와 증상을 입력한 뒤 분석하도록 구성했다. 원인식품과 원인병원체 Top3, 상대위험점수와 색상등급을 제공했다.

원인식품과 원인 병원체의 상대위험점수는 각 원인의 절대확률이 아니라 과거 같은 타깃의 예측분포에서 얼마나 높은 위치인지 보여주는 백분위 점수를 보여주어 상대적인 위험도를 파악할 수 있게 하였다. 이와 더불어 해당 식중독 사건과 유사한 사건 발생번호와 감염증 주간 통계도 함께 보여주어 의사결정에 도움을 주었다.




그림 1-6. 원인병원체 · 원인식품 Top3와 관련 정보를 제공한 대시보드

1.11 분석모델 정책 활용 성과

검체 채취와 검사, 현장점검의 우선순위 지원

식품의약품안전처에서는 내부 시스템에 모델을 탑재한 후 운영중이다. 원활한 운영을 위해 사용자 매뉴얼을 배포 및 교육을 실시하였다. 이를 통해 식중독 원인조사 담당자에게 데이터 기반의 신속한 원인규명을 위한 정보를 제공할 수 있었다. 원인병원체와 원인식품 정보를 참고하여 검체 채취, 검사항목, 점검 등 초기 대응에 활용하였다. 추가로, 식중독 확산 방지를 위한 의심식품 관련 정보를 제공하여 식중독 전파 및 확산을 방지하였다.

구체적으로는 첫째, 조사 착수 직후 모델로 도출된 Top3 결과를 참고해 인체·식품·환경 검체의 채취 범위를 우선적으로 정할 수 있었다. 채취 범위를 우선적으로 정함으로써 가장 중요한 식중독 초기 대응이 경험에 의해서만이 아닌 데이터에 기반한 합리적 의사결정이 가능하게 하였다. 둘째, 검사자원이 제한되기 때문에 상위 후보와 관련된 검사 패널에 우선 배치하였다. 검사 항목 우선순위를 지원하여 원인 규명까지의 시간을 대폭 단축하였다. 셋째, 원인식품 후보에 따라 조리·보관·유통단계의 점검범위를 조정하고 회수와 보관점검 등 위험관리 조치를 검토할 수 있었다. 이에 따라 담당자마다 달라질 수 있는 초기 판단에 같은 데이터 기준을 제공해 우선순위 결정의 일관성을 높일 수 있었다.


뿐만 아니라, 조사 진행 과정에서 추가 정보가 확보될 경우 모델을 통해 Top3 후보를 재산출(갱신)하고 확률을 업데이트하여 사건별로 명확한 정보를 제공할 수 있다.





1-2

조류생태 · 환경 데이터를 활용한 공항 조류충돌 위험 평가 모델 개발



Part 1-2

조류생태·환경 데이터를 활용한 공항 조류충돌 위험 평가 모델 개발

한국공항공사

하늘길의 위험을 조류 충돌위험 평가 모델로 안전운항 확보

분석 배경	분석 방법	분석 결과
조류 충돌로 인한 위험이 매년 증가하고 있는 상황	공항별 조류 출몰·충돌 이력, 기상데이터, 토지 정보 등을 융합하여 조류 충돌 위험 지도 구축	고위험 시간대와 지역(구역)을 파악하여 조류충돌 예방 활동 진행

과제 한눈에 보기

조류 충돌(버드 스트라이크) 증가에 따라 기존 경험 기반 대응 방식에서 벗어나, 축적된 데이터와 환경·운항 정보를 활용한 과학적 조류 출몰 예측 및 위험성 평가 체계 구축이 필요하다.

이에 한국공항공사는 공항별 조류 포획 및 분산 및 충돌 이력 데이터와 항공기 운항, 기상, 일출·일몰, 토지피복, 하천 거리 등 다양한 요인을 융합 분석하여 시간대별·구역별 조류 위험도를 예측하고, 항공기 노출도와 조류별 충돌 심각도를 반영한 위험지도 및 관리 대시보드를 구축하였다.

이를 통해 고위험 시간대와 지역을 사전에 파악하여 조류충돌 예방 활동과 인력·장비를 효율적으로 배치하고, 공항별 맞춤형 예방 계획 수립 및 항공기 운항 안전성 향상에 기여하였다.




그림 2-1. 연도별 조류 충돌 현황



이렇게 바뀌었습니다!

데이터가 공항 안전관리의 다음 행동을 제안

AS-IS

- 관제 연락과 초기 순찰, 월별·시간별 경험에 따라 근무 위치 설정
- 조류종과 이동 경로가 체계적으로 정리되지 않은 상태에서 사후 조치 중심으로 대응
- 조종사 운항 시 조류충돌에 대한 위험성 증대



TO-BE

- 조류 출몰·총돌, 항공 운항, 기상·일출·일몰, 토지·수계 데이터를 통합해 공항별 위험 시간·구역을 예측하여 근무 위치 설정
- 항공 노출도와 조류 충돌 심각도를 결합한 위험 순위로 선제 대응
- 공항별 위험조류 정보를 제공하여 비행 안정성 강화



그림 2-2. 공항별 현황과 위험 정보를 한 화면에서 제공하는 통합 시각화

2.1 현황 및 배경

경험 중심의 대응을 예측 기반의 선제적 안전관리로 전환

항공기와 조류의 충돌은 엔진 손상과 기체 파손을 유발할 수 있으며, 운항 지연과 결항, 정비·보험 비용 증가까지 연쇄적으로 초래한다. 기후변화로 철새의 텃새화와 출몰 시기 변화가 나타나면서 전국 공항의 조류충돌 위험은 더욱 복잡해지고 있다. 2020년 189건 이던 연간 조류충돌은 2024년 354건으로 증가하여 공항 안전관리의 핵심 현안으로 부상했다.

연번	공항명	조류충돌건수	운항편수	연번	공항명	조류충돌건수	운항편수
1	김포	140	757,479	8	양양	3	9,640
2	김해	147	427,658	9	여수	12	33,931
3	제주	119	926,699	10	무안	10	11,004
4	청주	33	110,292	11	사천	5	6,271
5	대구	38	105,837	12	포항경주	3	9,825
6	광주	30	76,970	13	군산	7	10,615
7	울산	12	30,427	14	원주	0	6,207

표 2-1. 공항별 운항편수에 따른 조류충돌 현황

기존 현장 업무는 관제탑과 직원 간 실시간 정보 공유, 초기 순찰, 월별·시간별 경험에 따라 근무 위치를 정하는 방식이 중심이었다. 조류 종별·구역별 데이터가 체계적으로 정리되지 않아 현장 근무자의 경험 의존도가 높았고, 조류 포획 및 분산 이후 조류의 이동에 따라 중복 기록이 발생할 가능성도 있었다. 이에 한국공항공사는 축적된 예방 활동과 충돌 이력에 생태·기상·운항 데이터를 결합하여 위험을 사전에 예측하는 체계로 전환하고자 했다.

분석 대상 공항

한국공항공사가 관리하는 14개의 공항 중에 입지 환경과 상대적 위험도 등을 함께 고려하여 김포·김해·제주·청주·무안공항을 선정했다. 도심형, 연안·하구 습지형, 내륙 농경지·하천형, 화산섬형 등 서로 다른 생태환경을 대표하도록 구성했다.

2.2 분석 필요성

‘어디에, 언제, 어떤 조류가 나타날지’를 조류 출몰 이전에 파악 필요

조류충돌 예방의 핵심은 사고 발생 이후의 대응이 아니라, 조류가 출몰할 가능성이 높은 시간과 공간을 미리 식별해 인력과 장비를 배치하는 데 있다. 그러나 단순 통계만으로는 조류 출몰이 기상, 일출·일몰, 토지 유형, 수계와 어떤 방식으로 결합되는지 설명하기 어렵다. 특히 동일한 기상과 환경이라도 공항의 입지와 운영 여건에 따라 출몰 민감도가 달라 공항별 맞춤형 모델이 필요하다.

① 연안·하구 습지형

공항 무안, 김해, 군산, 여수, 포항, 울산, 양양, 사천

- 연안·하구 습지 및 갯벌 인접, 철새 도래지 영향 큼
- 오리류·백로류 등 습지성 조류 출현多

② 도심형

공항 김포, 광주, 대구

- 대도시 도시에 위치
- 인공 구조물·주거지와 인접 비둘기·까치·참새 등 도심형 조류 출현多

③ 내륙 농경지·하천형

공항 청주, 원주

- 내륙 농경지 및 하천 주변 입지
- 참새·짙·제비 등 농경지·도시형 조류 중심

④ 특수형(화산섬)

공항 제주

- 화산섬 곳자알·송골·용암습지 분포
- 내륙+해안성 조류가 혼합 출현

핵심 분석 질문

- ① 조류 충돌 예방 활동이 필요한 위험 시간대는 언제인가?
- ② 같은 시간대에도 어느 구역을 우선 관리해야 하는가?
- ③ 해당 시간·공간에 어떤 조류가 출몰할 가능성이 높은가?

분석 결과는 현장 실무자가 바로 활용할 수 있도록 지도와 대시보드로 구현해야 했다. 위험 시간대와 구역을 예측하는 데 그치지 않고, 항공기 운항 밀도와 조류별 충돌 심각도를 함께 고려하여 실질적인 우선순위를 제시하는 것이 과제의 중점이었다.

2.3 데이터 목록

공항 운영 데이터와 생태·환경 데이터를 하나의 분석 기반으로 통합

조류 출몰과 서식생물 데이터의 행·열 코드를 결합해 공항 그리드 위치를 생성했다. 기상 데이터는 관측 불가 값이 30% 이상인 변수를 제외하고, 최근 2시간 값, 전날 동일 시각 값, 월·시간 평균값 순으로 보간했다. 풍향과 시간은 주기성을 반영하도록 사인·코사인 변수로 변환했으며, 일출·일몰을 기준으로 상대시간과 박명 여부를 파생했다. 각 그리드 중심점에서 하천까지의 최단거리를 계산하고 토지피복 유형별 면적 비율을 결합해 공간 특성을 수치화했다.

구분	데이터명	주요 활용 속성정보	데이터범위	출처
1	조류 코드정보	조류코드, 과명, 조류종명, 습성내용, 외형, 서식지, 중량, 그룹코드 등	-	한국공항공사
2	조류 출몰실적	IATA 공항코드, 조류코드, 출몰일자, 위치지역코드, 위경도, 개체수 등	2012.01~2025.07	한국공항공사
3	조류 충돌실적	충돌일자, 조류코드, 항공기기종, 운항영향, 기상상태, 충돌부위 등	2012.01~2025.07	한국공항공사
4	항공기 운항 실적	공항코드, 운항편명, 회항여부, 회항사유코드, 실제운항시분등	2012.01~2025.07	한국공항공사
5	조류충돌 비정상 운항	발생일자, 구분코드, 예정출발시분, 실제출발시분등	2009.01~2019.12	한국공항공사
6	서식생물 관리코드	생물코드, 구분코드, 생물명	-	한국공항공사
7	서식생물 관리	IATA공항코드, 서식일자, 위치구역코드, 내부외부구분코드, 위경도 등	2012.01~2025.07	한국공항공사
8	기상데이터	도시, 공항, 풍향, 풍속, 시정, 온도, 날씨, 현재기온, 측정일, 측정시간 등	2012.01~2025.07	기상청
9	공항 내곽그리드맵	14개 공항에 대한 내곽그리드맵	-	한국공항공사

표 2-2. 주요 활용 데이터

2.4 EDA : 충돌·충돌 발생 패턴 분석

충돌과 충돌의 시간·고도·계절·환경 패턴 파악

1,062건 2012~2024년 조류충돌	82건 연평균 충돌	864건 100ft 이하 충돌
----------------------------------	----------------------	----------------------------




그림 2-3. 월별 조류 충돌 건수

2012~2024년 국내 공항에서는 총 1,062건의 조류충돌이 발생했으며, 운항 1만 회당 평균 충돌 건수는 약 2건이었다. 전체 공항 단위에서 특정 시기에 조류충돌 발생이 높다. 이는 절대 운항량보다 공항 주변의 입지와 생태환경이 위험 수준에 크게 작용할 수 있음을 보여준다.



그림 2-4. 국내 공항별 운항 1만회당 충돌 건수

고도별 충돌 분포의 대다수는 이착륙 구간인 100ft이하에 집중되었다.

2.5 EDA : 공항별 공간 특성

같은 조류 충돌 위험도 공항 환경에 따라 다른 모습으로 확인




그림 2-5. 토지피복과 조류 출몰 패턴을 공항별로 비교한 공간 분석 결과

토지 유형 분석에서는 공항별 차이가 분명했다. 김포공항은 주거·상업·업무시설과 수변·농경지가 혼재한 도심형 특성이 나타났고, 김해와 무안공항은 하구·습지·농경지의 영향을 크게 받았다. 청주공항은 농경지와 하천, 제주공항은 해안·초지·과수원 등 해양과 내륙 환경이 혼합된 구조를 보였다.

인공초지 비율과 출몰량의 비선형 관계를 GAM으로 분석한 결과, 김포·무안·제주공항 모두 인공초지 비율 0.8~1.0 구간에서 출몰량이 최고치를 보였다. 이는 초지 면적이 늘수록 위험이 일정하게 증가하는 것이 아니라 특정 임계구간에서 급격히 커질 수 있음을 의미한다. 환경변수 기반 그리드 군집화에서는 농경지, 도심, 연안, 활주로 중심 등 네 유형이 구분되었으며, 논과 하천 인접지, 인공초지와 교통지역을 포함한 군집의 평균 출몰량이 높게 나타났다.

2.6 빅데이터 모델링

시간, 공간, 조류종을 단계적으로 예측하고 충돌 위험도로 통합

단계	분석 모델	방식	주요 입력·산출
1단계	위험 시간대 예측	시간 단위 이진 분류	기상·일출일몰·시간 파생변수
2단계	위험 구역 랭킹	그리드 순위 예측	출몰 이력·공간·환경 변수
3단계	조류(과) 예측	공항별 6개 다중분류	공항별 TOP5 조류(과)+기타
4단계	위험도 평가	종합점수·순위	출몰확률×공간순위×조류심각도×항공노출도

표 2-3. 단계별 분석모델 및 분석 방식

모델 개발을 위해 후보 알고리즘은 CatBoost, XGBoost, LightGBM, RandomForest를 비교했다. 위험 시간대와 조류(과) 분류는 클래스 불균형을 고려해 PR-AUC, Recall, Precision, F1-score를 평가했고, 위험 구역 모델은 실제 출몰 그리드가 상위 K개 후보 안에 포함되는 비율인 Top-K 적중률을 사용했다. 시간대 예측에서는 공항별 데이터 특성에 따라 최적 모델을 선정했고, 공간 랭킹에서는 XGBoostRanker·LightGBMRanker·CatBoostRanker를 비교했다.

빅데이터 모델링 : 네 단계의 예측을 하나의 위험도로 구성

모델링은 현장 의사결정의 순서에 맞추어 네 단계로 설계했다. 먼저 한 시간 단위로 조류 충돌 예방 활동이 필요한 위험 시간대를 판별하고, 위험 시간으로 분류된 시점에는 공항 그리드 가운데 우선 순찰해야 할 구역을 순위화했다. 이어 같은 시간과 공간에서 출현 가능성이 높은 조류(과)를 예측하고, 마지막으로 조류별 충돌 심각도와 항공기 운항 노출도를 결합해 최종 충돌 위험도를 산정했다. 이 구조는 단순히 조류가 많이 나타나는 곳을 찾는 데 그치지 않고, 실제 항공기 운항과 겹쳐 사고 가능성이 커지는 시간과 장소를 구분하기 위한 것이다.

단계	질문	주요 입력	현장 산출물
1. 위험 시간	언제 출몰 가능성이 높은가	월·요일·시간, 기온·습도·풍향·풍속·시정, 일출·일몰 상대시간과 박명 여부	시간별 위험 확률과 집중관리 시간대
2. 위험 구역	같은 시간에 어디를 먼저 볼 것인가	시간별 출몰 이력, 공항 그리드, 토지유형, 하천거리와 공간적 특성	그리드별 위험 순위와 Top-K 관리 후보

단계	질문	주요 입력	현장 산출물
3. 조류(과)	어떤 조류가 출현할 가능성이 높은가	공항별 출몰 상위 5개 조류(과), 기상·시간·환경 변수	공항별 6개 클래스 출현 확률
4. 종합 위험도	출몰이 실제 운항 위험으로 이어지는가	위험 시간 확률, 그리드 순위, 조류 충돌 심각도, 항공기 노출도	시간·공간·조류를 통합한 최종 위험점수

표 2-4. 모델링 흐름 및 산출 결과

위험 시간대와 조류(과) 예측에는 CatBoost, XGBoost, LightGBM, RandomForest를 후보 모델로 적용했다. 조류 예방 활동은 실제 발생 시간보다 발생하지 않은 시간이 많거나 공항별 양성·음성 비율이 달라질 수 있으므로, 전체 정확도만으로 모델을 고르지 않았다. 양성 탐지 성능을 민감하게 반영하는 PR-AUC를 우선 비교하고 Recall 0.8 이상을 기본 조건으로 삼은 뒤 Precision과 F1-score의 균형을 확인했다. 위험 구역은 분류 문제가 아니라 같은 시간대의 여러 그리드 중 우선순위를 정하는 문제이므로 CatBoostRanker, XGBoostRanker, LightGBMRanker를 비교하여 평가했다.

위험도는 ‘출몰 가능성’과 ‘충돌 결과의 심각성’을 함께 분석

조류별 충돌 심각도는 체중, 군집 출현 특성, 과거 충돌 자료와 표본 수를 반영해 산정했다. 극단적으로 큰 조류가 전체 점수를 왜곡하지 않도록 이상치를 제어하고 로그 스케일로 정규화했다. 군집 위험은 평균 군집 빈도를 70%, 군집 경험 유무를 30% 반영해 일시적 관측보다 반복적으로 무리를 이루는 경향에 더 큰 의미를 두었다. 표본이 적은 조류는 위험도가 과도하게 높거나 낮게 산출되지 않도록 평균값 방향으로 스무딩했다.

항공기 노출도는 공항별·시간대별 실제 운항 횟수를 집계하고 특정 날짜의 결항이나 일시적 운항 급증이 기준을 흔들지 않도록 중앙값으로 기대 운항 강도를 산정했다. 이 값을 활주로 중심 그리드 1.0, 인접 영역 0.6, 외곽 영역 0.3의 공간 가중치로 분배해 항공기가 실제로 통과할 가능성을 근사했다. 최종 위험도는 위험 시간 예측 확률, 그리드 위험 순위, 예측 조류의 충돌 심각도, 항공 노출도를 결합해 계산했다. 상위 5개 조류(과)에 포함되지 않은 기타 조류에도 기본 위험값 0.3을 부여하여 정보 부족으로 위험이 0에 수렴하지 않도록 했다.

2.7 모델 성능과 해석

공항별 성능 차이를 인정하고 현장 활용에 맞는 최적 모델을 개발

공항	최종 위험시간 모델	F1-score	PR-AUC
김포	CatBoost	F1 97.46	PR-AUC 98.34
김해	CatBoost	F1 91.39	PR-AUC 92.50
제주	CatBoost	F1 87.79	PR-AUC 81.70
청주	CatBoost	F1 74.24	PR-AUC 71.53
무안	RandomForest	F1 60.70	PR-AUC 63.99

표 2-5. 공항별 모델 성능




그림 2-6. 공항별 변수 중요도(김포, 김해, 제주, 청주, 무안)

공항별로 성능차이가 존재하기 때문에 공항별 특성에 따른 모델을 따로 개발하였다. 김포공항의 위험 시간 예측에서는 기온, 상대습도, 일출 이후 시간 등이 중요했다. 김해공항은 주간 여부와 현재 시간, 천문박명 종료 여부, 겨울 계절성이 주요 변수였다. 제주·청주·무안공항은 현재 시간과 일출·일몰 기준 상대시간의 영향이 크게 나타났다. 즉 조류 활동은 절대 시간만이 아니라 공항별 일조 조건과 계절·기상의 결합으로 설명해야 했다.

조류 예측

각 공항의 출몰 이력에서 상위 5개 조류(과)를 선정하고 나머지를 기타로 묶어 6개 클래스로 분류했다. 김포는 매과·오리과, 김해는 종다리와·까마귀과·백로류, 제주는 참새과·제비과·비둘기과, 청주는 참새과·오리과·백로과, 무안은 매과·물떼새과·평과를 중심으로 예측했다.

2.8 모델 시각화

위험을 ‘현장 행동’으로 바꾸는 대시보드



그림 2-7. 공항별 일간 위험지도(충돌 확률과 위험 순위) 예시

시각화 화면은 김포·김해·제주·청주·무안공항을 선택할 수 있는 접속화면과 일간·주간·월간 대시보드, 상세 검색 화면으로 구성했다. 지도에서는 조류 충돌 예측과 조류 충돌 위험도를 전환해 확인할 수 있고, 그리드 셀을 선택하면 해당 구역의 확률, 예상 조류, 위험 단계와 기상 정보를 조회할 수 있다.




그림 2-8. 지도·통계표·시간대 그래프를 결합해 위험 원인을 설명하는 대시보드

일간 화면은 다음 날, 주간 화면은 다음 주, 월간 화면은 다음 달의 위험 분포를 제공한다. 우측 통계표는 위험도가 높은 순서대로 정렬되며, 상세 화면에서는 연도·월·일·시간·조류(과)·위험 단계별 검색이 가능하다. 인쇄와 엑셀 기반 그래프 생성 기능을 포함해 현장회의, 근무계획 수립, 관계기관 공유에 바로 활용하도록 설계했다.

2.9 분석모델 정책 활용 성과

조류충돌 예방 인력과 장비를 ‘필요한 곳에 먼저’ 배치

현재 5개 공항 현장에서 해당 모델을 실제 활용하고 있다. 분석모델 예측 결과로 나타나는 조류 충돌 고위험 시간 및 위치에 인력 및 장비를 선제적 배치하여 조류 충돌 예방 활동을 수행 중이다.

조류충돌 위험도 평가 결과를 활용해 고위험 시간대와 공간을 사전에 식별하고, 조류충돌 예방 인력을 위험 구간 중심으로 배치하였다. 현재의 정기 순찰과 관제 연락 중심 대응에 예측 정보를 더하면 순찰 경로와 근무조 편성을 구체화하고, 활주로 이착륙 구간과 외곽 유입 경로를 우선 관리할 수 있다.

또한, 공항별로 다른 생태환경과 우점 조류를 반영한 맞춤형 예방 계획을 수립할 수 있다. 김포의 대형 수조류, 김해의 하구·습지 조류, 제주의 해안·강풍 영향, 청주의 농경지·하천 조류, 무안의 철새도래지·중대형 조류 등 서로 다른 위험 요인에 맞추어 장비와 대응 방식을 차등화하며 고도화할 수 있다.

위험지도와 시간대별 통계는 관제, 공항 운영, 조류충돌 예방팀이 동일한 상황 인식을 공유하도록 돕고, 교육·훈련과 예방 홍보 자료로도 활용할 수 있다. 뿐만 아니라, 지속적인 추가 데이터 확보 등을 통해 예측 정확도를 개선하며 공항 안전정책 확보를 위해 노력할 예정이다.





1-3

농산물 중점 수거 · 검사대상 선별 모델 개발



Part 1-3

농산물 중점 수거·검사대상 선별 모델 개발

식품의약품안전처

식탁에 오르기 전 농산물 위험 예측 모델로 살펴 국민의 안전한 먹거리 확보

분석 배경	분석 방법	분석 결과
방대한 검사자료를 수기로 비교해 수거·검사 대상을 정하는 데 한계 존재	생산·유통 검사와 기상 데이터를 표준화해 지역·월·품목별 부적합률 예측	위험품목 자동선별과 통계·원자료 조회 화면을 MLOps 환경에 배포

과제 한눈에 보기

농산물 잔류농약 검사는 국민의 먹거리 안전을 지키는 핵심 업무다. 그러나 검사 대상 품목과 생산·유통지역이 다양하고 검사자원은 한정되어 있어 과거 부적합 통계만으로 우선순위를 정하는 데 한계가 있었다. 계절과 지역, 기상조건에 따라 달라지는 위험을 반영한 선별체계가 필요했다.

이에 식품의약품안전처는 생산단계와 유통단계의 잔류농약 검사자료를 표준화하고 기온·강수 등 기상정보와 지역·시기·품목 특성을 결합했다. 트리 기반 회귀모델을 활용해 지역·월·품목별 부적합 위험도를 산출하고, 위험도에 영향을 준 주요 요인을 함께 확인하도록 했다.

분석 결과는 지역과 시기, 품목을 선택해 예측위험도와 우선 검사대상을 확인하는 화면과 엑셀 자료로 구현했다. 이를 통해 부적합 가능성이 높은 농산물을 우선 수거·검사하고 한정된 검사자원을 효율적으로 배분해 먹거리 안전관리의 사전예방 기능을 강화할 기반을 마련했다.



그림 3-1. 지역·월·품목별 예측결과를 제공하는 시각화 화면

💡 이렇게 바뀌었습니다!

수기 통계 중심의 대상 선정에 AI 기반 위험예측으로 고도화

이번 과제는 흩어진 기록을 하나의 분석체계로 연결하고 결과를 현장의 행동정보로 바꾸었다.

생산·유통 검사자료와 기상정보를 표준화하였다. 트리 기반 모델로 지역·월·품목별 부적합률을 예측하고 정책 목적에 맞는 Recall 지표로 검증하고, 위험품목, 통계, 원자료를 한 화면에 제공했다. 식품의약품안전처 본부와 6개 지방청이 수거·검사 대상을 선정하는 참고자료로 활용할 기반을 마련하였다.

데이터 수집에서 분석과 활용까지 이어진 이 흐름은 유사한 공공업무로 확산할 수 있는 기반이 되었다.





그림 3-2. 기존 업무와 AI 적용 후 업무의 변화

3.1 현황 및 배경

생산부터 유통까지 여러 기관이 농산물 안전을 함께 관리

공공서비스의 변화는 현장에서 반복되는 불편과 위험을 정확히 바라보는 데서 시작된다. 농산물 안전관리는 모든 품목을 같은 강도로 검사하기보다 시기와 지역에 따라 위험 가능성이 높은 대상을 먼저 찾는 것이 중요하다.

식품의약품안전처는 국내 농산물 안전관리의 총괄기관으로 생산부터 유통까지 전 단계를 관리하는 총괄 기관이다. 식품행정통합시스템은 지방청, 농림축산식품부, 17개 지방자치단체의 잔류농약·중금속 검사자료를 실시간으로 수집하고, 부적합 지역·품목·성분 분석을 매월 유관기관과 공유했다.

수집하여 검사한 결과 기관별로 약 400~510종의 잔류농약 성분을 정밀검사하고 기준을 넘으면 압류·폐기 또는 출하시기 연기 등 행정조치를 실시한다.

● 과제 분석 배경



그림 3-3. 농산물 안전관리 현황과 주요 이슈

3.2 분석 필요성

한정된 인력으로 위험품목을 더 정확히 선별 필요

식품의약품안전처와 농림축산식품부의 농산물 분류체계가 달라 동일 품목도 코드와 명칭이 다르게 관리되어 데이터 통합에 추가 시간이 필요했다.

또한, 기존에는 과거 부적합 자료를 단순 비교해 검사 대상을 정하였고, 기상과 병해충 등 외부요인을 충분히 활용하지 못했다. 뿐만 아니라, 방대한 자료를 수기로 분석하는 데 시간·예산·인력의 한계가 있어 지역과 월별 위험품목을 자동으로 산출하는 분석이 필요했다.

핵심 분석 질문

- ① 어느 지역의 어떤 품목이 위험한가?
- ② 위험이 높아지는 시기는 언제인가?
- ③ 기상과 과거 검사이력 가운데 부적합 가능성을 높이는 요인은 무엇인가?

세부 분석은 이 질문에 답하면서 현장에서 우선 확인해야 할 대상을 구체화하는 방향으로 설계했다.

3.3 데이터 목록

생산·유통 검사와 날씨를 같은 기준으로 표준화

좋은 분석은 많은 자료를 모으는 것보다 서로 다른 자료를 같은 기준으로 정확히 연결하는 데서 출발한다.

생산단계는 국립농산물품질관리원의 검사자료를 활용했다. 수집 790,810건 가운데 조건에 맞는 407,015건을 분석했다. 유통단계는 식품의약품안전처의 수거·검사 및 부적합 통보자료를 사용했다. 기상청 종관관측 자료에서 기온, 강수, 바람, 기압, 습도, 일사·일조 등을 결합했다.

품목명은 식품의약품안전처 기준 분류체계로 표준화했다. 지역×월×품목 단위로 검사 건수, 부적합건수와 부적합률을 집계했다.

분석 대상과 범위

생산·유통단계 잔류농약 검사자료를 식품의약품안전처 품목체계로 표준화하고 기온·강수 등 기상정보를 지역·월·품목 단위로 결합했다.

데이터명	주요 변수	보유기관
유통단계 수거검사 데이터 (LIMS 데이터)	LIMS 의뢰번호, 분야, 품목유형명, 검체명, 성적일자, 판정 등	식품의약품안전처
유통단계 수거검사 데이터 (부적합 통보 데이터)	관할기관, 원산지, 제품유형, 보고일자, 시험항목, 결과 등	식품의약품안전처
생산단계 수거검사 데이터 (SAFEQ 데이터)	분석구분, 수거일, 접수번호, 시료번호, 품명, 수거시도, 재배지, 검출성분, 검출치 등	국립농산물품질관리원
품목코드 테이블	품목코드, 품명 등	식품의약품안전처, 국립농산물품질관리원

표 3-1. 주요 활용 데이터

3.4 EDA : 검사와 부적합 현황

검사량과 부적합이 품목·지역·시기별로 다를 수 있음 확인

모델을 만들기 전에는 데이터의 분포와 차이, 결측과 이상값을 충분히 살펴야 한다. 이 탐색과정은 모델의 방향을 정하는 기초가 된다.

연도별 검사건수와 부적합건수를 비교해 장기 변화를 확인했다. 품목별 검사 편중과 부적합 발생의 차이도 함께 살펴보았다. 검사건수가 매우 적은 구간에서 부적합 1건이 발생하면 부적합률이 50% 또는 100%로 크게 뛰었다. 이와 같은 결과는 단순 비율만으로 위험을 판단하면 작은 표본이 과대평가될 수 있었다. 따라서 최근 검사건수와 부적합건수, 기간별 부적합률을 함께 파생변수로 만들었다.

전체 품목 1,195개 중 최근 5년간 부적합 판정을 1회 이상 받은 품목은 210개, 5회 이상 받은 항목은 102개로 전체 품목 대비 각 17.6%, 8.5%로 부적합 판정이 소수 품목에 집중되었다. 또한, 부적합 판정 건수 기준 상위 80%를 차지하는 품목은 55개로 소수에 해당하였다.



그림 3-4. 최근 5년간 부적합 판정 품목 현황



그림 3-5. 주요 부적합 판정 품목 수

또한, 전체 농산물 안전 검사 중 잔류농약이 차지하는 비중이 전체의 약 91%로 나타났다.




그림 3-6. 농산물 안전검사 항목 구분

3.5 EDA : 시가·품목·기상 패턴

과거 위험과 계절·날씨의 관계를 탐색

최근 3개월·6개월 부적합률, 전년도 동월 전후 3개월 부적합률, 최근 3년 검사·부적합 건수를 계산하고, 기상청 종관기상과 농촌진흥청 농업기상을 비교했다.

농업기상 자료의 RMSE가 0.239로 종관기상 0.242보다 소폭 낮았다. 차이가 크지 않았고 운영 안정성과 기존 수집체계를 고려해 기상청 종관기상 자료를 최종 활용했다.




그림 3-7. 월평균 부적합 건수 빈도표

총 검사 건수는 10월 > 9월 > 11월 > 6월 > 7월 순으로 나타나며, 1~4월과 12월은 검사 건수가 다른 월 대비 낮게 나타났다. 부적합 건수는 10월>6월>5월>7월 순으로 높게 나타나며, 해당 월들은 총 300건 이상의 부적합을 기록. 부적합률은 검사 건수가 적은 상반기에서 높게 나타나는 경향을 보였다.




그림 3-8. 월별 검사 건수

그림 3-9. 월별 부적합 건수

3.6 빅데이터 모델링 : 예측 구조

지역·월·품목별 부적합률을 회귀모델로 예측

탐색 결과를 토대로 실제 업무의 판단과정을 모델 구조에 옮겼다. 성능뿐 아니라 현장에서 설명하고 운영할 수 있는지도 함께 고려했다.

종속변수는 지역×월×품목 단위의 원자료 부적합률로 정했다. 과거 발생패턴, 검사건수 변화, 기상조건과 지역특성을 입력변수로 사용했다. Random Forest, LightGBM, XGBoost, CatBoost와 시계열 모델 Chronos를 비교한 결과, 트리 기반 모델은 변수 중요도를 제공하고 월별 집계자료에서 안정적인 성능을 보였다.

생산단계와 유통단계를 구분해 모델을 개발했다. 유통 모델에는 생산단계 최근 3개월 부적합률도 반영했다. 이렇게 구축한 모델은 다음 단계에서 실제 자료를 얼마나 안정적으로 설명하는지 성능과 오류를 함께 검증했다.

3.7 빅데이터 모델링 : 안정화와 검증

시간 순서를 지키고 작은 표본의 급격한 변동 완화

탐색 결과를 토대로 실제 업무의 판단과정을 모델 구조에 옮겼다. 성능뿐 아니라 현장에서 설명하고 운영할 수 있는지도 함께 고려했다.

미래정보가 학습에 섞이지 않도록 과거구간으로 학습하고 이후 시점을 검증하는 Rolling Walk-Forward 방식을 사용했다.

학습시간과 성능을 고려해 재학습 주기는 6개월로 설정하였고, 이렇게 구축한 모델은 다음 단계에서 실제 자료를 얼마나 안정적으로 설명하는지 성능과 오류를 함께 검증했다.

3.8 모델 성능과 해석 : 정책지표

오차뿐 아니라 실제 위험품목을 놓치지 않는지 평가

모델의 가치는 하나의 높은 점수보다 어떤 사례를 잘 찾고 어디에서 틀리는지를 분명히 설명할 때 드러난다.

최종 모델 선정을 위한 고도화 전략(베이지안 스무딩 적용, Tweedie 비용 함수 적용, 파생변수 확장 등)을 반영하여 모델의 성능을 평가하였다. 평가는 정책활용지표(recall 기반)를 중심으로 회귀오차지표(RMSE, MAE)를 보조지표로 활용했다.

최종 모델은 두 가지로 나뉘었다. 첫째, 생산 단계 예측 모델은 Recall($\geq 1\%$)는 96.6%로 높게 나타나, 실제 상위 위험 품목을 정책 기준(1%) 이상으로 탐지하는 성능이 우수함을 확인하였다.

두번째, 유통 단계 예측 모델은 Recall($\geq 1\%$)는 95.0%로 높게 나타나, 정책 기준(1%) 수준의 위험 품목 탐지 성능이 우수함을 확인하였다.



그림 3-10. 생산 단계 예측 모델 성능




그림 3-11. 유통 단계 예측 모델 성능

3.9 모델 시각화

지역·월·품목별 위험과 근거자료를 함께 제시

복잡한 분석결과가 현장에서 쓰이려면 사용자가 다음 행동을 바로 결정할 수 있는 화면으로 바뀌어야 한다.

시각화 화면에서 생산·유통 단계와 지역, 권역, 월을 선택할 수 있었다. 예측 부적합률과 위험품목을 그래프와 표로 확인했기 가능하며, 시험항목 구분별 통계와 원자료 조회, 엑셀 다운로드를 제공했다. 추가로 참고할 수 있는 통계자료도 제공하여 원활한 정책 결정을 내릴 수 있게 하였다. 화면은 분석결과를 보여주는 데 그치지 않고 담당자가 우선순위를 정하고 후속조치를 선택하도록 구성했다.



그림 3-12. AI 예측과 통계정보를 제공하는 시각화 서비스

3.10 분석모델 정책 활용 성과

본부와 6개 지방청의 수거·검사 계획 수립을 지원

식품의약품안전처에서는 분석모델을 활용하여 농산물 수거 검사의 부적합률 검출률을 제고할 예정이다. 이를 통해 업무에 소요되는 시간 감소와 대국민 신뢰 및 안정성 제고로 산업 및 수출 확대에 기여할 계획이다.

구체적으로 첫째, 모델로부터 도출된 결과를 지역·월별 위험품목을 자동 산출해 중점 수거·검사 대상을 정하는 근거자료로 식품의약품안전처 본부와 6개 지방 식약청이 공동으로 사용할 수 있도록 제공하여 부적합통계, 시각화정보등 분석자료 배포를 통해 농림축산식품부와 국립농산물품질관리원까지 활용범위를 넓힐 기반을 마련했다. 이를 통해 기존의 과거 통계 기반 사후 대응 방식에서 벗어나, 예측 기반의 선제적 검사 계획 수립이 가능해졌다.

둘째, 통합된 분류체계와 예측결과는 기관 간 일관된 농산물 안전관리 정책 수립을 지원했다. 이를 통해 중앙과 지방 간 동일한 데이터 기준 및 분석 체계를 적용할 수 있으며, 지역별 위험 품목 관리의 일관성 확보 가능하였다.

셋째, 농림축산식품부와 식품의약품안전처의 상이한 품목 분류체계를 매핑 테이블로 정비하여, 수작업 통합 과정을 제거하여 기관 간 데이터 연계 및 통계 산출의 표준화 기반을 마련하고, 반복적인 수거 매핑 업무를 자동화하였다. 이를 통해 업무 효율화를 창출할 수 있었다.





1-4

자율운항선박의 안전 확보를 위한 최적화된 운항 경로 및 패턴 분석



Part 1-4

자율운항선박의 안전 확보를 위한 최적화된 운항 경로 및 패턴 분석

해양경찰청

바다 위 다음 움직임을 선박 경로 예측 모델로 읽다

분석 배경	분석 방법	분석 결과
해상교통량 증가와 자율운항선박 등장으로 해양 환경이 매우 복잡해짐	AIS·V-PASS·선박제원· 해양기상을 결합해 경로예측과 이상거동 탐지 모델을 개발	20~60분 예측경로와 충돌·이상 위험을 지도에서 확인하는 관제지원 체계를 마련

과제 한눈에 보기

해상교통량과 레저활동이 증가하고 자율운항선박의 실증이 확대되면서 해상관제 환경이 더욱 복잡해졌다. 현재 위치와 현상을 확인하는 관제만으로는 선박의 급격한 침로 변경이나 충돌 가능성을 충분히 앞서 파악하기 어려웠다. 유인선과 무인선이 함께 운항하는 환경에 대비한 미래경로 예측체계가 필요했다.

이에 해양경찰청은 AIS·V-PASS 항적과 선박제원, 입출항 이력에 수심·조석·조류·풍속·파고·해무 등 해양기상 정보를 결합했다. 권역과 선종별 이동특성을 반영해 20·40·60분 뒤의 경로를 예측하고, 예측항적과 실제 움직임을 차이 및 DCPA·TCPA를 활용해 이상거동과 충돌위험을 탐지했다.

분석 결과는 현재 항적과 미래 예측경로, 해양기상과 위험신호를 관제 지도에서 함께 확인하는 화면으로 구현했다. 이를 통해 위험 선박을 우선 확인하고 관제 집중도와 구조자원 배치를 조정해 자율운항선박 시대의 선제적 해상안전을 지원할 기반을 마련했다.



그림 4-1. 선박 위치와 위험 선박 정보를 함께 확인하는 시각화 화면.



이렇게 바뀌었습니다!

현재 위치 확인 중심의 관제를 미래 위험 예측 중심으로 개선

AS-IS	TO-BE
• 현재 선박 위치와 현상 중심만 관제 가능 • 관제사의 경험과 개별 정보 확인에 의존 • 기상·항적·선박제원 정보가 분산되어 확인하기 어려움	• 20~40~60분 뒤의 선박 경로를 예측하여 표출 • 예측과 실제 항적의 차이로 이상거동을 표시하여 미래 시점의 정보 제공 • 해양기상과 충돌위험 등의 분산된 정보를 한 화면에서 확인 가능




그림 4-2. 해역 및 시간대별 선박 통수에 따른 충돌 사고 현황

4.1 현황 및 배경

증가하는 해상활동과 자율운항선박이 새로운 관제 과제로 대두

바다는 같은 항로를 이용하는 상선과 어선, 레저선박이 끊임없이 교차하는 공간이다. 통항량이 늘수록 관제사가 동시에 살펴야 할 선박과 위험상황도 함께 증가한다. 2018년부터 2024년까지 해상안전사고가 42% 늘었고, 2023년과 2024년 사이 국내 해양사고도 5.3% 증가한 것으로 나타나 보다 선제적인 관제지원이 요구되었다.

해양경찰청은 AIS와 V-PASS, 관제레이더, CCTV, 항공촬영 등 다양한 장비를 활용해 선박의 위치와 움직임을 확인해 왔다. 그러나 기존 화면은 현재 위치와 주변 상황을 보여주는 데 초점이 맞춰져 있었다. 선박이 수십 분 뒤 어느 해역으로 이동할지, 실제 항적이 정상적인 흐름에서 벗어나는지, 가까운 선박과 충돌위험이 커지는지를 한 번에 판단하기에는 정보가 분산되어 있었다.

여기에 자율운항선박의 원격제어와 해상실증이 확대되면서 관제환경은 더욱 복잡해졌다. 유인선과 무인선이 같은 바다를 이용하면 서로 다른 운항방식과 반응특성을 함께 고려해야 한다. 기존 관제정보를 공통 데이터로 정비하고, 미래 이동과 위험을 예측하는 분석체계를 마련하는 일이 새로운 해상안전 과제로 떠올랐다.

관제환경의 변화

통항량 증가에 따른 동시 관제대상 확대

자율운항선박 실증에 따른 유인선·무인선 혼재

현재 위치 확인을 넘어 미래 경로와 위험을 함께 판단할 필요



그림 4-3. AIS·V-PASS·레이더·CCTV 등 여러 감시수단을 활용하는 해상관제와 선박 모니터링 현장

4.2 분석 필요성

선박의 미래 위치와 위험한 움직임을 미리 파악 필요

관제현장의 부담을 줄이려면 단순히 더 많은 정보를 보여주는 것보다, 어떤 선박을 먼저 확인해야 하는지 설명하는 분석이 필요했다. 선박의 과거 항적에서 이동 흐름을 읽고, 해역과 선종의 차이를 반영해 앞으로의 위치를 예측해야 위험이 커지기 전에 교신과 회피안내를 검토할 수 있었다.

조류와 풍속, 파고, 해무 같은 해양기상은 선박의 속력과 침로에 직접 영향을 준다. 특히 소형선박과 예인선은 국지적인 돌풍이나 조류 변화에 민감하다. 그러나 예보와 실측 사이에는 시간차가 있고 관측지점의 간격도 넓어, 선박이 실제로 위치한 지점의 환경을 그대로 설명하기 어려웠다. 주변 관측값을 공간적으로 보완하고 항적과 같은 시간축에 맞추는 과정이 필요했다.

선박의 크기와 폭, 흘수, 화물, 선종에 따라 조종성능도 달랐다. 같은 속력과 침로 변화라도 대형 상선과 소형 어선의 의미는 다를 수 있었다. 따라서 하나의 전국 공통모델보다 권역과 선종을 구분한 예측이 적절했다. 또한 관제사가 별도 시스템을 오가며 정보를 찾지 않도록 위치·예측경로·기상·이상거동·충돌위험을 하나의 화면에서 연결해야 했다.

핵심 분석 질문

- ① 선박은 20·40·60분 뒤 어느 위치에 도달할 것인가?
- ② 예측경로와 실제 항적의 차이에서 이상거동이 나타나는가?
- ③ 두 선박의 최근접거리와 도달시간은 충돌위험을 어떻게 보여주는가?

4.3 데이터 목록

선박 항적과 바다 환경을 하나의 시간·공간 데이터로 통합

선박의 다음 움직임을 설명하려면 위치정보만으로는 부족했다. AIS와 V-PASS에서 수집한 위도·경도, 속력, 침로를 중심으로 선박제원과 입출항 이력을 연결했다. 선박 길이와 폭, 흘수, 선종, 목적지 등의 정보는 같은 항적이라도 조종특성이 달라지는 이유를 설명하는 데 활용했다.

수심과 조석, 조류, 풍속, 파고, 해무, 기상특보는 선박이 놓인 항해조건을 보여주는 자료였다. 관측값은 지점마다 수집시각과 공간 간격이 달랐기 때문에 항적과 동일한 기준시각으로 맞추고, 주변 관측소의 값을 활용해 선박 위치의 환경값을 추정했다. 해양사고 이력은 위험이 자주 나타난 해역과 선종, 계절을 파악하는 탐색자료로 사용했다.

구분	주요 데이터	활용
선박 이동	AIS, V-PASS	항적·속력·침로 파악
선박 특성	선박제원, 입출항 이력	권역·선종별 모델 구성
해양환경	수심, 조석, 조류, 파고	운항 영향 반영
기상·안전	풍속, 해무, 특보, 사고이력	위험 판단과 시각화

표 4-1. 주요 활용 데이터

정비된 데이터는 동적DB, 정적DB, 항해DB로 구분해 관리했다. 실시간으로 변하는 항적은 동적DB에, 선박제원과 입출항 이력은 정적DB에, 수심·조석·특보 등 항해조건은 항해DB에 배치했다. 이렇게 역할을 나눈 데이터 구조는 탐색과 모델 학습, 실시간 분석, 화면 제공을 같은 기준으로 이어주는 공통 기반이 되었다.

분석 대상과 범위

AIS·V-PASS 항적과 선박제원·입출항 이력에 수심·조석·조류·풍속·파고·해무를 결합하고 권역과 선종별로 분석했다.

4.4 EDA : 항적 품질과 이동 패턴

끊어진 신호를 보완하고 선박의 이동 흐름을 복원

모델을 만들기 전에는 데이터의 분포와 차이, 결측과 이상값을 충분히 살펴야 한다.

AIS 항적에는 수신 누락과 시간 간격 차이가 있었다. 실시간 처리 속도와 성능을 고려해 Linear와 Spline 보간을 적용했다. 상대운동 기하를 이용해 두 선박의 최근접거리 CPA와 최근접시간 TCPA를 계산했다. TCPA가 0보다 작은 경우는 이미 최근접 시점을 지난 것으로 구분했다. 이 과정을 통해 모델이 불규칙한 신호가 아니라 연속된 이동 흐름을 학습하도록 했다.




그림 4-4. 누락된 항적을 보완한 비교 결과

4.5 EDA : 해역·선종별 차이

항구와 선종에 따라 속력과 이동 분포 차이 확인

권역별 항적 분포를 비교하자 항로의 모양과 밀집 구역이 서로 달랐다. 같은 알고리즘을 전국에 일괄 적용하면 지역별 오차가 커질 수 있었다. 또한, 선종별 분석에서도 속력, 침로 변화, 체류 패턴이 다르게 나타났다. 특히 조종 성능과 조류의 영향을 크게 받는 선박은 별도 특성 반영이 필요했다.

따라서 학습데이터를 권역과 선종으로 그룹화하고 독립 모델을 구성하는 방향을 정했다. 확인된 분포와 차이는 변수선정과 모델구조, 평가방법을 결정하는 근거로 이어졌다.

● 서해해역 3개 권역

- ▶ 인천권역 범위 :
항만 VTS : 경인항, 인천항, 평택항,
대산항
연안 VTS : 경인연안, 태안연안 일부
- ▶ 군산권역 범위 :
항만 VTS : 군산항
연안 VTS : 군산광역시, 태안연안 일부
- ▶ 목포권역 범위 :
항만 VTS : 목포항
연안 VTS : 진도연안, 목포광역시




● 남해 4개 권역

- ▶ 완도권역 범위 :
항만 VTS : 완도항
연안 VTS : 여수연안
- ▶ 제주권역 범위 :
항만 VTS : 제주항
연안 VTS : 제주광역시
- ▶ 여수+통영권역 범위 :
항만 VTS : 여수항
연안 VTS : 통영연안
- ▶ 부산권역 범위 :
항만 VTS : 마산항, 부산신항, 부산항



● 동해 3개 권역

- ▶ 울산권역 범위 :
항만 VTS : 울산항
- ▶ 포항권역 범위 :
항만 VTS : 포항항
- ▶ 동해권역 범위 :
항만 VTS : 동해항



4.6 빅데이터 모델링 : 경로 예측

선박의 관성과 시공간 패턴을 함께 학습

성능뿐 아니라 현장에서 설명하고 운영할 수 있는지도 함께 고려했다.

STENet, LSTM·CNN 결합모델, Encoder·Decoder와 Attention 기반 모델을 비교했다. 최종적으로 Trajectory Inertia Transformer를 적용했다. 모델은 위치와 시계열 관계를 함께 학습했다.

총 3가지의 분석 주제에 대해 모델을 다르게 적용하였고, 예측 시간 간격은 20분, 40분, 60분 예측모델을 구성했다. 이렇게 구축한 모델은 다음 단계에서 실제 자료를 얼마나 안정적으로 설명하는지 성능과 오류를 함께 검증했다.

모델명	생성내용	적용 AI 모델	적용기능	특징
선박 예측경로생성 AI 모델	선박 과거이동경로상 동적특징, 항해중 특정데이터를 반영하여 선박이동 예측경로를 생성	Deep Learning Model (LSTM, Attention 모델 등)	• 선박이동 예측 • 이상거동 탐지	• 중장기 경로 생성 • 실시간 선박교통량 반영 X
선박 피항경로 생성 AI 모델	선박간 충돌위험도에 따라 선박 피항경로를 생성	Machine Learning Model (Fuzzy 추론 모델)	• 선박충돌회피 경로생성	• 단기 경로 생성 • 실시간 선박교통량 반영
선박 이상거동 탐지 AI 모델	선박 예측경로와 실제이동 항적간 오차와 관제사의 피드백을 학습 하여 이상거동 유무를 판별	Machine Learning Model (Random Forest 등 분류모델)	• 이상거동 탐지	• 2단계 (오차 및 사용자 학습 기반) 평가 모델

표 4-2. 적용 모델 개요

첫째, 예측 경로 생성 모델은 선박의 과거항적, 목적지, 선박특성, 해양환경 등 요소를 반영하여 향후 진행되는 선박의 예측 경로를 생성하였다. 둘째, 이상거동 탐지 모델은 현재 위치에서 과거 30분 전의 지점을 기준으로 생성된 예측경로와 [현재~과거 30분] 동안 실 경로를 비교하였다. 셋째, 선박충돌의 국제항해 규약(국제해상충돌예방규칙 협약(COLREGs), 1972)에 기반한 충돌회피 과정을 준수하며 타 연구에서 선박 간 충돌위험성 평가 방법을 비교하여 모델 선정하였다.

모델에 대한 참고논문

- Kim, K.-I., & Lee, K. M. (2018). Deep learning-based caution area traffic prediction with automatic identification system sensor data. *Sensors*, 18(9), 3154.
- Namgung, H. (2019). Anomalous vessel behavior detection based on SVR seaway model. *International Journal of Fuzzy Logic and Intelligent Systems*, 19(1), 18-24.
- Chen, X., Wu, P., Wu, Y., Aboud, L., Postolache, O., & Wang, Z. (2025). Ship trajectory prediction via a transformer-based model by considering spatial-temporal dependency. *Intelligence & Robotics*, 5(3), 562-578.

4.7 모델 성능과 해석 : 전체 성능

327만여 건으로 시간대별 위치의 오차 검증

모델의 가치는 하나의 높은 점수보다 어떤 사례를 잘 찾고 어디에서 틀리는지를 분명히 설명할 때 드러난다.

총 3,275,467건의 평가 표본을 사용했다. 전체 60분 이동 구간의 평균 변위 오차인 ADE는 1.04km였다. 60분 시점의 최종 변위 오차인 FDE는 2.41km였다. RMSE는 큰 오차에 민감하게 반응하나 ADE는 전체 경로의 평균적인 차이를, FDE는 마지막 예측지점의 차이를 보여주었다.

예측 시간이 길어질수록 불확실성도 커졌다. 따라서 관제에서는 단기 예측을 우선 활용하고 중·장기 예측은 위험 방향을 살피는 보조정보로 사용하도록 하였다.

평가 항목	결과	의미
평가 표본	3,275,467건	대규모 항적 기반 검증
ADE(평균 변위 오차)	1.04km	전체 60분 이동 거리 중 평균 시점 오차
FDE(최종 변위 오차)	2.41km	60분 이동거리 시점 오차

표 4-3. 모델 성능

4.8 모델 성능과 해석 : 지역·선종

하나의 평균보다 해역과 선종별 오차를 함께 확인

지역별 RMSE와 선종별 RMSE를 따로 산출했다. 해역의 항로 형태, 조류, 선박밀도와 선종의 조종 특성이 예측 난이도에 영향을 주었다. 성능이 낮은 구역에서는 관제사의 판단을 우선하고 AI 결과를 참고정보로 활용해야 했다.

향후 출입항정보, 선박밀집도, 다중선박 조우와 어선 세부분류를 보강하면 해역별 성능을 더 높일 수 있었다.

결과 해석 시 유의사항

예측시간이 길어질수록 불확실성이 커진다. 단기 경로는 우선관제에, 중·장기 경로는 위험방향을 살피는 보조정보로 구분해 활용해야 한다.

지역	샘플수	10분	20분	30분	40분	50분	60분	ADE	FDE
울산	204,935	0.64	1.24	2.06	2.99	4.02	5.10	2.19	5.10
인천	158,229	0.47	1.02	1.68	2.47	3.30	4.27	1.80	4.27
목포	302,145	0.90	1.27	1.96	2.75	3.65	4.62	2.02	4.62
부산	252,106	0.79	1.26	2.01	2.90	3.88	4.98	2.13	4.98
여수	94,199	0.59	1.09	1.75	2.53	3.39	4.32	1.83	4.32
통영	495,180	0.71	1.16	1.82	2.59	3.42	4.31	1.90	4.31
완도	454,262	0.66	0.96	1.37	1.85	2.39	2.98	1.38	2.98
제주	934,525	1.03	1.35	1.91	2.61	3.39	4.25	1.94	4.25
군산	241,569	0.47	0.99	1.61	2.30	3.08	3.88	1.69	3.88
포항	113,285	0.45	0.95	1.54	2.30	3.17	4.10	1.69	4.10
동해	25,032	0.25	0.58	0.93	1.29	1.66	2.05	0.94	2.05

표 4-4. 지역별 RMSE (km)

지역	샘플수	10분	20분	30분	40분	50분	60분	ADE	FDE
화물선	1,742,401	0.98	1.25	1.73	2.34	3.02	3.79	1.74	3.79
여객선	48,493	0.85	1.32	1.88	2.60	3.38	4.27	1.90	4.27
유조선	871,523	0.36	0.89	1.54	2.28	3.08	3.94	1.66	3.94
예부선	58,839	0.65	0.94	1.30	1.72	2.26	2.85	1.31	2.85
기타선	554,211	0.64	1.40	2.35	3.41	4.56	5.78	2.49	5.78

표 4-5. 선종별 RMSE (km)

4.9 모델 시각화

예측경로와 위험 신호를 익숙한 관제 지도 위에 표시

복잡한 분석결과가 현장에서 쓰려면 사용자가 다음 행동을 바로 결정할 수 있는 화면으로 바뀌어야 한다.

기존 관제 시스템과 유사한 화면 구성과 색상을 적용했다. 선박을 선택하면 현재 항적과 20·40·60분 예측경로를 함께 확인할 수 있었다. 해양기상, 충돌위험, 이상거동 플래그를 지도에서 함께 제공했다. 관제사는 여러 메뉴를 오가지 않고 위험 원인과 예상 이동을 확인할 수 있었다.

AI 모델, 데이터베이스, 시각화 시스템이 자동으로 연계되도록 구성했다. 화면은 분석 결과를 보여주는 데 그치지 않고 담당자가 우선순위를 정하고 후속조치를 선택하도록 구성했다.



그림 4-5. 권역별 분석 메인화면



그림 4-6. 예측항로 분석 화면

4.10 분석모델 정책 활용 성과

위험 선박을 먼저 찾고 관제 자원을 선제적으로 배치

해양경찰청 빅데이터플랫폼 내 메뉴를 신설하여 AI 모델의 결과를 확인할 수 있도록 하였다. 선박정보, 조류, 기상 등 연계 데이터를 빅데이터플랫폼을 통해 제공하여 다양한 안전정보를 한눈에 파악할 수 있다. 해당 플랫폼 내에는 분석을 통해 도출된 항로 예측 정보를 2분간격으로 제시하여 선박교통의 안정성 향상 및 효율적인 운항 경로를 도출할 수 있다. 향후에 선박 정보를 지속적으로 업데이트하여 제공 예정이다.

구체적으로 모델을 통해 예측경로와 실제 항적의 차이가 임계치를 넘으면 이상거동 플래그를 표시하여 관제사는 해당 선박을 우선 확인할 수 있다. 이를 통해 위험을 충돌 가능성이 높은 해역과 시간대를 사전에 파악하여 관제 집중도와 구조자원 배치 우선순위를 정할 수 있었다. 졸음 운전, 이상 거동 등 위험 선박 필터링으로 수백 척 중 핵심 선박만 집중 감시하여 관제 집중도를 향상하였다. 지속 가능한 순환 개선 구조 마련을 위해 관제사의 이상거동 코멘트와 충돌위험 평가를 다시 학습에 반영할 계획이다.





1-5

딥페이크 범죄 대응을 위한 AI 탐지 모델 개발



Part 1-5

딥페이크 범죄 대응을 위한 AI 탐지 모델 개발

국립과학수사연구원

진짜와 가짜 경계를 딥페이크 탐지 모델로 가려내다

분석 배경	분석 방법	분석 결과
딥페이크 범죄 확산으로 실제 수사환경에서 쓸 수 있는 탐지기술이 필요	Real·Fake 이미지와 영상을 정비하고 여러 탐지모델을 다양한 지표로 비교·고도화	검증된 다중모델 추론 화면을 마련하여 실제 딥페이크 탐지 수사에 활용

과제 한눈에 보기

생성형 AI 기술이 빠르게 발전하면서 실제와 구분하기 어려운 딥페이크 이미지와 영상이 범죄에 활용될 위험이 커졌다. 생성기술과 압축·편집 방식이 계속 달라져 하나의 탐지모델만으로 다양한 조작을 안정적으로 판별하기 어려웠다. 여러 모델의 결과를 같은 기준에서 비교하고 검토하는 감정지원체계가 필요했다.

이에 국립과학수사연구원은 다양한 Real·Fake 이미지와 영상의 품질, 중복, 워터마크와 인구통계 구성, 저화질과 열화조건을 포함한 학습·평가자료를 구축하였다. 구축된 데이터를 활용하여 여러 딥페이크 탐지모델을 동일한 데이터와 지표로 비교했으며, 다중모델의 결과와 분석이력을 함께 조회하는 체계를 마련했다.

분석 결과는 의뢰자료를 입력하면 모델별 탐지점수와 판단결과를 비교하는 화면으로 구현했다. 이를 통해 특정 모델의 판단에만 의존하지 않고 결과의 재현성과 검토 가능성을 높여 딥페이크 범죄 대응과 디지털 증거분석의 신뢰성을 강화할 기반을 마련했다.



💡 이렇게 바뀌었습니다!

개별 탐지기술 검토를 표준 데이터와 재현 가능한 다중모델 분석으로 개선

AS-IS

- 기존 모델만으로 빠르게 진화하는 생성기술 대응에 한계 존재
- 판독이 어려운 사례는 검증 불가로 처리
- 모델이 한정적이어서 타기관 확산이 어려움



TO-BE

- 여러 탐지모델을 동일 데이터와 지표로 비교하여 정확한 분석 결과 도출 가능
- 수동 감정 대비 분석 시간을 단축하고 판독이 어려웠던 사례를 체계적으로 관리 가능
- 다중모델 추론을 통해 타기관 확산 가능



5.1 현황 및 배경

빠르게 진화하는 딥페이크가 수사와 사회 신뢰를 위협

딥페이크 범죄가 사회문제로 떠오르면서 AI 기반 탐지·분석 기술을 빠르게 고도화할 필요가 커졌다. 새로운 생성기술이 계속 등장해 한 가지 모델만으로 다양한 조작유형과 화질에 안정적으로 대응하기 어려웠다.

딥페이크는 얼굴교체뿐 아니라 얼굴 재연, 음성·피부질감 조작과 전체 합성으로 범위가 넓어졌다. 조작유형마다 남는 흔적이 달라 하나의 특징만 보는 방식은 한계가 있었다. 수사자료에는 촬영기기와 해상도, 압축횟수, 화면크기가 제각각인 파일이 포함되어있기 때문에 연구환경의 깨끗한 자료보다 현장과 가까운 품질구성이 중요했다.

또한, 딥페이크 감정에서는 하나의 모델이 내놓은 답보다 서로 다른 탐지모델이 어떤 근거로 같은 판단 또는 다른 판단을 했는지 비교하는 과정도 신뢰도 향상을 위해 중요했다.

5.2 분석 필요성

높은 성능뿐 아니라 실제 환경에서 실행되는 모델 필요

고화질 Fake는 실제처럼 보이는 반면 기존 Real 데이터는 수량과 유형이 부족했다. 화질만으로 진짜와 가짜를 구분하는 편향을 줄여야 했다. 같은 평가자료와 지표를 적용해 모델별 장단점을 객관적으로 비교해야 했다. 한쪽 라벨만 잘 맞히는 모델도 걸러낼 필요가 있었다. 코드, 가중치, 라이브러리와 데이터 출처를 확인하고 같은 입력에서 같은 결과가 재현되는지 검증해야 했다.

모델이 고화질을 Fake의 표시로, 저화질을 Real의 표시로 외우면 새로운 파일에서 오탐이 커질 수 있었다. 품질과 라벨의 관계를 의도적으로 분리해야 했다. 내부망과 망분리, 접근통제 조건에서도 모델이 작동해야 했다. 정확도와 함께 모델크기, 구동시간, GPU 자원과 배포방식까지 확인할 필요가 있었다.

핵심 분석 질문

- ① 자료가 Real인지 Fake인지 모델별 판단은 일치하는가?
- ② 저화질·압축·편집 조건에서도 성능이 유지되는가?
- ③ 인구집단과 생성방식에 따른 편향이나 취약점은 없는가?

세부 분석은 이 질문에 답하면서 현장에서 우선 확인해야 할 대상을 구체화하는 방향으로 설계했다.

5.3 데이터 목록

Real과 Fake, 이미지와 영상을 균형 있게 구성

주요 데이터는 Real 이미지·영상과 Fake 이미지·영상이었다. 영상은 프레임을 추출해 이미지 기반 모델에 입력하도록 구성했다. 기존 데이터에 민간 구매데이터를 더해 Real 유형의 다양성을 보완했다. 인증 커버리지를 확대하고 저화질·열화 데이터도 포함해 품질 편향을 낮추었다. 공개 샘플은 개인정보 가능성을 검토하고 비식별화 기준을 적용했다.

기존 국립과학수사연구원에서 보유자료는 영상 509건과 이미지 691건이고, 민간 구매 데이터는 영상 835건과 이미지 14,665건으로 Real 이미지와 고화질 Fake를 보완했다. 영상자료는 6초 미만으로 길이를 맞추고 프레임 추출기준을 통일했다. 공개 가능성이 있는 샘플은 개인정보와 민감정보 포함 여부를 확인했다.

구분	Real	Fake	합계
기존 영상	112	397	509건
기존 이미지	300	391	691건
구매 영상	7	828	835건
구매 이미지	13,952	713	14,665건

표 5-1. 데이터 구성

분석 대상과 범위

다양한 Real·Fake 이미지와 영상을 품질·중복·워터마크·인구통계 기준으로 점검하고 저화질과 열화조건을 포함하여 데이터셋을 구성하였다.

5.4 EDA : 데이터 품질

중복·워터마크·형식 오류를 우선적으로 제거

생성 이미지의 워터마크를 육안으로 전수 점검했다. 이미지 간 픽셀값을 비교하고 육안 확인을 더해 중복자료를 제거했다. 답페이크 생성 이미지는 813건에서 802건으로 정리되었다. 픽셀 오차율 5% 이내의 중복 데이터가 남지 않았음을 확인했다. 라벨과 파일형식, 입력항목의 오류를 점검해 평가 결과가 데이터 오류에 흔들리지 않도록 했다.

워터마크는 이미지 아래 약 1/13 영역을 기준으로 탐지해 무손실 PNG로 저장했다. 위치가 다른 사례는 육안으로 확인해 수동으로 정리했다. 영상은 ffmpeg과 H.264 코덱으로 재인코딩했다. 30fps 기준 약 150프레임 분량으로 맞춰 파일 길이가 모델 결과에 주는 영향을 줄였다.

전처리명	방안	데이터
워터마크 제거	- 육안 검사로 워터마크가 존재하는 이미지 식별 - 식별된 이미지의 하단 부분(약 1/13 영역)에 위치한 워터마크를 제거 ※ 일부 위치가 다른 이미지에 대해 편집기를 이용하여 수동 절삭 - 워터마크 종류별 이미지 대비 상대 크기를 확인하여 최대 영역 크기 산출 - python PIL 라이브러리를 이용, 알고리즘 기반 워터마크 영역 절삭 후 저장	답페이크 이미지 데이터
중복 이미지 제거	- python PIL 라이브러리를 이용, 픽셀 일치 여부를 계산하여 일치하는 이미지를 1차 제거 - 이후 육안으로 확인 작업을 거쳐 중복에 가까운 이미지 2차 제거	답페이크 이미지 데이터
영상 길이 조정 및 재인코딩	- 대회 목적에 맞게 전체 영상 가운데 길이가 6초 이상인 영상들에 한해 길이를 5초 가깝게 절삭 (30fps 영상 기준 150fps 분량) - ffmpeg 소프트웨어 이용, 무손실 옵션 저장 (H.264 Codec)	답페이크 영상 데이터

표 5-2. 데이터 전처리 방안

5.5 EDA : 다양성과 편향

성별보다 인종과 화질의 다양성을 중점적으로 점검

데이터 전처리 방안과 더불어 구성된 이미지와 영상 데이터에서 인구통계학적 특성을 추출해 구성 비율을 확인했다. 성별 편차보다 인종 다양성이 모델 성능에 더 큰 영향을 줄 수 있다고 보았고, 고화질 Fake만 많으면 모델이 화질을 가짜의 단서로 잘못 학습할 수 있었다. 저화질과 열화 자료를 포함해 실제 수사환경과 가까운 조건을 만들었다. 음성은 제외하고 이미지와 영상 프레임을 중심으로 평가데이터를 구성했다.

5.6 빅데이터 모델링 : 탐지모델 설계

이미지와 영상 프레임의 조작 흔적을 다양한 방식으로 학습

분석 데이터를 토대로 실제 업무의 판단과정을 모델 구조에 옮겼다. 총 7개의 모델을 개발하였고, 성능을 비교하였다.

모델 구분	주요 모델 설명	모델 특징점
1	Golang 기반 전처리: Golang으로 병렬 이미지 처리/리사이징 파이프라인 구축 (CPU 효율 극대화) 데이터 증강: 회전, 리사이징을 최소화한 보수적 증강 전략 사용	고도화된 딥페이크 식별 가능 대량의 포렌식 분석 시 처리 시간 단축
2	패치 추출: 내부적으로 192x192 크기의 중요 패치 6개를 추출하여 정밀 분석 학습 전략: GenD(Generalization) 전략을 통해 Unseen Domain에 대한 대응력 강화	설명 가능성: 탐지 근거 확보 용이 신뢰도 높음 고해상도 입력 지원
3	비디오의 후반부(Back-half)에서 조작 패턴이 더 명확함을 이용하여 해당 구간 집중 샘플링 하이브리드 데이터셋: OpenFake, HydraFake 등을 결합하여 Face Swap과 Entire Synthesis 모두 대응	SOTA 성능 입증 정밀도 극대화
4	기반 기술: Meta AI의 대규모 Vision Transformer(ViT-G/14) 아키텍처 활용 (약 1.8B 파라미터) 학습 데이터: HydraFake, DF40_Test 외 자체 구축 데이터셋 활용 최신 생성 모델(FLUX, Midjourney, Kling, Veo 등)을 API로 직접 생성하여 데이터 다양성 확보 최적화: Full-finetuning 수행, FP16 Mixed Precision 및 Gradient Accumulation 적용으로 대규모 모델 학습 효율화	배경 간섭 배제 범용성: 다양한 입력 환경에서 일관된 성능 보장 (오디오 정보 미사용)

모델 구분	주요 모델 설명	모델 특징점
5	얼굴 부분이 fake인지 분류하는 모델보다는 이미지 전체가 fake인지 분류하는 모델로 ConvNeXt V2, FCMAE(Masked Autoencoder) 활용	단일 모델 기반으로 추론 속도가 매우 빠르며, 얼굴 검출이 어려운 상황에서도 이미지 전체 패턴 분석을 통해 탐지 가능함.
6	기반 기술: Community Forensics의 검증된 학습 파이프라인(Code & Weights)을 활용하여 안정적 성능 확보 단일 데이터셋 전략: OpenFake 데이터셋(약 400만 장) 단독 사용 데이터 증강 (Augmentation) RandAugment: 회전, 색상 변환 등의 기하학적/광학적 변환을 무작위로 강하게 적용 (N=2, M=10) RSA (Random State Augmentation): 학습 데이터의 상태를 무작위로 변환하여 모델의 강건성(Robustness) 극대화 최적화: AMP(Automatic Mixed Precision) fp16 적용, Cosine Annealing Scheduler 사용	높은 일반화 성능, 검증된 베이스라인: 최신 연구(CVPR 2025 등)에서 검증된 파이프라인을 그대로 적용
7	기반 기술: Microsoft의 Swin Transformer V2 아키텍처 및 계층적 윈도우 어텐션(Hierarchical Window Attention) 활용 데이터셋: OpenFake 데이터셋 ('현실형' 딥페이크 데이터) Stable Diffusion 3.5, Midjourney v6/v7 등 최신 생성 모델 포함 약 300만 장의 Real(LAION-400M)과 100만 장의 Synthetic 이미지로 구성 추론 최적화 (Inference Optimization): Logit Aggregation: 비디오 처리 시 15개 프레임을 추출하고, 상위 K개의 Logit 값을 평균 내어 최종 판단 (노이즈 제거 및 안정성 확보)	최신 트렌드 반영: 최신 Diffusion 기반의 전체 합성(Entire Synthesis) 이미지 탐지에 탁월

표 5-3. 모델 세부 내용

5.7 빅데이터 모델링 : 평가와 선정

Macro F1 score로 진짜와 가짜를 균형 있게 평가 진행

탐색 결과를 토대로 실제 업무의 판단과정을 모델 구조에 옮겼다. 성능뿐 아니라 현장에서 설명하고 운영할 수 있는지도 함께 고려했다.

주 평가지표는 Macro F1 score였다. Real과 Fake 각각의 F1을 같은 비중으로 평균해 한쪽만 잘 맞는 모델을 걸러냈다. 추가로 AUROC를 확인해 분류 임계값 전반의 구분력을 비교했다. 성능뿐 아니라 처리속도와 메모리 사용량도 함께 살폈다. 코드, 가중치와 실행환경을 동일하게 맞춘 뒤 반복 실행해 결과의 재현성을 확인했다.

F1은 Precision과 Recall을 함께 반영했다. Macro 방식은 Real과 Fake의 F1을 각각 계산한 뒤 동일한 비중으로 평균했다. AUROC는 임계값을 바꾸어도 두 라벨을 구분하는 능력이 유지되는지 보여주었다. 실제 적용에서는 오탐과 미탐의 비용을 고려해 임계값을 별도로 조정할 수 있었다.

모델별 학습자료와 구조가 달라 동일 파일에서도 Fake 확률이 다르게 나타날 수 있었다. 결과 차이는 오류가 아니라 추가 검토가 필요한 신호로 활용했다. 대규모 Vision Transformer와 Swin Transformer V2, 최신 포렌식 학습 파이프라인 등 서로 다른 구조가 포함되었다. 단일모델의 약점을 다른 모델이 보완하도록 했다.

모델 구분	모델설명	Macro F1 score	AUROC
1	SPAI 아키텍처, Albumentations 전처리, Center Crop/Resize 전략	0.969953	0.981194
2	SigLIP 백본, NPR(이웃 픽셀 관계) 모듈, 텍스처(엔트로피) 패치 추출	0.95236	0.969911
3	DINOv3 백본, LoRA(Low-Rank Adaptation) 파인튜닝	0.929077	0.953926
4	CLIP 비전 인코더, dlib 기반 얼굴 검출 및 크롭	0.899643	0.938411
5	ConvNeXt V2, FCMAE(Masked Autoencoder) 사전학습	0.909016	0.942172
6	Vision Transformer (ViT), 기본 패치(16x16) 처리	0.878091	0.916314
7	HuggingFace AutoModel (Swinv2ForImageClassification 기반), Haarcascade 얼굴 검출	0.878511	0.926657

표 5-4. 모델별 성능

5.8 모델 시각화

파일 업로드부터 모델별 확률과 이력까지 한 화면에 표출

국립과학수사연구원의 딥페이크 탐지 담당자는 이미지·영상 파일을 업로드하고 분석할 모델을 하나 이상 선택 가능하며, 전체 모델 선택과 얼굴 Crop 적용 여부도 설정할 수 있었다. 결과 화면은 모델별 Fake 확률을 진행막대와 백분율로 표시했다. 얼굴 Crop을 사용하면 감지된 얼굴의 경계상자도 보여주었다. 분석이력에서 최고 Fake 확률을 확인하고 상세화면으로 이동해 모델별 결과를 비교할 수 있었다.

각 모델별로 특징이 다르기 때문에 이를 비교하여 정확한 의사결정을 내릴 수 있도록 하였다.




그림 5-1. 파일별 모델 결과와 Fake 확률 상세 화면

5.9 분석모델 정책활용 성과

자동 선별로 감정관이 집중할 대상을 먼저 발굴하여 정보 제공

검증된 탐지모델을 내부 추론·판독 시스템에 탑재해 딥페이크 의심 미디어를 자동 선별하고 감정관의 판독을 지원하도록 했다.

국립과학수사연구원 내부적으로는 모델 탑재 이후 약 100종 이상의 딥페이크 사진, 영상,

음성에 대한 감정을 완료하였다. 사진, 영상, 음성이 혼합된 건에 대해서도 감정 업무 수행이 가능하였다. 추가로 지속적으로 발전하는 최신 생성형 AI에 대응하기 위한 고도화를 추진중이다.

외부적으로는 유사 업무를 하는 기관에 배포를 추진하고 있다. 중앙선거관리위원회에서 2026년 전국동시지방선거에서 딥페이크를 이용한 불법 콘텐츠 분석에 활용하였고, 약 7000회가량의 사진, 영상, 음성의 딥페이크 여부 판독을 진행하였다.

또한, 유관기관인 성평등가족부, 방송미디어통신위원회와 MOU를 체결하여 모델 확산을 추진하고있다.

이를 통해 국립과학수사연구원 디지털 증거 감정 체계를 고도화하였다. 이에 따라 자동으로 감정 처리 효율성의 향상하였고 감정 속도도 빨라져 공공 영역의 신뢰를 강화하고 신종 범죄 대응 역량을 높일 수 있었다.

뿐만 아니라, 감정 신뢰도 및 객관성을 제고하였다. 하나의 모델이 아닌 다양한 모델을 다중으로 비교하여 분석함으로써 신뢰성을 확보할 수 있었다. 모델을 지속적으로 고도화하고 데이터를 축적하며 분석과 정책이 함께 개선되는 순환구조를 만들 수 있었다.

국립과학수사연구원은 2026년 4월부터 2029년 12월까지 과학기술정보통신부가 주관하는 IITP 연구과제로 한국전자기술연구원과 공동으로 『복합 생성형 딥페이크 대응을 위한 능동탐지·심층분석 솔루션 개발』 사업을 수행하며, 이를 통해 딥페이크 탐지 모델을 고도화해 나갈 계획이다.



2025

공공부문 데이터 분석·활용

우수사례집

Part •

공공행정



2.1 국가보훈 상이등급 기준 정비 및 등급 판정 예측을 위한 데이터 분석

국가보훈부

2.2 부동산 거래 데이터를 활용한 이상거래 탐지 모델 개발

국토교통부


2.3 조달물품 유사 구매실례 추천 및 입찰 참여 가능성 분석 모델 개발

조달청



2-1

국가보훈 상이등급 기준 정비 및 등급 판정 예측을 위한 데이터 분석



Part 2-1

국가보훈 상이등급 기준 정비 및 등급 판정 예측을 위한 데이터 분석

국가보훈부

흡어진 판정기록을 있는 상이등급 예측 모델

분석 배경	분석 방법	분석 결과
추상적인 판정기준과 비정형 의료기록에 따른 담당자·심의위원 판정 편차 및 민원 발생	약 21만 건의 심의자료 구조화와 부위별 AutoGluon 모델을 활용한 예상등급·유사사례 분석	Tuning Tabular 모델과 대시보드 구축을 통한 판정 사전검증 및 의사결정 지원 기반 마련

과제 한눈에 보기

상이등급 판정은 국가유공자의 보상과 예우를 결정하는 중요한 절차다. 그러나 진단서와 심의의결서가 비정형 문서로 축적되고, 상병과 수술·신체부위의 표현도 서로 달라 과거의 유사 판정사례를 일관되게 찾아 비교하기 어려웠다. 담당자의 경험을 보완할 객관적인 검토체계가 필요했다.

이에 국가보훈부는 2012년 7월부터 2025년 9월까지 축적된 심의자료에 상병·수술·진료과목·신체부위·판정등급 정보를 연결했다. 용어 사용의 차이를 보정하고 부위별 등급예측 모델과 유사사례 검색기능을 구축해 예측결과와 과거 판정근거를 함께 확인하도록 했다.

분석 결과는 상이부위와 입력정보를 조회하고 예상등급과 유사 심의사례를 비교하는 화면으로 구현했다. 이를 통해 담당자 검토과정에서 손쉽게 유사사례 검토 등을 통해 검토 근거를 보강하고, 판정 편차와 재심·번복 가능성을 줄여 상이등급 판정의 일관성과 행정 신뢰도를 높일 기반을 마련했다.



2012년 이후 축적된 의료·심의자료의 표준화와 경계사례 분석 필요

💡 이렇게 바뀌었습니다!

개별 경험과 비정형 기록 중심의 판정을 데이터 기반 유사사례 검토로 보완

AS-IS	TO-BE
• 담당자별 검토자별 판정기준 해석 차이 • 진단서·심의의결서의 비정형 텍스트 관리 • 판정 편차 발생 원인의 체계적 비교 한계	• 상병·수술·신체부위·판정등급 정보의 표준화·연계 • 부위별 예상등급과 유사 판정사례의 통합 제공 • 판정반복·기준미달·소수등급에 대한 모델 성능 점검



심의자료를 연결해 판정의 일관성을 높인다



1.1 현황 및 배경

추상적 기준과 비정형 기록으로 담당자마다 다른 판정 편차 발생

국가보훈 상이등급 판정은 국가유공자의 보상과 예우를 결정하는 중요한 절차로, 동일한 상병과 장애 정도에는 일관된 기준이 적용되어야 한다. 그러나 일부 정신·신경 분야의 판정기준은 표현이 추상적이어서 같은 상병이라도 해석이 달라질 가능성이 있었다.

심의의결서와 진단서가 비정형 텍스트로 관리된 점도 일관된 판정을 어렵게 했다. 상병과 수술, 신체부위의 표현이 문서마다 달라 판정자료와 의료기록을 연결하기 어려웠고, 과거의 유사사례를 찾아 판정근거와 결과를 체계적으로 비교하는 데에도 많은 시간이 필요했다.

추상적 기준의 해석과 적용 차이는 판정결과와 편차뿐 아니라 재심과 민원, 행정 부담으로 이어질 수 있었다. 이에 2012년 이후 축적된 의료·심의자료를 표준화하고, 반복적으로 나타나는 판정패턴과 등급 간 경계사례를 분석할 필요가 있었다. 이를 바탕으로 담당자의 검토 일관성을 보완하고 판정의 일관성을 사전에 점검할 수 있는 데이터 기반 검토체계를 마련하고자 했다.



1.2 분석 필요성

판정을 대신하지 않으면서 일관성을 점검할 도구 필요

상이등급 판정의 일관성을 높이려면 동일한 상병과 신체부위에서 판정결과가 어떻게 달라지는지 먼저 살펴야 했다. 이에 등급분포와 판정결과를 비교해 기준이 일관되게 적용되었는지 확인하고, 판정 편차가 큰 상병과 경계등급을 찾아내고자 했다.

또한 상병과 수술, 진료과목, 심의내용 가운데 등급 결정에 영향을 주는 요인을 분석할 필요가 있었다. 이를 통해 담당자의 판단을 보완하는 객관적인 근거를 마련하고, 해석이 모호하거나 판정 차이가 반복되는 기준의 정비 방향을 구체화하고자 했다.

상이등급 자료는 등급별 사례 수의 차이가 큰 불균형 구조였다. 이 경우 전체 정확도가 높더라도 사례가 적은 희귀등급을 제대로 예측하지 못할 수 있다. 따라서 전체 성능뿐 아니라 등급별 정밀도와 재현율을 함께 평가하고, 소수등급의 예측 여부도 별도로 확인해야 했다.

분석결과는 하나의 예상등급만 제시하는 데 그치지 않고 등급별 예측확률과 과거 유사사례를 함께 제공하도록 설계했다. 담당자가 모델의 판단근거와 한계를 확인하고, 전문적 판단을 보완하는 참고자료로 활용할 수 있도록 하기 위해서였다.

핵심 분석 질문

- ① 동일 상병과 신체부위에서 판정결과가 일관적인가?
- ② 등급에 영향을 주는 상병·수술·진료정보는 무엇인가?
- ③ 예측과 실제 판정이 다를 때 참고할 유사사례는 무엇인가?

1.3 데이터 목록

심의결과와 상이처·상병·수술·진료과목 데이터를 연결

상이등급 판정자료를 일관된 기준으로 분석하려면 서로 다른 시점과 형식으로 축적된 의료·심의정보를 먼저 연결해야 했다. 분석기간은 2012년 7월부터 2025년 9월까지로 설정하고, 접수정보와 심의자료, 담당의 판정, 최종 심의결과를 사례별로 연계했다.

최종 상이등급을 기준으로 분석 대상을 눈, 귀·코·입, 흉터, 신경·정신, 흉복부, 체간, 팔·손, 다리·발과 복합장애로 구분했다. 상이처와 상병·수술코드, 진료과목, 심의유형과 심의내용은 동일한 기준으로 비교할 수 있도록 정규화했다. 개인정보는 비식별 처리하고 자유기술 형태의 문장은 분석 가능한 정보로 정제했다.

등급기준미달 사례는 특정 신체부위에 속하지 않아 부위별 모델에 그대로 연결하기 어려웠다. 이에 전체 기준미달 자료에서 각 부위별 데이터 규모의 5%에 해당하는 사례를 무작위로 추출해 학습자료에 포함했다. 이를 통해 부위별 등급과 기준미달을 함께 구분할 수 있는 분석자료를 구축했다.

분석 대상과 범위

2012년 7월~2025년 9월 심의자료를 눈, 신경·정신, 흉복부, 팔·손, 다리·발 등 상이부위별로 구분해 분석했다.

영역	주요 항목	활용
심의	접수·유형·연도·최종등급	현황과 학습정답
의료	상이처·상병·수술·진료과	등급 영향요인
판정과정	담당의·심의위 결과	반복·불일치 분석
텍스트	심의내용·진단기록	유사사례·멀티모달 비교

표 6-1. 주요 활용 데이터

1.4 EDA : 부위·등급·판정반복 데이터 분석

부위·등급별 불균형과 담당의·심의위 간 판정 차이 확인

부위별 등급예측 모델을 설계하기 위해 신체부위와 상이등급에 따른 판정분포를 살펴 보았다. 등급판정을 받은 103,705건 가운데 흉복부 장기 장애가 63,636건으로 과반을 차지했다. 신경·정신 장애는 17,601건, 눈 장애는 6,441건으로 뒤를 이었다. 부위별 자료량의 차이가 커 하나의 통합모델보다 각 부위의 특성을 반영한 모델이 필요했다.

상이등급별로는 7급이 43,495건으로 가장 많았고, 6급 2항이 26,472건으로 나타났다. 반면 1급 1항은 89건, 1급 2항은 85건에 불과했다. 이처럼 일부 등급에 사례가 집중되고 상위등급은 극소수인 불균형 구조에서는 전체 정확도만으로 모델을 평가하기 어려웠다. 소수등급의 재현율과 예측 여부를 별도로 확인할 필요가 있었다.

담당의 판정과 심의위 최종결과를 비교한 결과, 대부분의 신체부위에서 등급이 변경된 비율이 높게 나타났다. 따라서, 판정이 크게 달라진 원인을 별도로 살펴볼 필요가 있었다.

이러한 분석은 자료량이 충분한 부위와 소수사례가 많은 등급을 구분하고, 판정반복이 자주 발생하는 경계영역을 확인하는 근거가 되었다. 이를 바탕으로 부위별 모델을 구성하고 등급별 평가기준과 유사사례 분석방향을 설정했다.




그림 6-1. 담당의와 심의위 판정의 등급 이동 흐름.

1.5 빅데이터 모델링 : 부위별 학습

상이부위별로 서로 다른 등급구조 반영

상이등급은 신체부위마다 적용되는 등급체계와 자료량이 달랐다. 흉복부 장기, 신경·정신, 눈 등 주요 부위의 특성을 하나의 모델로 설명하기 어려워 부위별 독립모델을 설계했다. 이를 통해 각 부위에서 실제로 나타나는 등급구조와 판정특성을 개별적으로 학습하도록 했다.

등급기준미달 사례는 특정 신체부위에 속하지 않아 부위별 자료와 직접 연결하기 어려웠다. 이에 전체 기준미달 자료에서 각 부위 데이터 규모의 5%에 해당하는 사례를 무작위로 추출해 학습자료에 포함했다. 모델이 부위별 등급뿐 아니라 기준미달도 함께 구분할 수 있도록 구성한 것이다.

후보모델로는 정형데이터를 학습하는 Tabular Predictor와 심의내용 등 텍스트 정보까지 함께 활용하는 Multi Modal Predictor를 비교했다. 동일 사례가 학습·검증·테스트 자료에 중복되지 않도록 분리해 새로운 사례에서도 성능이 유지되는지 확인했다.

평가에서는 전체 정확도뿐 아니라 등급별 Recall과 미예측 클래스 여부를 함께 살폈다. 이는 사례가 적은 등급을 모델이 전혀 예측하지 못하는 문제를 확인하기 위한 것이다. 이후 부위별 모델의 성능과 오류를 비교해 안정성과 소수등급 예측력을 갖춘 최종모델을 선정했다.




그림 6-2. 상이부위별 학습자료와 예측모델 구성

1.6 빅데이터 모델링 : AutoGluon 비교

여러 후보를 자동으로 비교·조합해 최적 모델 탐색

부위별 학습자료에 가장 적합한 모델을 찾기 위해 AutoGluon을 활용했다. AutoGluon은 LightGBM, CatBoost, XGBoost, Random Forest와 신경망 등 여러 알고리즘을 자동으로 학습하고, 성능이 우수한 모델을 조합해 최종 예측값을 산출했다.

후보모델은 정형데이터를 활용한 Basic Tabular와 Tuning Tabular, 심의내용 등 텍스트를 함께 학습한 Basic Multi Modal과 Tuning Multi Modal의 네 가지로 구성했다. 기본 설정 모델과 파라미터를 조정한 모델을 비교해 튜닝에 따른 성능 변화를 확인하고, 텍스트 정보의 추가 활용이 예측력 향상에 기여하는지도 살펴보았다.

성능은 Weighted F1과 Accuracy뿐 아니라 등급별 Precision·Recall, Confusion Matrix와 ROC-AUC를 함께 활용해 평가했다. 전체 평균성능이 높더라도 사례가 적은 특정 등급을 한 번도 예측하지 못하면 실제 심의 지원에 활용하기 어렵기 때문이다.

이에 부위별·등급별 오류와 미예측 클래스를 별도로 확인해 소수등급의 실무 활용 가능성을 검증했다. 이러한 비교를 바탕으로 전체 성능과 등급별 안정성을 균형 있게 갖춘 최종모델을 선정했다.



그림 6-3. AutoGluon 후보 모델과 비교 구조.

1.7 모델 성능과 해석 : 모델 선정

전체 성능의 안정성과 소수등급 예측력 개선을 종합해 Tuning Tabular 선정

흉복부 장기, 신경·정신, 눈 등 세 주요 부위의 후보모델을 비교한 결과, Basic Tabular와 Tuning Tabular가 가장 높은 Weighted F1을 기록했다. 반면 텍스트 정보를 함께 학습한 Multi Modal 모델은 전반적으로 낮은 성능을 보였다. 정형화된 상병·수술·진료정보가 등급을 구분하는 데 더 안정적으로 기여한 것으로 나타났다.

Basic 모델과 Tuning 모델의 전체 성능 차이는 크지 않았다. 학습 과정에서 확인한 검증성능과 최종 테스트성능의 차이도 작아 뚜렷한 과적합은 나타나지 않았다. 두 모델 모두 새로운 사례에 비교적 안정적으로 적용할 수 있음을 확인했다.

다만 소수등급에서는 튜닝의 효과가 보다 분명하게 나타났다. 눈 장애의 일부 소수등급은 Tuning 모델에서 Recall과 F1이 크게 개선되었다. 신경·정신 부위에서도 중간 규모 등급과 기준미달 사례의 성능이 소폭 높아졌다.

이에 전체 성능의 안정성과 소수등급의 예측력 개선을 종합적으로 고려해 Tuning Tabular를 최종모델로 선정했다. 모델의 활용범위는 전체 평균점수만으로 판단하지 않고, 부위·등급별 데이터 규모와 Recall, 오분류 양상을 함께 확인하도록 했다.




그림 6-4. 상이부위별 Basic·Tuning 모델 성능 비교.

1.8 모델 성능과 해석 : 클래스별 검증

AUC와 혼동행렬로 등급별 강점과 오류 확인

흉복부 장기, 신경·정신, 눈 부위 모델의 등급별 판별력을 ROC 곡선과 혼동행렬로 확인했다. 대부분의 ROC 곡선이 좌측 상단에 가까운 형태를 보였으며, AUC는 대체로 0.9 이상으로 나타났다. 이는 주요 등급을 다른 등급과 비교적 안정적으로 구분했음을 의미한다.

혼동행렬에서는 실제등급과 예측등급이 일치하는 대각선 영역을 중심으로 결과가 집중되었다. 특히 눈 장애의 7급 등 사례가 충분한 주요 등급에서 높은 정확도를 확인했다. 반면 자료가 적은 일부 등급은 소수의 오분류만으로도 Recall과 ROC가 크게 달라졌다.

따라서 전체 평균성능만으로 모델을 평가하지 않고 등급별 자료량과 Precision·Recall, 오분류 양상을 함께 확인했다. 예측하지 못했거나 다른 등급과 반복적으로 혼동된 소수등급은 추가 데이터를 축적하고 모델을 재학습해야 할 우선대상으로 분류했다.

이러한 검증 결과는 모델을 모든 등급에 동일하게 적용하기보다, 부위와 등급별 신뢰 범위를 고려해 심의 참고자료로 활용하기 위한 기준이 되었다.

결과 해석 시 유의사항

예측등급은 최종 판정이 아니다. 클래스별 확률과 유사사례, 소수등급의 데이터 규모를 함께 확인하는 심의 참고정보로 활용해야 한다.




그림 6-5. 상이등급별 ROC 곡선과 판별성능

1.9 모델 시각화

입력정보·예측등급·유사사례를 한 흐름으로 제공

분석결과를 실제 심의업무에 활용할 수 있도록 입력부터 결과 확인까지 하나의 화면으로 구현했다. 사용자는 상이부위와 상병, 수술, 진료과목 등 사건정보를 입력한 뒤 등급예측을 요청할 수 있다.

대시보드는 예상등급과 등급별 예측확률을 제시하고, 실제 심의결과와 비교할 수 있도록 구성했다. 하나의 등급만 보여주는 대신 클래스별 확률을 함께 제공해 모델의 판단이 명확한 사례와 등급 간 경계에 있는 사례를 구분하도록 했다.

유사사례는 상병과 수술, 심의내용의 유사도를 기준으로 검색했다. 사용자는 과거 사례의 판정등급과 주요 근거를 함께 확인해 현재 사례와 비교할 수 있다. 복수 상병을 입력할 때의 처리방식과 유사도 표현을 명확히 하고, 예측결과와 근거와 한계도 화면에 안내했다.

대시보드는 모델이 판정을 대신하는 시스템이 아니라 담당자의 검토를 지원하는 도구로 설계했다. 예상등급과 실제 검토등급이 다르거나 예측확률이 비슷한 사례는 유사사례와 입력자료를 다시 확인하는 사전점검 대상으로 활용할 수 있다.



그림 6-6. 등급예측과 유사사례를 제공한 대시보드

1.10 정책 활용 및 기대효과

예측등급과 유사사례를 활용해 판정의 일관성과 심의업무의 효율성 향상

상이등급 예측모델과 유사사례 분석결과는 담당자의 검토를 지원하는 사전점검 자료로 활용할 수 있다. 예측등급과 실제 검토등급의 차이가 크거나 등급별 확률이 비슷한 사례는 입력자료와 과거 유사사례를 다시 확인하도록 안내한다. 동일 상병의 등급분포와 담당·심의위 간 판정변경 사례를 비교하면 기준이 추상적이거나 판정 편차가 큰 영역도 찾을 수 있다.

반복적으로 예측하지 못하거나 다른 등급과 혼동되는 사례는 판정기준 문구와 입력항목, 담당자 교육자료의 개선대상으로 활용할 수 있다. 특히 자료가 부족한 소수등급과 경계사례를 지속적으로 축적하면 기준정비와 모델 고도화를 함께 추진할 수 있다. 다만 모델의 결과는 최종 판정을 대신하지 않으며, 담당자 검토과정에서 판단을 보완하는 참고정보로 사용해야 한다.

예상등급과 유사 판정사례를 한 화면에서 제공하면 심의자료를 검색하고 사례를 비교하는 시간을 줄일 수 있다. 또한, 등급분포와 과거 판정근거를 참고함으로써 기준 적용의 일관성과 판정결과에 대한 신뢰도를 높일 것으로 기대된다.


향후에는 심의자료 검색시간, 등록처리기간과 현장 활용실적을 성과지표로 관리할 필요가 있다. 심의결과와 예측오류를 다시 학습자료로 축적하면 분석결과가 기준정보로 이어지고, 개선된 기준과 데이터가 다시 모델에 반영되는 순환구조를 마련할 수 있다.





2-2

부동산 거래 데이터를 활용한 이상거래 탐지 모델 개발



Part 2-2

부동산 거래 데이터를 활용한 이상거래 탐지 모델 개발

국토교통부

숨은 불법 부동산 거래의 빈틈을 찾는 이상거래 탐지 모델

분석 배경	분석 방법	분석 결과
전문가가 전세사기·편법증여 의심거래를 직접 추출하는 기존 분석 방식으로 인해 3일 이상의 분석 시간 소요	매매·임대차·소유권·자금조달 자료를 연계한 개별·조직형 전세사기 및 편법증여 의심거래 탐지모델 개발	XGBoost·K-Core 네트워크 분석과 GIS 기반 시각화를 통한 조사물건 자동 선별 및 분석시간 약 2시간으로 단축

과제 한눈에 보기

부동산 이상거래는 가격과 계약조건, 자금조달 방식, 거래 당사자의 관계 등 여러 정황을 함께 살펴야 한다. 거래량이 많은 상황에서 담당자가 개별 자료를 일일이 확인하는 방식만으로는 조사 필요성이 높은 거래를 빠르게 선별하기 어려웠다. 시장 변화와 지역별 특성을 반영한 데이터 기반 탐지체계가 필요했다.

이에 국토교통부는 부동산 거래·가격·계약정보에 거래 당사자 특성과 지역·시장지표를 결합했다. 정상거래와 다른 패턴을 학습해 거래별 이상 가능성을 산출하고, 가격 편차와 계약 특성 등 판단에 영향을 준 주요 요인을 함께 제시하는 이상거래 탐지모델을 구축했다.

분석 결과는 지역과 기간별 위험거래를 조회하고 개별 거래의 위험도와 의심요인을 확인하는 화면으로 구현했다. 이를 통해 담당자의 수작업 선별을 보완하고 조사 필요성이 높은 거래를 우선 검토해 불법·편법 거래 조사와 부동산시장 질서 확립을 지원하는 기반을 마련했다.



이렇게 바뀌었습니다!

임대인 목록을 수동 연계하던 조사를 거래·관계망 자동탐지로 전환

AS-IS

- 전문가가 작성한 기준목록과 매매계약의 수작업 연계
- 개별 임대인 중심 분석에 따른 조직적 거래관계 탐지의 한계
- 조사후보 추출에 3일 이상 소요

TO-BE

- 매매·전세계약을 결합한 거래단위 학습
- K-Core 분석을 활용한 임대인 집단의 핵심 연결관계 탐지
- 자동추출과 GIS 조회를 통한 약 2시간 이내 조사후보 선별



3일 이상
→
약 2시간



핵심 성과

이상거래 가능성과 주요 의심요인을 제시하는 탐지모델 구축



정책 가치

불법·편법 거래 조사 효율화 및 부동산시장 질서 확립 지원

2.1 현황 및 배경

흘어진 거래 정보를 연결해 전세사기와 편법증여 의심거래 탐색 필요

부동산 이상거래는 개별 거래의 가격만으로 판단하기 어려웠다. 거래 당사자의 특성과 소유권 변동, 매매·임대차 관계를 함께 살펴야 전세사기나 편법증여로 의심되는 거래의 연결구조를 파악할 수 있었다.

국도교통부는 2024년 구축한 AI 기반 이상거래 모니터링 시스템을 상시적인 의사결정 지원도구로 활용하기 위해 탐지모델을 추가로 개발했다. 기존 분석은 악성임대인으로 의심되는 대상을 먼저 선별한 뒤 관련 매매계약을 수작업으로 연결하는 방식이었다. 이 때문에 실제 조사대상 계약을 확정하려면 별도의 확인과 정리가 필요했다.

방대한 거래 자료를 사람이 직접 분석하는 데에는 시간과 인력의 제약도 컸다. 전문가가 기준목록을 작성하고 조사후보를 추출하는 데 3일 이상이 걸렸으며, 개별 임대인을 중심으로 살펴보는 방식만으로는 여러 사람이 얹힌 조직적 거래관계를 찾아내기 어려웠다.

이에 매매와 임대차 정보를 거래단위로 결합한 학습자료를 구축하고, 조직적 전세사기의 연결망과 편법증여 의심신호를 자동으로 탐지할 필요가 있었다. 탐지결과를 GIS 화면에서 조회할 수 있도록 구현해 조사 필요성이 높은 거래를 신속하게 선별하는 분석체계를 마련하고자 했다.



2.2 분석 필요성

개별 거래와 조직적 관계, 증여 의심을 서로 다른 방식으로 확인 필요

부동산 이상거래를 효과적으로 선별하려면 거래유형에 따라 서로 다른 위험신호를 분석해야 했다. 개별 전세사기와 조직적 전세사기, 편법증여는 거래구조와 확인 가능한 정보가 달라 유형별 분석기준을 구체적으로 설정할 필요가 있었다.

개별 전세사기는 임대인과 임대차 계약의 특성과 부동산거래신고 및 임대차신고의 유형 등을 종합해 위험도를 분류하도록 했다. 반면 조직적 전세사기는 한 건의 거래보다 특정 단지나 지역에서 여러 임대인이 물건과 거래관계를 공유하는 연결구조를 파악하는데 중점을 두었다.

편법증여는 가족관계와 금융·기업정보를 충분히 확보하기 어려운 한계가 있었다. 매도인과 매수인의 특성 및 자금조달계획서 등 활용 가능한 정보를 보조 지표로 사용하되, 해당 조건만으로 편법증여를 단정하지 않고 조사후보를 선별하는 참고근거로 활용하도록 했다.

이를 통해 제한된 조사인력으로 우선 확인해야 할 거래와 거래집단을 신속하게 선별하는 분석체계를 구축하고자 했다.

핵심 분석 질문

- ① 개별 매매계약에서 전세사기 의심신호가 나타나는가?
- ② 여러 임대인이 반복적으로 연결된 조직적 관계망이 있는가?
- ③ 자금조달과 거래특성에 편법증여 의심패턴이 있는가?

2.3 데이터 목록

부동산거래신고·임대차신고·자금조달 자료를 연결

이상거래의 연결구조를 파악하려면 여러 업무시스템에 분산된 매매·임대차 정보를 동일한 거래와 당사자를 기준으로 정확하게 연결해야 했다.

분석에는 매매물건과 임대물건, 매매거래자와 임대인 자료를 활용했다. 부동산거래신고, 임대차신고, 전월세 확정일자 등 다양한 자료를 연계하여 거래단위의 학습자료를 구축했다.

부동산거래신고, 임대차신고, 전월세 확정일자 자료를 결합하고 임대인별 주택 거래를 분석하여 거래관계망을 구성했다. 편법증여 의심거래 분석에는 자금조달계획서와 기존 의심거래 분류정보를 활용해 반영했다.

전세사기 의심거래로 기선별된 이력은 전세사기 의심거래를 구분하는 학습정답이자 모델의 탐지성능을 확인하는 검증기준으로 활용했다. 이렇게 정비한 자료는 개별 거래의 위험도 분류와 조직적 연결관계 탐지, 편법증여 조사후보 선별의 기반이 되었다.

분석 대상과 범위

부동산거래신고·임대차신고·자금조달 자료를 연결해 개별 전세사기, 조직적 전세사기, 편법증여를 구분해 분석했다.

2.4 EDA : 개별 전세사기

사고가 집중되는 주택유형과 지역을 분석

전세사기 의심거래의 특성을 파악하기 위해 주택유형과 지역, 임대인의 거래이력을 중심으로 데이터 분포를 살펴보았다.

전체 가구에서는 아파트가 가장 큰 비중을 차지했지만, 전세사기 의심거래로 선별된 건은 다세대주택에 집중되어 있었다. 지역별로는 수도권 비중이 높았으며, 연도·시도·시군구 단위로 세분화한 결과에서도 유사한 공간적 집중 양상이 나타났다. 이를 통해 주택유형과 지역정보를 주요 위험요인으로 검토할 필요성을 확인했다.

임대인의 임대차신고 정보와 임대차신고 및 부동산거래신고를 결합한 자료가 높은 상관관계를 보였다. 반면 주택의 가격과 다른 변수는 상관성이 상대적으로 낮았다.

이러한 탐색 결과를 바탕으로 주요 변수를 선정했다. 상관성이 높은 변수는 정보의 중복 여부를 점검해 모델의 안정성과 해석 가능성을 확보하도록 했다.



그림 7-1. 개별 전세사기 상관관계 분석

2.5 EDA : 조직적 거래와 편법증여

매매·임대 연결과 시기별 자금패턴을 확인

조직적 전세사기는 개별 계약만으로 파악하기 어려워, 당사자 간 연결관계와 거래금액·시기의 분포를 함께 살펴보았다.

먼저, 임대인의 부동산거래신고 정보를 분석하여 보유주택 수로 집단을 구분했다. 이후 단지와 시군구, 읍면동 단위에서 동일한 물건이나 거래관계로 연결된 임대인을 그래프로 구성했다. K-Core 값이 높을수록 여러 임대인과 반복적으로 연결된 핵심집단에 가까운 것으로 해석했다. 전세사기 의심거래로 선별된 건은 구분하여 표시해 직접 연결된 주변 임대인과 잠재적인 연관집단을 함께 확인했다

편법증여 의심거래는 증여금액과 주택유형, 거래시기를 중심으로 분포를 분석했다. 증여금액도 구간별로 구분하여 분포도를 확인하였으며, 주택유형은 아파트가 대부분을 차지했다.

이러한 탐색 결과를 바탕으로 조직적 전세사기 분석에는 임대인별 보유주택 수와 지역별 연결구조, K-Core 값을 주요 지표로 활용했다. 편법증여 분석에는 거래금액과 주택유형, 계약시기 등 반복적으로 나타난 거래특성을 주요 변수로 반영했다.

K-Core로 찾는 핵심 거래집단

K-Core는 연결이 적은 대상을 차례로 제외하면서 서로 반복적으로 연결된 핵심집단을 찾는 네트워크 분석기법이다. K값이 높을수록 여러 임대인·주택과 촘촘하게 연결된 집단에 가깝다는 의미다. 다만 연결이 많다는 사실만으로 전세사기를 의미하지는 않으며, 조사 필요성이 높은 관계망을 선별하는 보조지표로 활용했다.

2.6 빅데이터 모델링 : 개별 전제사기

불균형 거래자료에서 중요한 변수를 단계적으로 선별

개별 전제사기 탐지모델은 조사대상 계약을 자동으로 선별하면서도 담당자가 결과를 이해하고 실제 업무에 활용할 수 있도록 설계했다.

먼저 전체 후보변수를 대상으로 Optuna 기반의 하이퍼파라미터 최적화를 수행했다. XGBoost의 변수중요도를 활용해 1차·2차 핵심변수를 선별한 뒤, 변수조합별로 파라미터를 다시 조정해 탐지성능을 비교했다. 데이터는 학습 70%, 검증 15%, 테스트 15%로 분리해 새로운 거래에서도 성능이 유지되는지 확인했다.

초기 모델링에서는 XGBoost와 GBM, GLM, Stacked Ensemble을 비교했다. 분석자료에서 의심거래의 비율이 낮다는 점과 앙상블 모델의 복잡한 설명구조, 운영비용을 함께 고려했다. 그 결과 성능과 해석 가능성, 시스템 적용의 효율성을 균형 있게 확보할 수 있는 XGBoost를 최종 모델로 선정했다.

최종 모델은 부동산거래신고 자료에 임대차신고 자료를 거래단위로 직접 결합하도록 구성했다. 이에 따라 악성임대인 의심목록과 부동산거래신고자료를 다시 수작업으로 연결하지 않고도 조사 필요성이 높은 계약을 자동으로 출력할 수 있도록 했다. 이후 별도의 테스트 자료를 활용해 의심거래 탐지성능과 현장 적용 가능성을 검증했다.




그림 7-2. 학습용 데이터 구축과 후보모델 개발 과정

2.7 빅데이터 모델링 : 조직적 전세사기·편법증여 탐지

관계망과 분류모델을 이상유형에 맞게 분리

조직적 전세사기와 편법증여는 의심거래가 형성되는 방식이 서로 달라, 유형별 특성에 맞는 분석모델을 각각 구축했다.

조직적 전세사기 분석에서는 부동산거래신고자료와 임대차신고 자료를 결합한 정보에 따라 정비하고, 단지·시군구·읍면동 단위의 임대인 관계망을 구성했다. 이후 사회연결망분석(SNA)을 적용해 K-Core 집단과 핵심노드, 주변 하위노드를 식별하고 결과를 저장했다. 임대인의 보유주택 수의 기준을 달리 적용하면서도 핵심 연결관계가 지속적으로 나타나는지 확인해 일시적인 연결과 반복적으로 형성된 관계망을 구분했다.

편법증여 분석에는 상시조사 규칙과 자금조달계획서에서 활용 가능한 특성을 결합했다. 이를 XGBoost 모델에 적용해 거래별 이상 가능성을 산출하고, 조사 필요성이 높은 거래를 우선 선별하도록 했다.

각 모델은 데이터 정제와 변수 생성을 담당하는 전처리기, 이상 가능성을 산출하는 탐지모델, 조사후보를 정리하는 후처리기로 구분해 패키징했다. 또한 월별 배치작업과 GIS 기반 지도서비스에 연계해 새로운 거래자료가 들어오면 동일한 절차로 분석결과를 생성하도록 구성했다. 이후 별도의 검증자료를 활용해 유형별 탐지성과 운영 안정성을 확인했다.

2.8 모델 성능과 해석 : 이상거래 탐지성능 검증

재현율을 중심으로 성능을 평가하고 영향요인과 활용범위를 함께 확인

부동산 이상거래 데이터는 정상거래가 대부분이고 전세사기 의심거래 건은 소수인 불균형 구조를 보였다. 이러한 자료에서는 전체 정확도가 높더라도 실제 조사대상을 충분히 찾아내지 못할 수 있어, 전세사기 의심거래 건을 얼마나 놓치지 않고 탐지하는지를 나타내는 재현율(Recall)과 PR-AUC를 핵심 평가지표로 설정했다.

업무 적용을 위한 목표 재현율은 80%, 최소 기준은 60%로 정했다. 검증성능이 최소 기준에 미치지 못한 모델은 운영환경에 배포하지 않고 기존 모델로 자동 전환되도록 롤백 절차를 설계했다. 이를 통해 새로운 자료가 추가되거나 모델을 재학습하더라도 일정 수준 이상의 탐지성능을 유지하도록 했다.

특성 중요도 분석에서는 임대인의 거래이력이 의심거래 선별에 미친 영향을 확인했다. 담당자가 모델의 판단근거를 파악하고 조사 우선순위를 정할 수 있도록 거래별 위험도와 주요 영향요인을 함께 제시했다.

다만 모델의 탐지결과는 불법행위를 확정하는 판정이 아니라 추가 확인이 필요한 조사항보를 의미했다. 최종 판단은 담당자가 실제 거래내역과 등기·건축물대장 등 공부 정보를 함께 검토하도록 해 모델의 결과가 신중하게 활용되도록 했다.




그림 7-3. 모델 성능 변수별 검증

2.9 모델 시각화

지역별 이상거래 현황부터 조사대상 검토까지 한 화면으로 연결

이상거래 탐지결과가 실제 업무에 활용되려면 담당자가 지역별 위험현황을 직관적으로 파악하고, 조사 필요성이 높은 대상을 단계적으로 좁혀갈 수 있어야 했다. 이에 여러 유형의 이상거래 현황을 통합적으로 조회할 수 있는 GIS 기반 서비스를 구축했다.

담당자는 분석유형과 지역, 물건 조건 등을 설정해 이상거래 분포와 조사후보를 확인할 수 있었다. 지도에는 지역별 위험 수준과 거래 분포를 이해하기 쉬운 형태로 나타냈으며, 조회 범위와 조건에 따라 관련 현황이 함께 갱신되도록 구성했다. 이를 통해 넓은 지역의 전반적인 위험 흐름을 살핀 뒤 관심 지역과 조사대상을 순차적으로 검토할 수 있었다.

분석결과는 지도뿐 아니라 주요 현황과 조사에 필요한 정보가 유기적으로 이어지도록 구현했다. 담당자는 지역별 이상거래 현황을 파악하고 우선 확인할 대상을 선정한 후, 필요한 거래정보를 연속된 화면에서 살펴볼 수 있었다.

이처럼 GIS 기반 서비스는 이상거래 현황 파악부터 조사대상 선정과 개별 거래 확인까지 하나의 업무 흐름으로 연결했다. 복잡한 분석결과를 실무자가 쉽게 이해하고 활용할 수 있는 조사 지원체계를 마련했다.



2.10 분석모델 정책 활용 성과

자동 탐지와 관계망 분석으로 조사시간을 줄이고 이상거래 대응의 정확성 향상

분석결과는 기존 이상거래 조사절차와 RTMS, GIS 기반 지도서비스에 연계해 담당자의 의사결정을 지원하도록 했다. 개별 전세사기 추출규칙과 조직적 관계망 분석결과를 교차검토해 조사 우선순위를 정하고, 편법증여는 특정 요건에 해당하는 거래를 중심으로 주요 의심특성과 모델결과를 함께 확인하도록 했다.

전처리부터 모델 분석, 조사후보 생성까지의 과정을 자동화하고 월별로 의심거래 이력을 갱신하도록 구성했다. 이를 통해 전문가가 기준목록을 작성하고 조사후보를 추출하는데 3일 이상 걸리던 업무를 약 2시간으로 97% 단축하며 한정된 인력과 예산범위 내에서 업무의 효율성을 극대화하였다. 이를 통해 시장에 적시대응이 가능하도록 하였다. 또한, 모델을 활용한 관계기관 통보율을 12.3%p향상하여 정확도를 제고하였다.

개별 전세사기와 조직적 전세사기, 편법증여를 유형별로 탐지하고 GIS 화면에서 거래와 관계망을 교차확인함으로써 조사대상 선별의 정확성과 일관성을 높일 수 있다. 분기별 전세사기 기획조사와 연도별 직거래 기획조사를 실시하여 AI 활용 조사의 정례화를 위해 추진하였다.

또한 한정된 조사인력을 위험도가 높은 거래와 핵심 관계망에 우선 배치해 불법·편법 거래에 신속하게 대응하고 국민의 임차보증금 보호를 강화할 수 있다.

향후에는 조사결과와 실제 전세사기 의심거래, 편법증여 의심거래 이력을 다시 학습자료로 축적해야 한다. 이를 바탕으로 추출규칙과 모델의 재현율을 지속적으로 검증하고 재학습(환류)시켜 업무시간과 조사 적중률, 현장 활용실적을 성과지표로 관리하며 개선할 예정이다.





2-3

조달물품 유사 구매실례 추천 및 입찰 참여 가능성 분석 모델 개발



Part 2-3

조달물품 유사 구매실례 추천 및 입찰 참여 가능성 분석 모델 개발

조달청

수많은 규격서 속 답을 SI 유사구매 추천으로 찾다

분석 배경	분석 방법	분석 결과
225조원 규모의 공공조달에서 수작업 유사구매실례 검색과 업체 탐색에 많은 행정력 소요	LLM으로 규격서를 요약하고 임베딩 검색과 계약·투찰 이력 분석으로 공고와 업체를 추천	유사공고 검색시간 50% 단축과 상위 5개 업체 내 실제 계약업체 포함률 80% 이상 달성 목표

과제 한눈에 보기

공공기관이 물품을 구매하려면 규격과 기능이 비슷한 과거 계약가격을 조사하고 견적을 제출할 수 있는 업체를 찾아야 한다. 그러나 나라장터에 축적된 규격서의 형식과 표현이 다양해 담당자가 문서를 일일이 열어 비교하는 데 많은 시간이 들었다. 입찰 경험이 낮은 업체에 반복적으로 견적을 요청하는 비율도 줄일 필요가 있었다.

이에 조달청은 HWP·PDF·엑셀 등 다양한 규격서를 텍스트로 변환하고, LLM으로 주요 물품과 규격·성능 정보를 추출했다. 문서의 의미를 벡터로 바꿔 유사한 과거 공고와 가격분포를 검색하고, 계약·투찰 이력과 업종정보를 활용해 입찰 참여 가능성이 높은 업체를 추천하는 모델을 구축했다.

분석 결과는 신규 공고의 핵심규격과 유사 구매사례, 계약가격과 추천업체를 한 화면에서 확인하도록 구현했다. 이를 통해 유사구매실례 검색과 견적요청 시간을 줄이고 입찰 참여 가능성이 높은 업체를 발굴해 공공조달의 경쟁성과 구매 효율성을 높일 기반을 마련했다.





그림 8-1. 공고 상세, 유사공고와 추천업체를 함께 표출한 화면

💡 이렇게 바뀌었습니다!

계약서류를 일일이 열람하던 유사구매실례 검색을 AI 검색·추천 중심으로 개선

AS-IS	TO-BE
• 많은 양의 계약서류를 매번 확인하여 업무 처리 필요 • 담당자가 공고와 계약서류를 직접 찾아 비교하여 많은 시간 소요 • 입찰과 무관한 업체에도 견적을 요청하는 경우 존재	• LLM이 규칙서 핵심정보를 추출·요약하여 한번에 볼 수 있도록 구성 • 의미가 비슷한 과거 공고와 가격분포를 즉시 추천하여 담당자가 확인하도록 조치 • 계약·투찰 경험이 높은 업체를 우선적으로 제시



3.1 현황 및 배경

확대된 공공조달에서 정확한 유사구매실례 검색이 중요

공공서비스의 변화는 현장에서 반복되는 불편과 위험을 정확히 바라보는 데서 시작된다. 공공조달의 유사구매실례 검색은 수많은 문서 가운데 지금 구매하려는 물품과 실제로 닮은 사례를 찾는 일에서 시작된다.

2024년 공공조달 규모는 약 225조원으로 전년보다 17조원, 8.2% 증가했다. 물품 공고 규모는 정부예산 656.6조원의 약 37%에 해당했다. 발주기관은 거래실례가격, 유사규격 가격과 견적가를 종합해 예정가격을 정했다. 그러나 담당자가 계약서류를 하나씩 열람하면서 조사시간이 길어졌다.

현실가격과 조사결과의 차이는 업체 불만과 예산 비효율로 이어질 수 있었다. 입찰과 무관한 업체의 견적을 받거나 단일 응찰로 수의계약에 전환되는 문제도 있었다. 따라서 신뢰할 수 있는 유사 구매실례와 참여 가능 업체를 함께 찾는 범정부 유사구매실례 검색기반이 필요했다.




그림 8-2. 공공조달의 규모




그림 8-3. 공공 사업 비중

3.2 분석 필요성

규격이 비슷한 과거 공고와 실제 참여업체를 함께 탐색 필요

같은 물품도 공고 제목과 규격서 표현이 달라 단순 키워드 검색만으로 유사사례를 찾기 어려웠다. 유사구매실례 검색에는 계약금액뿐 아니라 모델명, 성능, 구성, 설치방법과 품질조건 등 규격의 의미가 함께 반영되어야 했다.

견적요청 업체는 과거 같은 물품을 계약하거나 투찰한 경험, 최근 활동과 제재 여부를 종합한 선정이 필요하였다. 종합적인 분석결과는 조달데이터허브에서 실시간 조회하도록 30초 이내 응답과 내부 GPU 자원 활용을 고려해야 했다.

핵심 분석 질문

- ① 규격서에서 핵심 물품과 성능을 어떻게 추출할 것인가?
- ② 의미가 비슷한 과거 구매사례와 가격은 무엇인가?
- ③ 실제 입찰에 참여할 가능성이 높은 업체는 어디인가?

세부 분석은 이 질문에 답하면서 현장에서 우선 확인해야 할 대상을 구체화하는 방향으로 설계했다.




그림 8-4. 현재 업무 수행 방식의 문제점

3.3 데이터 목록

공고문서와 계약·투찰·업체 이력을 하나의 추천기반으로 구성

좋은 분석은 많은 자료를 모으는 것보다 서로 다른 자료를 같은 기준으로 정확히 연결하는 데서 출발한다.

2024~2025년 나라장터 물품공고, 입찰·투찰·계약내역과 업체정보를 수집했다. MAS 쇼핑물의 특정 세부품목 자료도 활용대상에 포함했다. 규격서·내역서·시방서에서 모델명, 규격, 기능, 성능, 구성, 기술요구와 설치방법을 추출했다.

업체 추천에는 세부품명번호별 계약·투찰 횟수, 최근 3·6·12개월 활동, 시장점유율과 부정당업자 제재정보를 사용했다. 공고 요약과 원문 연결정보는 벡터DB에 저장해 검색 결과에서 원자료를 확인할 수 있도록 했다.

분석 대상과 범위

나라장터의 HWP·PDF·엑셀 규격서와 공고·계약·투찰 이력을 텍스트와 의미벡터로 변환해 유사사례 및 업체 추천에 활용했다.

정비된 데이터는 이후 탐색과 모델링, 결과 해석을 같은 기준으로 이어주는 공통 기반이 되었다.

데이터 영역	주요 내용	활용
공고문서	규격서·내역서·시방서	물품 규격 추출·요약
입찰·계약	공고, 투찰, 계약, 가격	유사 구매실례와 가격분포
업체	기본정보, 이력, 제재	참여 가능 업체 추천
기준정보	세부품명번호, MAS 품목	검색·추천 범위 통일

표 8-1. 주요 활용 데이터

3.4 EDA : 공고와 첨부문서

6만 9천여 공고의 문서형식과 첨부패턴을 분석

모델을 만들기 전에는 데이터의 분포와 차이, 결측과 이상값을 충분히 살펴야 한다. 이 탐색과정은 모델의 방향을 정하는 기초가 된다.

2025년 전체 입찰공고는 69,863건이었다. 중앙조달은 8,138건, 자체조달은 61,725건으로 자체조달이 88.3%를 차지했다. 중앙조달의 78.3%는 공고당 첨부파일이 1~2개이고, 자체조달의 약 80%는 1~3개로 나타났다.

첨부파일은 HWP 121,113개, XLSX 20,615개, PDF 17,655개, HWPX 12,968개 순이었다. 상위 6개 형식이 99.4%를 차지했다. HWP와 XLSX 비중만 75.4%여서 한글문서와 표에서 텍스트를 안정적으로 추출하는 전처리가 중요했다.




그림 8-5. 조달방식별 입찰공고 비율('25년)



그림 8-6. 입찰공고차수 및 조달방식별 입찰공고 비율('25년)




그림 8-7. 중앙조달의 첨부파일 개수별 입찰공고 수('25년)



그림 8-8. 자체조달의 첨부파일 개수별 입찰공고 수('25년)

3.5 EDA : 참여업체와 전문성

과거 경험과 최근 활동이 실제 참여를 설명

전체 입찰공고 중 83.85%에는 1~20개 업체가 참여했다. 참여업체가 1개뿐인 공고가 54.1%로 가장 많았다. 2025년 참여업체 27,650개 가운데 70.94%는 연간 참여가 1~16건이었다. 1회 참여업체는 6,406개로 23.17%였다.

계약 기준으로 볼 때, 물품별 단순 평균 1위 업체 점유율은 약 22% 수준이나, 계약건수를 고려한 가중평균 점유율은 약 8%로 크게 낮아짐을 확인할 수 있다. 이는 총 계약건수가 작은 소규모 시장에서는 특정 물품 업체의 점유율이 높을 수 있으나, 계약건수가 많은 대규모 시장에서는 물품 경쟁이 치열하다고 볼 수 있다.




그림 8-9. 공고당 입찰에 참여한 업체 수



그림 8-10. 업체당 참여한 입찰공고 수



그림 8-11. 물품별 계약·투찰 시장 집중도 분석 결과(점유율이 높다=경쟁이 약하다=특정업체의 독점이 있다)

3.6 빅데이터 모델링 : 규격서 요약

여러 형식의 문서에서 물품과 핵심규격을 단계적으로 추출

탐색 결과를 토대로 실제 업무의 판단과정을 모델 구조에 옮겼다. 성능뿐 아니라 현장에서 설명하고 운영할 수 있는지도 함께 고려했다.

압축파일 내부까지 순회해 첨부목록을 만들고 파일명 키워드로 공고별 규격서 1개를 우선 판별했다. HWP·HWPX·XLSX·DOCX·PDF·PPTX내의 텍스트와 표를 추출했다. 대용량 문서는 토큰 기준으로 나누고 Map-Reduce 방식으로 주요 물품 식별, 규격 추출, 구조화 요약을 수행했다. 최종 요약은 텍스트파일과 벡터DB에 저장했다. 문서가 길어도 입력 한도를 넘지 않도록 호출 수와 토큰 예산을 관리했다.

이렇게 구축한 모델은 다음 단계에서 실제 자료를 얼마나 안정적으로 설명하는지 성능과 오류를 함께 검증했다.



그림 8-12. 규격서 식별·텍스트 추출·요약 과정

3.7 빅데이터 모델링 : 유사물품 구매 실례 추천

의미검색과 이력기반 순위화를 각각 설계

탐색 결과를 토대로 실제 업무의 판단과정을 모델 구조에 옮겼다. 성능뿐 아니라 현장에서 설명하고 운영할 수 있는지도 함께 고려했다. 공고 요약에 임베딩하고 Anchor·Positive·Negative 학습쌍으로 유사문서와 비유사문서의 거리를 학습했다. KURE-V1, BGE-M3-KO 등 한국어 임베딩 후보를 Triplet Loss로 추가 학습했다. BM25 키워드 검색과 Vector Search를 결합하는 하이브리드 구조도 마련했다.

업체 추천은 물품별 계약·투찰 이력, 점유율과 최근성을 변수로 Logistic Regression 기반 순위를 산출했다. 제재업체는 추천에서 제외하고 결과를 API로 제공해 검색화면과 견적요청 기능에 연결했다.



그림 8-13. 정답 여부에 따른 유사도 분포

정답인 경우(label=1)의 유사도는 대부분 유사도 0.7 이상 구간에서 밀집하는 것으로 보이고, 정답인 아닌 경우(label=0) 유사도는 대체로 0.55 이하에 분포하며, 0.7 이상 구간에서는 해당 건수가 급격히 감소함을 확인하였다.

유사도 0.6 미만 구간은 대부분 오답 영역에 해당하고, 유사도 0.7 이상 구간은 정답인 경우의 비율이 높은 영역이므로, 0.6~0.7 구간은 정답과 오답이 혼재하는 경계 구간으로 볼 수 있다.

3.8 모델 성능과 해석 : 입찰참여 예상업체 분석

상위 5개 검색과 첫 정답 순위로 모델을 비교

모델의 가치는 하나의 높은 점수보다 어떤 사례를 잘 찾고 어디에서 틀리는지를 분명히 설명할 때 드러난다.

HitRate@K는 하나의 공고에 대해 실제 계약한 업체를 투찰한 업체(후보군)내에서 Top-K 검색결과로 정확히 식별할 수 있는지를 중심으로 평가하였고, MRR은 실 계약 업체가 얼마나 상위순위에 위치하는지를 반영하는 지표로, 얼마나 빠르게 상위결과로 빠르게 탐색할 수 있는지를 평가하는 보조지표로 활용하였다.

전반적으로 각 공고별 상위 5개 추천 업체 중 실제 계약 업체가 포함된 경우가 평균 80% 이상 수준(Hitrate@5)이며, 이때 업체의 평균 순위 또한 1~3위권(MRR)에 위치하였다. 실제 계약이 발생한 업체에 대해 모델이 부여한 평균 계약확률은 약 0.73~0.75수준으로 예측 확신도 측면에서 비교적 높은 일관성을 유지하고 있었다.

즉, 각 연도별 성능지표들의 분포를 분석했을 때 지표별 표준편차가 0.03~0.05수준으로 전반적으로 낮아 월별 변동성이 크지 않은 것으로 보이는 반면 '24년 대비 '25년에는 표준편차가 소폭 감소하여 예측 성능이 다소 향상되는 경향을 보였다.

학습데이터 범위	평가기간	성능지표	평균	최소값	최대값	표준차
'21.01~'23.12 (이후 '24년 추가 학습)	'24.01~12 (검증)	HitRate@5	0.837	0.797	0.930	0.034
		MRR	0.758	0.707	0.892	0.046
		Confidence Score	0.732	0.686	0.796	0.025
'21.01 ~ '24.12 (이후 '25년 추가 학습)	'25.01~12 (평가)	HitRate@5	0.829	0.793	0.903	0.027
		MRR	0.747	0.709	0.872	0.043
		Confidence Score	0.746	0.700	0.800	0.024

표 8-2. 연도별 모델 성능지표 비교 분석표

3.10 분석모델 정책 활용 성과

예정가격 조사와 견적요청의 근거를 빠르게 확보하여 유사구매실례 검색 시간을 줄이고 입찰기회 확장

분석은 모델 구축에서 끝나지 않았다. 기존 업무절차와 시스템, 담당자의 판단과 연결될 때 비로소 정책도구가 된다.

담당자는 개별 공고를 반복 검색하지 않고 규격이 비슷한 과거 구매의 계약금액과 투찰분포를 바로 확인할 수 있다. 입찰 가능성이 높은 업체에 견적을 요청해 무관한 업체 접촉을 줄이고 실효성 있는 견적 확보 가능성을 높였다.

장기적으로는 구매실례 검색 기능을 조달청 내부망 바깥에서도 이용할 수 있도록 하여 조달청 외 타 수요기관 계약담당자도 시스템을 활용할 수 있도록 시스템 개선을 추진하였다. 이를 통한 사전작업으로 국정원 보안성 검토를 완료하였다. 또한, 조달청 물품 계약담당자가 업무 수행 중 시스템을 실제 활용하며 2,000건이 넘는 모델 활용 실적을 확보하였다. 업무 담당자는 적절한 구매실례를 빠르게 검색하여 계약에 소모되는 시간을 대폭 줄이고 가격의 공정성은 확보할 수 있었다.



2025

공공부문 데이터 분석·활용

우수사례집

Part •

재난 안전



- 3.1 상수도 유량 데이터를 활용한 화재진압 소화전 사용 최적 활용 지원 모델 개발
대구광역시
- 3.2 야생멧돼지 아프리카돼지열병(ASF) 위험도 관리 및 방역 의사결정 지원 모델 개발
국립야생동물질병관리원
- 3.3 교량 잠재위험지수 산정 및 선제적 안전관리 지원 모델 개발
국토안전관리원



3-1

상수도 유량 데이터를 활용한 화재진압 소화전 사용 최적 활용 지원 모델 개발



Part 3-1

상수도 유량 데이터를 활용한 화재진압 소화전 사용 최적 활용 지원 모델 개발

대구광역시

불길 앞 골든 타임을 지키는 소화전 최적 추천 모델

분석 배경	분석 방법	분석 결과
거리·관경 중심의 기존 소화전 추천방식으로 인한 대형화재 시 실제 여유유량 파악의 한계	소화전·상수관로·도로·급수구역별 유량정보 결합과 거리·관경·접 근성·공급가능 유량 기반 우선순위 산정	유량 임계치·예상 사용시간·예비 소화전의 지도 제공을 통한 화재 진압 의사결정 지원 및 진압시간 30% 단축 목표

과제 한눈에 보기

화재 현장에서는 가까운 소화전을 신속히 확보하는 것이 중요하다. 그러나 거리만으로 소화전을 선택하면 실제 공급 가능한 물의 양이나 상수관로의 상태, 소방차의 도로 접근성을 충분히 고려하기 어렵다. 여러 소방차가 같은 구역의 소화전을 동시에 사용할 때 발생할 수 있는 용수 부족도 사전에 판단할 필요가 있었다.

이에 대구광역시는 달서구·중구·서구의 소화전과 상수관로, 관경, 5분 단위 유량, 도로폭 데이터를 결합했다. 화재지점과의 거리뿐 아니라 여유유량과 예상 사용시간, 소방차 접근 가능성을 함께 평가 하고, 사용량이 임계치를 넘을 경우 다른 급수구역의 예비 소화전을 추천하는 모델을 구축했다.

분석 결과는 화재 위치를 기준으로 사용 가능한 소화전과 공급능력, 추천순위를 지도에서 확인하는 화면으로 구현했다. 이를 통해 현장 지휘관이 용수 상황을 빠르게 판단하고 특정 구역의 집중사용을 줄여 안정적인 화재진압 용수를 확보할 수 있는 기반을 마련했다.

거리 너머 공급능력까지 살피는 소화전 최적 추천



거리·관경·유량·접근성을 결합한 안정적인 화재진압 용수 확보

💡 이렇게 바뀌었습니다!

거리·환경 중심 추천에 실제 공급가능 유량과 도로 접근성을 더했다.

AS-IS	TO-BE
• 화재 지점과의 근접성을 중심으로 한 소화전 추천 • 화재별 공급 여력 및 사용 가능 시간에 대한 정보 부족 • 동일 소구역 내 소화전 집중 사용에 따른 급수 불균형 가능성	• 거리·환경·도로 폭·공급 유량을 종합 반영한 소화전 추천 체계 구축 • 소화전 사용 개수별 잔여 유량 및 예상 사용 가능 시간 산정 • 공급 임계치 초과 시 인접 구역 예비 소화전 연계 추천



1.1 현황 및 배경

대형화재에서는 소화전의 위치만큼 공급 가능한 물의 양이 중요

화재진압의 골든타임을 확보하려면 현장에서 가까운 소화전뿐 아니라 충분한 용수를 안정적으로 공급할 수 있는 소화전을 신속하게 찾아야 했다.

대구광역시에서는 화재지점을 기준으로 주 소화전 4개와 보조 소화전 4개를 자동으로 제시하는 ‘대구형 소화전 스마트시스템’을 운영했다. 기존 시스템은 화재지점과의 거리, 상수관로의 관경을 고려하고 동일한 소구역에서는 최대 2개의 소화전을 추천했다. 이를 통해 현장 주변의 소화전 위치와 기본정보를 빠르게 확인할 수 있었다.

그러나 기존 추천화면만으로는 소화전별 여유유량과 예상 사용시간을 파악하기 어려웠다. 대형화재로 여러 소방차가 같은 급수구역의 소화전을 동시에 사용하면 유량이 급격히 감소해 용수 공급이 불안정해질 수 있었다. 주거·상업시설의 밀집도와 급수구역의 규모에 따라 공급 여건이 달라지는 점도 충분히 반영되지 않았다.

이에 기존 시스템의 신속한 위치 추천 기능을 유지하면서 실제 공급가능 유량과 도로 접근성까지 함께 고려할 필요가 있었다. 소화전별 잔여유량과 예상 사용시간을 계산하고, 특정 구역의 사용량이 임계치를 넘으면 다른 급수구역의 예비 소화전을 제시하는 방향으로 추천체계를 고도화했다.




그림 9-1. 기존 대구형 소화전 스마트 시스템 소화전 추천 화면

1.2 분석 필요성

소화전의 위치·관로·도로·유량을 동시에 판단 필요

소화전 추천체계를 고도화하려면 현장에서 실제로 사용할 수 있는 용수량과 접근성을 함께 판단해야 했다. 화재지점과의 거리만으로는 안정적인 용수 공급을 보장하기 어려웠기 때문이다.

소화전의 공급능력은 연결된 상수관로의 관경과 급수구역별 유량에 영향을 받았다. 화재지점과 가까운 소화전이라도 관경이 작거나 같은 구역의 사용량이 많으면 충분한 물을 공급하기 어려웠다. 화재 규모와 예상 진압시간도 필요한 용수량을 결정하는 주요 조건이었다. 또한 소방차의 진입 가능성을 고려해 전문가 의견에 따라 도로폭 4m 이상을 접근성 기준으로 적용했다.

실시간 유량자료를 직접 연계하기 어려운 점도 고려해야 했다. 이에 2022년 1월부터 2025년 8월까지 축적된 과거 유량자료를 분석해 급수구역별 평상시 사용패턴과 유량 임계치를 산정했다. 이를 바탕으로 소화전별 잔여유량과 예상 사용시간을 계산하고, 임계치에 도달하기 전에 다른 급수구역의 예비 소화전을 추천하도록 분석 방향을 설정했다.

핵심 분석 질문

- ① 화재지점에서 접근 가능한 소화전은 어디인가?
- ② 동시에 사용할 때 충분한 여유유량이 남는가?
- ③ 공급 한계를 넘으면 어느 급수구역의 소화전을 대안으로 활용할 수 있는가?

1.3 데이터 목록

소방·상수도·도로·화재자료를 소구역 기준으로 연결

소화전의 실제 공급능력을 평가하려면 여러 기관에 분산된 소방·상수도·도로정보를 동일한 위치와 급수구역을 기준으로 연결해야 했다.

먼저 소방본부의 소화전 정보와 상수도사업본부의 소방시설 자료를 연계해 소화전의 위치와 설치유형, 연결 관로의 관경을 정리했다. 여기에 상수관로와 소·중급수구역 경계, 5분 단위 유량자료를 결합해 소화전별 공급 여건을 파악했다. 급수체계는 하나의 중구역이 2~5개의 소구역으로 구성되는 구조를 반영했다.

현장 접근성을 판단하기 위해 도로망과 도로폭, 소방차 진입불가·곤란지역 자료도 함께 활용했다. 이를 바탕으로 도로폭 4m 이상인 구간을 소방차가 진입할 수 있는 도로로 구분했다.

또한, 2022년부터 2025년까지 달서구·중구·서구에서 발생한 대형화재 사례를 분석했다. 화재 발생부터 완진까지 걸린 시간과 동원된 소방차량, 실제 사용한 소화전을 확인해 화재 규모에 따른 용수 수요와 소화전 활용 특성을 분석했다. 이렇게 정비한 데이터는 소화전별 잔여유량과 예상 사용시간, 예비 소화전의 우선순위를 산정하는 기초자료로 활용했다.

분석 대상과 범위

대구 달서구·중구·서구의 소화전과 상수관로, 5분 단위 유량, 관경과 도로폭을 같은 공간기준으로 연결했다.

데이터 영역	주요 내용	활용
소방시설	소화전 위치·유형·관경	추천 후보와 관로 연결
상수도	관로·구역·5분 유량	임계치·잔여유량
도로	도로폭·진입곤란지역	소방차 접근성
화재사례	발생·완진·사용 소화전	출수량·사용시간 검증

표 9-1. 주요 활용 데이터

1.4 EDA : 소화전과 상수관로

지역별 소화전과 상수관로의 분포를 확인하고 누락된 환경정보를 보완

소화전 추천모델을 설계하기 위해 앞서 지역별 소방시설과 상수관로의 분포를 살피고, 분석에 필요한 환경정보의 품질을 점검했다.

서구에는 소방시설 730개가 있었으며, 이 가운데 지상식 소화전이 57%를 차지했다. 달서구에는 1,241개, 중구에는 598개의 소방시설이 있었고 지하식 소화전의 비율은 각각 56%와 58%로 나타났다. 세 지역 모두 관경 100~200mm 구간의 비중이 높았다. 특히 서구는 150mm가 33%로 가장 많았고, 100mm 31%, 200mm 20% 순이었다.

상수관로는 서구 8,820개, 달서구 11,465개, 중구 4,915개로 집계되었다. 세 지역 모두 전체 관로의 약 99%가 배수관으로 구성되어 있어, 소화전의 공급능력을 평가할 때 배수관의 위치와 관경을 주요 기준으로 활용할 필요가 있었다.

데이터 품질을 점검한 결과, 대구 전역 소방시설 7,344건 중 3,274건은 환경정보가 누락되어 있었다. 이는 전체의 44.58%에 해당하는 규모였다. 누락값은 해당 시설과 가장 가까운 상수도 시설의 정보나 주변 관로의 관경을 활용해 보완했다. 이러한 탐색 결과는 지역별 시설 특성을 반영하고, 관경과 급수구역 정보를 모델의 주요 변수로 선정하는 근거가 되었다.




그림 9-2. 지역별 소방시설·상수관로 현황과 환경정보

1.5 EDA : 접근곤란과 화재사례

좁은 도로와 지역별 유량여건이 소화전 활용을 제한

소화전이 충분한 용수를 공급하더라도 소방차가 현장에 접근하기 어렵다면 실제 활용에는 한계가 있었다. 이에 도로 여건과 대형화재 당시의 소화전 사용사례를 함께 분석해 추천모델에 반영할 조건을 구체화했다.

소방차 진입불가·곤란지역은 총 18곳으로, 일반도로 15곳과 공동주택 3곳으로 구분되었다. 지역별로는 서구 9곳, 중구 5곳, 달서구 4곳 순이었다. 주요 원인은 좁은 도로와 상습적인 불법주차였다. 도로폭 4m 미만 구간의 비율은 서구 67%, 달서구 22%, 중구 4%로 나타나 지역별 접근 여건에도 뚜렷한 차이가 있었다.

대형·초대형 화재는 총 11건을 분석했다. 서구에서 5건, 달서구에서 4건, 중구에서 2건이 발생했다. 각 사례의 화재진압 과정에서 동일한 급수구역의 소화전만 사용한 경우와 굽은 송수관 인근 또는 다른 급수구역의 소화전을 함께 사용한 경우를 비교했다. 이를 통해 소화전의 거리뿐 아니라 도로 접근성, 관경, 급수구역의 분산 여부가 안정적인 용수 확보를 좌우한다는 점을 확인했다.

이러한 분석 결과를 바탕으로 도로폭 4m 이상을 소방차 접근기준으로 적용하고, 동일 구역의 집중사용을 줄일 수 있도록 다른 급수구역의 예비 소화전을 함께 추천하는 방향으로 모델을 설계했다.




그림 9-3. 대구광역시 서구의 4m 미만 도로폭 분포

1.6 빅데이터 모델링 : 통합 평가

거리·환경·공간·유량 네 요소를 점수로 통합

현장에서 활용할 소화전을 선정하려면 화재지점과의 거리뿐 아니라 용수 공급능력과 소방차 접근성까지 하나의 기준으로 평가해야 했다. 이에 현장 지휘관이 소화전의 우선순위를 신속하게 판단할 수 있도록 주요 조건을 점수화했다.

평가지표는 화재지점과 소화전 사이의 거리, 연결 관로의 관경, 도로폭을 포함한 공간조건, 급수구역별 유량 사용률로 구성했다. 측정 단위와 범위가 서로 다른 지표는 0~1 사이의 값으로 정규화했다. 이후 데이터의 분포와 변별력을 반영하는 엔트로피 기법을 적용해 지표별 초기 가중치를 산정했다.

분석 결과, 거리와 환경이 전체 중요도의 93%를 차지하며 소화전 추천순위에 가장 큰 영향을 미쳤다. 다만 실제 현장에서는 공급 가능한 유량과 소방차의 진입 여건도 중요하므로 유량점수와 공간점수를 함께 반영했다. 최종적으로 지표별 가중합 점수가 높은 소화전을 우선 추천하되, 동일한 급수구역에 사용이 집중되지 않도록 추천규칙을 적용했다.

이를 통해 화재지점과 가깝고 공급능력이 충분하며 소방차가 접근하기 쉬운 소화전을 우선 선정하는 모델을 구축했다. 이후 실제 화재사례를 적용해 추천결과와 용수 공급의 안정성을 검증했다.

1.7 빅데이터 모델링 : 유량 임계치

평시 사용량과 여유생산량으로 구역별 최대공급량을 계산

소화전을 안정적으로 사용하려면 현재 사용량뿐 아니라 급수구역별로 추가 공급할 수 있는 여유유량을 함께 파악해야 했다. 이에 과거 유량자료와 정수장의 생산 여력을 활용해 구역별 최대 공급량과 추천 기준이 되는 임계치를 산정했다.

먼저 5분 단위 유량자료를 활용해 급수구역별 하루 평균 사용량을 계산하고, 이를 다시 연도별 평균으로 집계했다. 실제 공급유량은 사용유량을 유수율로 나누어 산출했다. 유수율은 2023년 94.7%, 2024년 92.6%, 2025년 추정치 90.5%를 각각 적용해 연도별 공급 여건의 변화를 반영했다.

정수장의 여유생산량도 급수구역별 공급능력에 포함했다. 생활용수 여유생산량 56만 6천㎥/일은 인구 비율에 따라, 공업용수 13만 6천㎥/일은 공업지역 면적 비율에 따라 각 구역에 배분했다. 이후 평균 공급유량과 배분된 여유생산량을 합산해 구역별 최대 공급유량을 산정했다.

최종 추천모델에는 최신 공급 여건을 반영한 2025년 유량 임계치를 적용했다. 이를 통해 소화전 사용에 따른 잔여유량과 예상 사용시간을 계산하고, 임계치에 가까워지면 다른 급수구역의 예비 소화전을 추천할 수 있도록 설계했다.

연도	유수율	전체 일자료	임계치 초과
2023	94.7%	44,165건	270건(약 0.6%)
2024	92.6%	44,286건	180건(약 0.4%)
2025	90.5%(추정)	29,282건	247건(약 0.8%)

표 9-2. 연도별 유량 임계치 자료정보

1.8 모델 성능과 해석 : 임계치 검증

초과비율 0.4~0.8%의 안정적인 상한선 마련

안정한 최대 공급유량을 추천기준으로 활용하려면 실제 유량자료와 비교해 기준의 안정성을 확인해야 했다. 이에 급수구역별 실제 공급유량이 계산된 최대 공급유량을 초과한 날의 비율을 연도별로 분석했다.

분석 결과, 최대 공급유량 초과비율은 2023년 약 0.6%, 2024년 0.4%, 2025년 0.8%로 나타났다. 세 연도 모두 초과 사례가 1% 미만에 머물러, 안정값을 구역별 공급능력의 상한 기준으로 활용할 수 있음을 확인했다.

유량 사용률에 따라 추천점수도 차등 적용했다. 사용률이 38% 미만인 구역은 공급 여유가 충분한 1분위 구간으로 분류했다. 38% 이상 100% 미만 구간은 사용률에 따라 점수를 정규화했으며, 최대 공급유량을 초과한 구역은 추천점수를 0으로 처리했다.

임계치를 초과한 급수구역은 기본 추천대상에서 제외했다. 이후 가용유량이 남아 있는 다른 급수구역을 다시 탐색해 예비 소화전으로 제시하도록 했다. 이를 통해 특정 구역의 집중사용을 방지하고, 화재진압에 필요한 용수를 안정적으로 확보할 수 있도록 추천기준을 마련했다.



그림 9-4. 화재지점과 주변 소화전의 구역별 비교

1.9 모델 성능과 해석 : 예상 사용시간

화재 때 늘어난 유량으로 소화전 1개당 출수량을 추정

소화전 추천결과를 현장에서 활용하려면 공급 가능 여부 뿐만 아니라 현재 유량으로 얼마나 오랫동안 진압을 이어갈 수 있는지도 제시해야 했다. 이에 실제 화재사례의 유량 변화를 활용해 소화전별 출수량과 예상 사용시간을 산정했다.

먼저 화재 발생부터 완전까지의 구역별 유량을 추출하고, 동일 시간대의 평상시 평균 유량을 차감했다. 평소보다 증가한 유량은 화재진압에 투입된 용수량으로 보았다. 진압시간 중 유량이 가장 높았던 시점은 가장 많은 소화전이 동시에 사용된 시점으로 가정했다.

해당 시점의 최대 투입유량을 실제 사용한 소화전 수로 나누어 소화전 1개당 5분 단위 출수량을 계산했다. 이어 급수구역의 잔여유량을 선택한 소화전 수와 단위 출수량으로 나누어 예상 사용시간을 산출했다.

사용할 소화전의 개수가 달라지면 예상 사용시간도 자동으로 다시 계산하도록 구성했다. 이를 통해 현장 지휘관이 동시 사용 가능한 소화전 수와 용수 지속시간을 비교하고, 필요하면 다른 급수구역의 예비 소화전을 선택할 수 있도록 했다.

결과 해석 시 유의사항

추천순위는 거리만으로 결정되지 않는다. 여유유량과 예상 사용시간, 도로 접근성, 동시 사용에 따른 공급부담을 함께 살펴야 한다.



그림 9-5. 화재지점 주변 주·보조 소화전 추천 사례

1.10 모델 시각화

추천순위와 접근도로, 잔여시간을 지도에서 확인 후 대처

분석결과를 화재현장에서 활용하려면 공급능력이 충분한 소화전과 접근 가능한 경로를 한 화면에서 신속하게 확인할 수 있어야 했다. 이에 현장 지휘관이 용수 상황을 파악하고 다음 조치를 결정할 수 있도록 지도 기반 추천화면을 구현했다.

소화전 추천 기능을 실행하면 화재별 주·보조 소화전과 해당 급수구역의 정보를 별도 화면에 제시했다. 소방차가 원활하게 진입할 수 있는 도로는 초록색으로, 도로폭이 좁아 접근이 어려운 구간은 빨간색으로 표시해 이동 가능 여부를 직관적으로 구분했다.

특정 급수구역을 선택하면 해당 위치가 확대되고, 사용 가능한 소화전 수와 잔여유량, 소화전별 출수량, 예상 사용시간을 함께 보여주었다. 선택한 소화전 수가 달라지면 잔여유량과 사용시간도 다시 계산해 현장의 용수 운용계획을 비교할 수 있도록 했다.

예비 소화전 기능을 활성화하면 유량 임계치를 초과한 급수구역을 추천대상에서 제외하고, 가용유량이 남아 있는 다른 구역을 재탐색했다. 새롭게 추가된 후보는 기존 추천 소화전과 구분해 표시했다. 이를 통해 담당자가 특정 구역의 집중사용을 피하고, 공급능력과 도로 접근성을 고려해 주·예비 소화전의 활용 우선순위를 결정할 수 있도록 했다.




그림 9-6. 구역별 유량과 추천 소화전을 제공한 시각화 화면

1.11 분석모델 정책활용 성과

유량 기반 소화전 추천으로 화재진압의 신속성과 소방용수 운용효율 상승

분석결과는 대구광역시 달서구, 중구, 서구 지역을 대상으로 우선 적용하였다. 특정 구역 소화전 집중 사용 방지 및 안정적 용수 확보의 기반을 구축하였다. 또한, 지도 기반 추천 화면을 연동하여 현장 지휘관 및 상황실의 직관적 의사결정을 지원하였다. 화재 초기에는 공급능력과 접근성을 고려해 주·보조 소화전을 선택하고, 잔여유량과 예상 사용시간이 감소하면 다른 급수구역의 예비 소화전을 선제적으로 배치할 수 있도록 하였다. 향후에는 대구광역시 전역에 확산할 계획도 수립하고 있다.

공급능력이 충분하고 소방차가 접근할 수 있는 소화전을 우선 추천하면 특정 구역에 사용이 집중되는 것을 방지하고 소방인력의 운용효율을 높일 수 있다. 또한 잔여유량과 예상 사용시간을 사전에 파악해 용수 부족에 따른 진압 지연을 줄일 수 있다. 이를 바탕으로 화재진압 시간은 기존 대비 평균 30%, 연간 화재 재산피해액은 10% 줄이는 것을 정책목표로 설정했다.


향후에는 실제 화재현장의 소화전 사용량과 진압결과를 지속적으로 추적하고, 도입 전후의 소화전 선정시간과 진압시간, 예비 소화전 활용실적을 성과지표로 관리할 필요가 있다. 이러한 운영성과를 바탕으로 추천기준을 고도화한다면 대구광역시 뿐만 아니라 다른 지방자치단체의 스마트 소방용수 관리체계로도 확산할 수 있다.





3-2

야생멧돼지 아프리카돼지열병(ASF) 위험도 관리 및 방역 의사결정 지원 모델 개발



Part 3-2

야생멧돼지 아프리카돼지열병(ASF) 위험도 관리 및 방역 의사결정 지원 모델 개발

국립야생동물질병관리원

야생멧돼지 ASF확산 예측 모델을 통한 선제 방역 강화

분석 배경	분석 방법	분석 결과
2019년 이후 야생멧돼지 ASF 장기화 및 기존 감염지역 인접지의 반복 발생	내부 시료 정보와 외부데이터10종을 결합한 발생예측, 환경위험도, 확산 및 부정행위 탐지 통합 분석	CatBoost 발생예측과 공간격차 분석을 통한 고위험지역 우선 조사대상 선별 및 선제 방역 지원

과제 한눈에 보기

아프리카돼지열병은 야생멧돼지를 통해 넓은 지역으로 확산될 수 있어 발생지역을 확인한 후 대응하는 방식만으로는 피해를 줄이는 데 한계가 있었다. 따라서, 행정구역 단위의 일괄 방역에서 벗어나 다음 발생 가능성이 높은 지역과 우선 조사대상을 미리 찾는 선제적 방역체계가 필요했다.

이에 국립야생동물질병관리원은 ASF 시료 정보와 기상·지형·토지피복·도로 등 외부자료 10종을 결합했다. 시군구별 발생확률과 1km² 격자별 환경위험을 예측하고, 확산경로 및 우선 조사대상을 함께 판단하는 분석모델을 구축했다.

분석 결과는 발생·확산 위험지역을 한 지도에서 확인하는 방역 의사결정 화면으로 구현했다. 이를 통해 방역인력과 수색·소독 자원을 위험지역에 우선 배치하고, 발생 이전의 예찰과 차단방역을 강화할 수 있는 기반을 마련했다.




그림 10-1. ASF 발생 및 확산 양상

💡 이렇게 바뀌었습니다!

행정구역 일괄대응에서 시공간 위험도에 따른 선제방역으로 개선

AS-IS	TO-BE
• 발생을 확인한 뒤 행정구역 단위로 일괄 대응 • 경험 기반 규칙과 수작업으로 의심 시료를 조사 • 발생·확산·농가취약성 정보 별도 관리 수행	• 시군구 발생확률을 1km² 환경위험 격자 단위로 제시하여 발생 위험도 선별 • 경험이 아닌 실제 발생 데이터에 기반하여 의심 시료를 빠르게 조사 • 발생·확산 등의 정보를 하나의 지도안에서 관리



2.1 현황 및 배경

2019년 이후 ASF가 장기화되며 확산의 구조 파악 필요

국내에서 처음 발생한 이후 야생멧돼지를 중심으로 아프리카돼지열병(ASF)이 장기화되었다. 초기에는 경기 북부와 강원지역에 집중되었으나 시간이 지나면서 인접 권역으로 점차 확산했다. 신규 발생도 기존 감염지역 주변에서 반복되는 경향을 보여, 감염지역 인근을 중심으로 지속적인 예찰과 방역이 필요했다. 월별 양성률은 시기에 따라 차이를 보여 계절적 특성을 고려한 대응이 필요한 것으로 나타났다.

그러나 발생을 확인한 뒤 이동제한과 차단방역을 실시하는 사후대응만으로는 넓어지는 감염지역과 장기화된 확산 위험을 관리하기 어려웠다. 이에 이미 발생한 지점을 추적하는 방식에서 탈피하여, 향후 발생 가능성이 높은 지역과 시기를 미리 파악하는 선제적 방역체계가 필요했다. 발생이 예상되는 지역을 중심으로 수색과 예찰, 소독자원을 우선 배치해 추가 확산에 대비할 필요가 있었다.




그림 10-2. ASF 확산 현황

2.2 분석 필요성

같은 시군구 안에서도 위험한 곳을 더 세밀하게 선별할 수 있는 분석 필요

야생멧돼지 ASF의 확산 위험을 정확히 판단하려면 행정구역보다 세밀한 공간단위로 지역별 환경 차이를 살펴야 했다. 동일 시군구 안에서도 산림과 도로, 수계의 분포와 기존 발생지와의 거리에 따라 위험수준이 달라질 수 있기 때문이다. 행정구역 전체를 하나의 위험도로 평가하는 방식으로는 이러한 지역별 차이를 충분히 반영하기 어려웠다.

효율적인 방역을 위해서는 발생 가능성뿐 아니라 예상 확산방향과 취약성도 함께 분석해야 했다. 이를 바탕으로 고위험지역을 먼저 찾고 방역인력과 수색·소독 자원을 우선 배치할 필요가 있었다.

시료 관련 부정행위 조사방식도 개선이 필요하였다. 기존에는 담당자의 경험과 사전에 정한 규칙을 적용해 상위 일정 비율을 조사대상으로 선정했다. 이 방식은 자료의 복합적인 분석이나 실제 적발 가능성이 높은 대상을 우선 선별하는 데 한계가 있었다.

따라서 지역별 발생·확산 위험을 통합적으로 판단하고, 시료의 부정행위 가능성까지 데이터로 선별하는 방역 의사결정 지원체계가 필요했다.

핵심 분석 질문

- ① 다음 발생 가능성이 높은 시군구는 어디인가?
- ② 1km² 안에서 위험을 높이는 환경조건은 무엇인가?
- ③ 우선 수색·방역지역은 어디인가?

2.3 데이터 목록

시료정보에 기상·지형·토지피복 등 10종 외부자료 추가

야생멧돼지 ASF의 발생과 확산 위험을 분석하기 위해 관리원이 보유한 검사결과와 야생멧돼지 시료 등의 자료를 핵심 내부데이터로 활용했다. 여기에 기상과 표고, 경사, 토지피복, 도로, 하천, 인구, 행정구역 등 총 10종의 외부 공공데이터를 결합해 지역별 환경과 사회적 특성을 함께 반영했다.

분석기간은 2019년부터 2025년 7월까지로 설정했다. 서로 다른 시점과 공간단위로 수집된 자료는 월별, 시군구 기준으로 통합해 지역별 발생 흐름을 비교할 수 있도록 정비했다. 일부 지역의 누락값은 주변 지역의 특성을 활용하는 KNN 방식으로 보완했다.

행정구역 안에서도 환경에 따라 위험도가 달라질 수 있다는 점을 고려해 공간자료는 1km² 격자 단위로 변환했다. 이를 통해 산림과 도로, 하천, 지형 등 국지적인 환경 차이를 세밀하게 반영하고, 시군구 발생확률과 격자별 환경위험도를 연결할 수 있는 분석기반을 마련했다.

분석 대상과 범위

ASF 시료와 기상·지형·토지피복·도로 등 외부자료 10종을 결합해 시군구와 1km² 격자의 두 공간단위로 분석

영역	주요 데이터	활용
발생·검사	시료·양성·음성	발생예측
농가	위치·사육정보	취약성
환경	기상·지형·토지피복	서식위험
이동·공간	도로·하천·인구	확산경로

표 10-1. 주요 활용 데이터

2.4 EDA : 시공간 발생 현황분석

발생은 일부 권역과 기존 감염지 주변에 집중

발생예측 모델을 구축하기에 앞서 야생멧돼지 ASF의 시공간적 분포를 살펴보았다. 시도와 시군구별 양성시료를 지도에 표시한 결과, 발생지역이 특정 권역에 집중되어 있었으며 기존 감염지역과 인접한 지역에서 반복적으로 발생하는 경향을 확인했다.

월별 검사건수와 양성률을 비교해 계절에 따른 변화도 분석했다. 검사건수가 많다고 양성률이 반드시 높아지는 것은 아니었으며, 특정 시기에 양성률이 높아지는 흐름이 나타났다. 이에 검사량과 실제 발생위험을 구분해 해석하고 월별 특성을 모델에 반영할 필요가 있었다.

과거 발생이력이 현재와 미래의 위험에 미치는 영향을 반영하기 위해 이전 시점의 발생 여부와 관리지역 정보를 시간차 변수로 구성했다. 이를 통해 단순히 현재의 환경조건만 보는 것이 아니라 감염지역 주변에서 이어지는 확산 흐름을 함께 학습하도록 했다.

탐색적 분석에서 확인한 공간적 편중과 계절성, 인접지역의 반복발생은 이후 변수선정과 모델구조를 결정하는 근거가 되었다. 모델 성능도 전체 평균뿐 아니라 지역과 시기별로 위험지역을 안정적으로 구분하는지를 중심으로 평가하도록 했다.




그림 10-3. ASF의 발생 분포

2.5 EDA : 환경과 이동요인 분석

산림·표고·도로·하천정보로 멧돼지 활동환경 도출

토지피복과 지형, 기상변수의 상관관계를 살펴 중복된 정보를 줄였다. 먼저, 인구가 많은 도심지역일수록 멧돼지 출현과 시료수집이 적은 음의 상관이 나타났다. 또한 도로자료의 17개 세부유형은 총개수와 평균·최대 길이 등 파생변수로 바꾸고 PCA를 검토했다.

분석 결과, 도심화 수준과 도로·토지피복 특성이 야생멧돼지 출현 및 ASF 시료 수집 분포와 밀접하게 연관된 것을 확인했다. 또한 중복성이 높은 변수는 통합·축소해 주요 환경요인의 설명력을 유지하면서 모델의 안정성을 높일 수 있음을 확인했다.




그림 10-4. 도로 특성과 ASF 양성률(시군구 단위) 간 상관관계

2.6 빅데이터 모델링 : 발생예측

불균형 자료에서 실제 발생지역을 놓치지 않는 모델 선정

야생멧돼지 ASF 발생 가능성을 예측하기 위해 Logistic Regression, Random Forest, XGBoost와 CatBoost를 후보모델로 비교했다. 양성시료의 비율이 낮은 불균형 자료의 특성을 고려해 소수 양성사례의 학습 비중을 높이는 클래스 가중치를 적용했다.

네가지 후보모델의 ROC-AUC는 0.96~0.98 수준으로 전반적으로 높은 판별력을 보였다. 이 가운데 CatBoost는 과거 발생이력과 기상·지형·토지피복 등 서로 다른 환경요인 사이의 복합적인 관계를 안정적으로 반영했다. 양성지역을 탐지하는 성능도 비교적 우수하게 나타났다.

이에 과거 발생이력과 기상·지형·토지피복 변수를 결합한 CatBoost를 최종 발생예측 모델로 선정했다. 이후 지역과 시점이 달라진 자료에서도 발생 가능성을 안정적으로 구분하는지 확인하고, 고위험지역을 놓치거나 저위험지역을 과도하게 위험지역으로 판단하는 오류를 함께 검증했다.




그림 10-5. 수치형 변수 간 상관행렬

2.7 빅데이터 모델링 : 환경·확산·부정탐지

발생확률을 격자위험과 조사우선순위로 확장

시군구 단위의 발생확률만으로는 실제 수색과 방역이 필요한 세부지역을 특정하기 어려웠다. 이에 발생 가능성이 높은 시군구 안에서 산림과 지형, 도로·하천 등 환경조건을 1km² 격자 단위로 분석해 고위험구역을 세분화했다.

환경적합도 모델에는 변수선택을 거친 L2 로지스틱 회귀를 적용했다. 분석 결과 AUC는 0.799로 나타났으며, 야생멧돼지의 출현과 ASF 발생에 적합한 환경을 격자별 위험도로 구분했다. 시군구 발생예측과 격자별 환경위험도를 결합해 방역인력과 수색자원을 우선 배치할 구역을 구체화했다.

시료 관련 부정행위 가능성도 별도의 점수체계로 분석했다. 시료의 위치와 채취시간, 동일개체 의심 여부, 과거 부정행위 확인지역과 업사 이력을 가중치로 반영해 의심대상을 자동으로 선별했다. 이를 통해 담당자의 경험과 일률적인 상위 비율에 의존하던 조사 방식을 위험도 기반의 우선 조사방식으로 전환했다.

이후에는 환경위험도가 실제 양성시료 분포와 얼마나 일치하는지 확인하고, 부정행위 의심점수가 조사결과를 안정적으로 구분하는지 검증했다. 또한 특정 지역이나 업사에게 조사대상이 과도하게 편중되지 않는지도 함께 점검했다.




그림 10-6. ASF 발생 환경적 위험도(1km 격자)

2.8 모델 성능과 해석 : 발생예측

임계값 0.621에서 탐지와 오경보의 균형 조정

2023년 자료를 활용해 최종 발생예측 모델의 판별력과 고위험지역 탐지성능을 검증했다. 분석 결과 최고 ROC-AUC는 0.9727로 나타나 양성지역과 음성지역을 비교적 안정적으로 구분했다.

위험지역을 판정하는 임계값은 F1이 가장 높으면서 Recall 0.80 이상을 충족하는 0.621로 설정했다. 이 기준에서 정확도는 0.9613, F1은 약 0.6698이었다. 실제 발생지역의 84%를 탐지했으며, 모델이 찾지 못한 발생지역은 23건이었다.

모델 개선 전과 비교하면 전체 정확도는 약 4.8%p 높아졌고, Precision은 0.3363에서 0.5560으로 개선되었다. 이는 고위험지역으로 예측한 대상 가운데 실제 발생지역이 포함되는 비율이 높아져 불필요한 방역대상을 줄일 수 있음을 의미한다.

다만 발생지역 일부를 놓친 사례가 확인된 만큼 예측결과만으로 방역대상을 결정해서는 안 된다. 모델의 위험확률은 현장 신고와 인접지역 발생상황, 환경위험도와 함께 검토해 수색·예찰지역의 우선순위를 정하는 참고정보로 활용해야 한다.

2.9 모델 성능과 해석 : 영향요인

과거 발생이력에 환경정보를 더해 확산위험 설명

모델의 주요 영향요인을 분석한 결과, 시도와 관리지역의 과거 발생이력이 가장 중요한 변수로 나타났다. 이는 기존 감염지역과 인접 권역에서 ASF가 반복적으로 발생한 공간적 특성이 모델에 반영된 결과다.

CatBoost는 과거 발생이력뿐 아니라 기상과 지형, 토지피복 정보를 압축한 변수까지 함께 활용했다. 이를 통해 개별 환경요인의 영향만 보는 데서 나아가 여러 조건이 결합된 지역별 발생구조를 포착했다.

후보모델은 위험지역을 놓치지 않는 민감도 중심 모델과 예측한 위험지역의 적중률을 높이는 정밀도 중심 모델, 두 지표를 고르게 반영한 균형형 모델로 구분되었다. ASF 방역은 실제 발생지역을 놓칠 경우 추가 확산으로 이어질 수 있어 정밀도보다 민감도를 우선해 최종모델과 임계값을 선정했다.

다만 과거 발생이력과 환경변수는 ASF 발생을 확정하는 원인이 아니라 위험확률을 설명하는 통계적 신호다. 따라서 모델결과는 현장 신고와 양성시료 분포, 인접지역의 발생상황을 함께 검토해 방역 우선순위를 정하는 참고정보로 활용해야 한다.

결과 해석 시 유의사항

위험지도는 실제 발생을 확정하는 지도가 아니다. 발생확률과 환경위험, 확산방향과 현장 신고정보를 함께 보며 예찰·수색·소독 순서를 정해야 한다.




그림 10-7. 모델에 활용된 변수 중요도(TOP 20)

2.10 모델 시각화

발생예측과 격자위험, 확산방향을 한 지도에서 연결

시군구별 ASF 발생확률을 지도에 표시하고, 발생 가능성이 높은 지역에는 1km² 환경위험 격자를 중첩해 세부 고위험지점을 확인하도록 했다. 분석사례에서는 양구·삼척·제천·의성·포항 등 5개 시군구가 발생예측 지역으로 제시되었다.

담당자는 시군구 전체를 동일한 위험지역으로 보는 대신 격자별 위험수준을 비교해 우선적으로 살펴볼 구역을 구체화할 수 있다. 고위험격자는 주변의 환경 요인과 야생멧돼지에 의한 확산을 복합 분석하여 확인하도록 구성해 발생위험이 높은 지역을 한 화면에서 검토할 수 있도록 했다.

시각화 화면은 분석결과를 단순히 보여주는 데 그치지 않고 수색과 예찰, 소독 등의 우선순위를 판단하는 데 활용할 수 있다. 이를 통해 한정된 방역인력과 자원을 위험도가 높은 지역에 먼저 배치하도록 지원했다.




그림 10-8. 2025년 8월 ASF 발생 위험도(시군구)

2.11 분석모델 정책 활용 성과

위험도에 따라 방역자원과 조사인력을 차등 배분

현재 이상시료 탐지 모델을 활용해 여러 조건을 복합적으로 분석하고, 부정행위 가능성이 있는 시료와 지역을 신속하게 확인하는 업무에 적용하고 있다. 모델 도입 후 이상시료 탐지에 걸리는 시간은 기존 방법 대비 약 50%이상 단축되었다. 또한 모델이 산출한 이상시료 목록을 바탕으로 분석 대상을 선정해 약 600건의 검토를 완료했으며, 기존의 단편적인 분석만으로는 확인하기 어려웠던 이상지역도 추가로 파악하였다.

시공간 위험도 분석결과를 활용하면 수색과 포획, 소독이 필요한 지역을 우선 선정할 수 있다. 시군구별 발생확률에 1km² 환경위험도와 멧돼지 시료 정보를 결합함으로써 행정구역 전체에 동일한 조치를 적용하던 방식보다 세밀한 방역계획 수립을 지원했다.

시료 부정행위 의심점수는 조사대상을 위험수준에 따라 선별하는 데 활용했다. 이상시료와 관련된 여러 정보를 함께 분석해 우선 확인할 대상을 제시함으로써 담당자가 조사범위를 효율적으로 좁힐 수 있었다. 이를 통해 반복적인 수작업 부담을 줄이고, 기존 방식에서 놓칠 수 있었던 부정행위 가능성을 다각도로 살펴볼 수 있는 기반을 마련했다.


발생 가능성이 높은 지역과 조사 필요성이 큰 대상을 먼저 선별하면 한정된 방역인력과 예산을 효율적으로 배분할 수 있다. 또한 현장 대응에 필요한 시간을 확보해 사후 확산 차단 중심의 방역에서 위험지역을 미리 관리하는 선제적 대응으로 전환할 수 있다. 앞으로도 분석 결과와 현장 확인 사례를 지속적으로 축적해 이상시료 탐지의 정확도를 높이고, 방역 사각지대를 줄이는 데 활용할 계획이다.





3-3

교량 잠재위험지수 산정 및 선제적 안전관리 지원 모델 개발



Part 3-3

교량 잠재위험지수 산정 및 선제적 안전관리 지원 모델 개발

국토안전관리원

다리 위 숨은 위험을 읽는 잠재위험 평가 모델

분석 배경	분석 방법	분석 결과
노후 교량과 기후재난 위험이 커졌지만 점검·보수는 시설상태 중심으로 운영	시설물·기후·하천·지반·인구·건물 등 공공데이터를 융합해 노출도·민감도·취약성 지표 생성	시나리오별 가중합 잠재위험지수와 지도를 제공해 점검·보수 우선순위 선정




그림 11-1. 집중호우 등 자연재난 영향으로 인한 교량 붕괴 사례

과제 한눈에 보기

교량 노후화가 진행되고 집중호우·홍수·폭설 등 기후변화의 영향이 커짐에 따라, 시설물의 점검 이력과 안전등급뿐 아니라 기후·환경 및 주변 여건을 종합적으로 고려한 선제적 안전관리 체계가 필요했다.

이에 국토안전관리원은 교량의 시설물 정보와 점검·보수 이력에 기후변화 시나리오, 홍수·지진, 하천·지반, 토지피복, 인구·건물 등 다양한 공공·환경 데이터를 융합했다. 이를 바탕으로 위험요인을 노출도·민감도·취약성으로 구분하고, 지표별 표준화와 가중치 적용을 통해 교량별 잠재위험지수를 산정했다.

분석 결과는 기후 시나리오와 기간별 교량 위험도를 비교할 수 있는 지도와 시각화 시스템으로 구현했다. 이를 통해 잠재위험이 높은 교량을 우선 검토하고, 현장점검과 보수·보강 대상 선정 및 중장기 안전관리계획 수립을 지원하는 기반을 마련했다.

💡 이렇게 바뀌었습니다!

정기점검 중심에서 복합위험을 고려한 선제 우선순위 관리 방법으로 개선

AS-IS	TO-BE
• 시설물의 안전등급과 노후도, 법정 점검주기 및 과거 점검·보수 이력을 중심으로 관리 • 기후·재난·주변 환경정보는 개별적으로 확인해 사후 점검과 보수·보강 중심으로 대응 • 구조적 특성, 육안점검 결과 등 시설물 자체 상태 중심의 평가에 한정되어 운영	• 교량 시설물·점검·보수 이력에 기후변화 시나리오, 홍수·지진, 하천·지반, 토지피복, 인구·건물 데이터를 통합해 노출도·민감도·취약성을 평가 • 기후(집중호우, 폭설 등) 및 주변 환경(대형 공장 위치 여부 등)을 반영한 교량별 잠재위험지수에 따라 선제적으로 관리 • 다양한 데이터를 연계한 분석 기반 점검 관리 체계 도입




그림 11-2. 실제 교량 안전 분석 시스템 내의 분석모델 화면

3.1 현황 및 배경

노후화와 기후변화가 교량 안전관리의 새로운 변수로 도출

최근 수년간 이상기후가 일상화되고 자연재난의 발생 빈도가 높아지면서, 우리 사회의 기반시설에 대한 안전 우려도 점차 커지고 있다. 특히 기후변화로 인한 극한 강우와 폭염, 폭설 등의 극단적 기상현상은 교량 구조물의 안전성에 직접적인 영향을 미치고 있다.

그중 교량은 준공 후 시간이 지날수록 재료와 구조의 노후화가 진행된다. 따라서 시설물 자체의 노후도뿐 아니라 폭우·적설·폭염과 지진 등 다양한 외부위험을 함께 고려해야 했다.

그러나 기존 교량 안전관리는 정기점검과 정밀진단, 과거 보수·보강 이력을 중심으로 운영되었다. 기후변화와 자연재난, 교량 주변의 환경 및 생활권 정보를 종합적으로 결합해 상대적 위험 수준을 판단하는 데에는 한계가 있었다.

이에 전국 교량 가운데 현장점검 대상을 합리적으로 선정하려면, 교량별 잠재위험을 동일한 기준으로 비교하고 관리 우선순위를 정할 수 있는 새로운 분석체계가 필요했다.



3.2 분석 필요성

현행 안전등급에 외부 위험요인을 더해 잠재위험 파악 필요

현행 교량 평가는 시설물의 부재 상태와 구조·재료 성능을 중심으로 안전등급을 산정한다. 이 체계는 점검 당시의 물리적 상태와 기능을 확인하는 데 중요한 기준으로 활용되고 있다.

그러나 같은 안전등급의 교량이라도 집중호우와 폭설, 홍수·지진 위험, 교통하중과 주변 생활권에 따라 실제 관리 필요성은 다르게 나타날 수 있다.

따라서 기존 안전등급을 대체하기보다, 시설물 상태에 기후·환경 및 사회적 영향요인을 보완해 현장점검과 보수·보강 대상을 선제적으로 검토할 수 있는 잠재위험 평가모델이 필요했다.




그림 11-3. 교량 종합평가 등급 산정을 위한 평가체계

3.3 데이터 목록

시설물 상태와 외부 위험을 교량 위치를 기준으로 연결

국토안전관리원은 기반시설관리시스템에서 총 52,695개의 교량 시설정보를 수급했다. 시설물명과 관리주체, 준공일, 내진설계 여부 및 위치정보를 정비하고, 전국 교량 표준 데이터와 연속수치지형도를 활용해 좌표 오류와 중복자료를 보정했다. 이를 통해 30,090개 교량을 최종 분석대상으로 선정했다.

교량별 관리번호를 기준으로 점검·진단정보 574,145건, 보수·보강정보 87,672건, 성능개선정보 54,793건을 연결했다. 점검·진단정보는 종합성능평가등급이 부여된 가장 최근 이력을 적용하고, 보수·보강 및 성능개선정보도 최신 공사이력을 중심으로 정리했다.

교량 자체의 상태뿐 아니라 외부 위험과 주변 피해 가능성을 함께 분석하기 위해 기후변화 시나리오, 홍수·지진, 하천·지반, 토지피복, 인구·건물 등의 공공·환경 데이터를 추가로 결합했다. 서로 다른 자료는 교량 위치를 기준으로 공간정보화하여 교량별 잠재위험 분석에 활용했다.

영역	주요 데이터	활용
시설물	교량 제원·준공일·내진설계·안전등급	노후도와 시설 취약성 파악
점검·관리	점검·진단·보수·보강·성능개선 이력	최근 시설상태와 관리이력 반영
기후·재난	기후변화·홍수·지진·하천·지반	외부 위험 노출 수준 분석
주변 환경	토지피복·인구·건물·건설현장·항만·물류단지	주변 영향과 피해 가능성 반영

표 11-1. 주요 활용 데이터

3.4 EDA : 시설물 현황 및 분포 분석

점검 이력과 안전등급, 관리주체별 분포에서 관리 여건의 차이 확인

시설물 기본정보를 마스터 테이블로 두고 점검·진단, 보수·보강, 성능개선 이력을 관리 번호로 연결했다. 이력자료는 점검일과 공사 시작일을 기준으로 가장 최근 자료를 추출해 교량별 상태를 비교했다.

전체 52,695개 교량 가운데 최신 점검일자가 등록된 교량은 42,994개로 81.6%였으며, 점검 이력이 확인되지 않은 교량은 9,701개로 18.4%였다. 개별 교량의 평균 점검 횟수는 12회로 나타났다.

점검 횟수가 1회인 교량 2,822개 가운데 지방자치단체 관리 시설은 2,261개로 80.1%를 차지했다. 시설물안전법 비대상 교량은 1,782개였으며, 30년 이상 노후 교량도 931개 포함되어 있었다.

관리주체별로는 지방자치단체가 전체의 52.6%로 가장 큰 비중을 차지했다. 교량 수와 점검 이력, 안전등급의 분포가 관리주체와 지역에 따라 달라 일률적인 관리기준을 보완할 필요가 있었다.




그림 11-4. 관리 유형별 교량 시설물 분포

3.5 EDA : 노후도 및 지역별 특성 분석

노후 교량의 증가와 지역별 등급 변화를 함께 분석

준공일을 기준으로 2025년 10월 1일 현재 교량의 경과년수를 계산했다. 30년 이상 된 노후 교량은 전체의 25.8%였으며, 가장 오래된 교량의 경과년수는 125년으로 확인되었다.

1990년대와 2000년대에 준공된 교량의 수가 가장 많아 향후 10년 안에 노후 교량의 비중이 빠르게 증가할 가능성이 있었다. 특히 지방자치단체는 30년 이상 교량의 절대 수가 가장 많았다.

지역별로는 경기도에 교량이 가장 많이 분포했다. 2013년과 2025년의 종합성능 평가 등급을 비교한 결과, 일부 지역을 제외한 대부분 지역에서 평균등급이 낮아지는 흐름이 나타났다.

등급 변화에는 시설물 노후화뿐 아니라 점검기준 강화와 중소규모 교량의 평가 확대도 영향을 줄 수 있으므로, 결과를 단순한 구조성능 저하로만 해석하지 않도록 했다.



그림 11-5. 준공연도별 교량 수

3.6 빅데이터 모델링 : 잠재위험 지표체계

교량 위험을 노출도·민감도·취약성의 세 축으로 구성

잠재위험지수는 외부위험이 교량에 영향을 미치는 과정을 단계적으로 설명할 수 있도록 설계했다. 먼저 기후변화와 홍수·지진 등 위험에 놓이는 정도를 노출도로 구성했다.

하천과 지반, 토지피복, 교통 및 주변 환경에 따라 위험의 영향이 달라지는 정도는 민감도로 정리했다. 교량의 경과년수와 내진설계 여부, 종합성능평가등급은 시설물 자체의 취약성을 설명하는 지표로 활용했다.

후보지표는 선행연구와 데이터 확보 가능성을 기준으로 수집했다. 이후 상관분석과 전문가 자문을 거쳐 정보가 중복되거나 설명력이 낮은 항목을 줄이고 최종 활용지표를 선정했다.

이와 같은 지표체계는 기존 안전등급을 대신하는 것이 아니라, 기후·재난과 주변 여건을 함께 고려해 추가 점검이 필요한 교량을 선별하기 위한 보완지표로 구성되었다.

교량	노후도		평균 인구수		...	위험점수	교량 위험도 지수
A	0.33	0.02	0.10	0.01	...	0.00685	6.50
B	0.67		0.49		...	0.00579	5.30
C	1.0		0.27		...	0.00731	7.37

표 11-2. 노출도·민감도·취약성 기반 잠재위험 지표체계

3.7 빅데이터 모델링 : 표준화와 가중치

서로 다른 단위의 지표를 같은 기준으로 환산해 하나의 지수로 결합

강수량과 적설량, 인구수, 하천거리, 안전등급처럼 단위와 값의 범위가 다른 지표는 그대로 더할 수 없다. 이에 각 값을 공통 척도로 표준화하고, 위험이 커지는 방향이 동일하도록 점수체계를 정리했다.

지표 간 상관관계와 변별력을 비교해 대표지표를 선정하고 기본 가중치를 산정했다. 전문가 자문에서는 향후 구조·기후·재난 분야 전문가의 AHP 조사 등을 통해 가중치를 정교화할 필요가 있다는 의견도 제시되었다.

교량별 잠재위험지수는 선택한 지표값에 가중치를 곱해 합산한 뒤 활용지표 수를 반영해 계산했다. 분석 화면에는 기본 가중치를 제공하되, 정책 목적에 따라 담당자가 지표와 비중을 변경해 결과를 비교할 수 있도록 했다.




그림 11-6. 활용지표 선정과 가중치 적용 절차

3.8 모델 성능과 해석 : 기후 시나리오

미래 기후의 경로와 기간에 따라 교량 위험의 변화를 비교

기후변화의 불확실성을 하나의 값으로 단정하지 않기 위해 저탄소 시나리오 SSP1-2.6과 고탄소 시나리오 SSP5-8.5를 적용했다.

각 시나리오는 단기 2025~2050년, 중기 2051~2075년, 장기 2076~2100년으로 구분했다. 강수량과 호우일수, 폭염·결빙일수 등은 1km 격자 또는 행정구역 단위로 변환해 교량 위치에 연결했다.

동일한 교량도 시나리오와 기간에 따라 노출 수준이 달라질 수 있었다. 따라서 분석결과는 하나의 확정된 미래위험이 아니라, 여러 조건에서 반복적으로 높은 위험을 보이는 교량을 검토하는 자료로 해석했다.

가중치 조정에는 교량과 재난에 대한 현장 이해가 필요하므로, 시스템에서는 검토된 기본값을 우선 제시하고 변경한 분석조건을 함께 기록하도록 했다.




그림 11-7. 교량 위험도 지수(여름철 우기)




그림 11-8. 교량 위험도 지수(겨울철 동절기)

3.9 모델 성능과 해석 : 타당성 검토

기존 공사이력과 비교해 잠재위험지수의 역할과 한계 확인

잠재위험지수와 2024년 보수·보강 및 성능개선 이력을 비교했다. 다만 공사이력은 현장점검과 행정절차에 따라 결정된 결과이므로, 이를 정답값으로 보는 성능검증이 아니라 지표의 타당성을 살펴보는 참고분석으로 정의했다.

가설별 AUC는 0.4429~0.5493 수준으로 나타났다. 기존 보수·보강과 성능개선은 기후·환경 데이터보다 실제 현장점검 결과를 중심으로 결정되어 왔음을 보여주는 결과였다.

따라서 잠재위험지수는 기존 점검과 공사결정을 그대로 재현하는 모델이 아니라, 기존 관리체계에서 충분히 다루지 못했던 기후·재난 및 주변 환경요인을 보완하는 우선순위 지표로 활용해야 한다.




그림 11-9. 잠재위험지수와 보수·보강 이력의 타당성 비교

3.10 모델 시각화

분석조건과 교량별 위험 결과를 지도와 목록으로 한눈에 제공

사용자는 기후 시나리오와 분석기간을 선택한 뒤, 노출도·민감도·취약성 평가에 적용되는 세부지표와 가중치를 확인할 수 있다. 설정한 조건으로 분석을 실행하면 교량별 잠재위험지수와 상대등급이 지도와 목록에 표시되어 위험도가 높은 교량을 한눈에 비교할 수 있다.

특정 교량을 선택하면 잠재위험지수를 구성하는 세부지표와 시설물 정보가 함께 제공된다. 이를 통해 해당 교량의 위험도가 높게 산정된 원인과 주요 영향요인을 구체적으로 파악할 수 있다.

분석과정의 안정성과 결과의 재현성도 고려했다. 기본 가중치를 적용한 분석결과는 별도로 저장해 사용자가 지표나 가중치를 잘못 설정하더라도 기준값과 비교할 수 있도록 했다. 분석에 적용한 기후 시나리오와 기간, 세부지표, 가중치 및 결과는 엑셀파일로 내려받아 추가 검토와 업무보고에 활용할 수 있다.

이처럼 화면은 교량별 위험순위만 제시하는 데 그치지 않고, 어떤 조건과 지표가 결과에 반영되었는지를 함께 기록하도록 구성했다. 이를 통해 분석결과의 근거를 명확히 확인하고 현장점검과 보수·보강 대상 선정에 활용할 수 있도록 의사결정의 설명 가능성을 높였다.

The image displays three sequential screenshots of a web application interface for bridge risk analysis. Each screenshot shows a sidebar with navigation options and a main content area with various settings and data.

- Left Screenshot:** Shows the 'Analysis Conditions' (분석조건 설정) screen. It has tabs for 'Bridge Selection' (교량선택), 'Exposure' (노출도), and 'Sensitivity' (민감도). Under 'Bridge Selection', there are checkboxes for 'Bridge Selection' (교량선택) and 'Bridge Selection' (교량선택). Under 'Exposure', there are checkboxes for 'Bridge Selection' (교량선택) and 'Bridge Selection' (교량선택). Under 'Sensitivity', there are checkboxes for 'Bridge Selection' (교량선택) and 'Bridge Selection' (교량선택).
- Middle Screenshot:** Shows the 'Bridge Selection' (교량선택) screen. It has a dropdown menu for 'Bridge Selection' (교량선택) and a list of bridges with their risk scores. The list includes bridges like 'Bridge Selection' (교량선택) and 'Bridge Selection' (교량선택).
- Right Screenshot:** Shows the 'Bridge Selection' (교량선택) screen. It has a dropdown menu for 'Bridge Selection' (교량선택) and a list of bridges with their risk scores. The list includes bridges like 'Bridge Selection' (교량선택) and 'Bridge Selection' (교량선택).

그림 11-10. 시나리오별 활용 지표 및 가중치 설정 화면

3.11 분석모델 정책 활용 성과

잠재위험이 높은 교량을 현장점검 후보로 우선 검토 가능

현재 집중안전점검 홈페이지에서 관련 공지와 배너를 게시해 관리주체가 분석결과를 점검업무에 참고할 수 있도록 적용하였다. 실제로 고위험 교량 20개소를 관리하는 10개 관리주체에 분석결과를 제공하였고, 우기에 대비해 고위험 10개 교량의 현장점검을 실시했다.

관리자는 기후 시나리오별 잠재위험지수를 활용해 현장점검이 필요한 교량 후보를 먼저 검토할 수 있다. 기존 안전등급과 점검주기에 기후·홍수·지진 및 주변 생활권 정보를 보완하는 방식이다. 특히 상시·우기·동절기 등 계절과 상향별 특성을 반영한 산출체계를 구축해 점검 시점과 여건에 적합한 위험요인을 함께 살펴볼 수 있도록 했다..

점검 결과와 잠재위험지수를 함께 살펴보면 보수·보강 대상과 안전관리 예산의 우선순위를 논의하는 객관적 근거로 활용할 수 있다. 또한, 시나리오와 기간별 결과는 단기 점검계획뿐 아니라 노후 교량 증가와 미래 기후변화를 고려한 중장기 안전관리계획 수립에도 활용할 수 있다. 다만 잠재위험지수가 높다는 이유만으로 위험교량을 확정해서는 안 된다. 최종 판단은 현장점검과 구조검토, 관리주체의 전문적 판단을 거쳐야 한다.

향후에는 집중안전점검 관련 설명회를 통해 지방자치단체의 모델 활용을 지원하고, 현장 적용 범위를 단계적으로 확대할 계획이다. 추가로, 교량 사고와 현장점검 결과를 분석모델에 반영해 잠재위험지수를 지속적으로 보완하고, 관련 데이터를 주기적으로 갱신해 분석자료의 최신성을 유지할 예정이다.



2025

공공부문 데이터 분석·활용

우수사례집

Part •

산업경제



4.1 에너지 다소비 사업장 사용량 예측 및 수요관리 최적화 모델 개발

한국에너지공단



4-1

에너지 다소비 사업장 사용량 예측 및 수요관리 최적화 모델 개발



Part 4-1

에너지 다소비 사업장 사용량 예측 및 수요관리 최적화 모델 개발

한국에너지공단

전력의 내일을 읽는 사용량 예측 모델 기반 수요관리 최적화

분석 배경	분석 방법	분석 결과
중소·중견기업은 산업부문 에너지의 32.1%를 차지하지만 전담인력과 데이터가 부족해 체계적인 수요관리에 어려움이 존재	사업장 전력·기상·기업정보를 결합하고 효율성 군집과 LSTM 시계열 예측모델 구축	분기별 사용량 예측과 비교군 대비 효율지표를 대시보드·보고서로 제공하는 기반 마련

과제 한눈에 보기

에너지 다소비 사업장은 산업부문 에너지 사용에서 큰 비중을 차지하지만, 중소·중견기업은 전담인력과 데이터가 부족해 사업장별 사용패턴을 분석하고 수요를 예측하는 데 어려움이 있었다. 업종과 규모가 다른 사업장을 같은 기준으로 비교하기도 어려워, 기업 특성을 반영한 맞춤형 수요관리 체계가 필요했다.

이에 한국에너지공단은 사업장별 15분·60분 단위 전력사용량에 업종·규모·매출·종업원 수 등의 기업정보와 기상정보를 결합했다. 유사 사업장과 비교할 수 있는 효율성 지수를 산정하고, 최근 12개월의 사용패턴을 학습해 다음 90일의 전력사용량을 예측하는 사업장별 LSTM 모델을 구축했다.

분석 결과는 전력사용 규모와 효율성, 피크위험도, 분기별 예측값을 확인할 수 있는 대시보드와 보고서로 구현했다. 이를 통해 공단은 수요관리 지원이 필요한 사업장을 우선 검토하고, 기업은 에너지 절감계획과 ESG·내부 관리자료 작성에 활용할 수 있는 기반을 마련했다.



그림 12-1. 전체 사업장에 대한 전력 사용 분포 및 부하율 등을 확인할 수 있는 시각화 화면

이렇게 바뀌었습니다!

과거 사용량 확인에서 사업장별 미래수요와 절감 기회 제시

AS-IS	TO-BE
- 전담인력과 분석데이터가 부족해 전력사용량과 피크를 사후에 확인 - 업종·규모가 다른 사업장을 동일 기준으로 비교해 일률적인 절감방안을 검토 - 전력 피크에 대한 사전 제시 정보가 없어 에너지 수요관리 불가	- 전력사용량과 기업·기상정보를 결합해 사업장별 90일 사용량을 예측 - 업종·산업·기업규모가 유사한 집단 안에서 효율성과 피크위험을 진단 - 전력 피크 회피를 위한 예측 부하, 잔여 전력량 및 권장 가이드라인 제시 가능




그림 12-2. 사업장별 미래 전력수요와 효율 수준을 보여주는 성과 화면

1.1 현황 및 배경

에너지 사용 비중이 큰 중소·중견기업에는 사업장별 맞춤형 관리 필요

사업장의 전력사용량은 생산일정과 계절, 업종과 규모가 함께 만든 결과이므로 단순한 전체 평균만으로 효율을 판단하기 어렵다.

산업부문은 우리나라 에너지 소비에서 큰 비중을 차지하며, 제조업 중심의 산업구조는 에너지 수요관리의 중요성을 더욱 높이고 있다. 특히 중소·중견기업은 연간 2,635만 toe를 사용해 산업부문 에너지의 32.1%를 차지했다. 그러나 중소·중견기업은 에너지 전문인력과 분석데이터가 충분하지 않아 사용량을 사후에 확인하는 수준을 넘어 향후 수요와 피크를 예측하기 어려웠다.

같은 양의 전력을 사용하더라도 업종과 규모, 생산공정과 설비 운영시간에 따라 효율 수준은 다르게 해석해야 한다. 기온과 계절, 지역 및 건물 특성도 사업장의 전력사용 패턴에 영향을 준다. 따라서 사업장별 전력 흐름을 분석하고 유사한 기업과 비교해 에너지 효율을 진단할 수 있는 데이터 기반 수요관리체계가 필요했다.

이러한 배경은 기존 업무를 보완할 새로운 분석체계가 왜 필요한지를 보여주었다.




그림 12-3. 에너지 다소비 사업장 수요관리 필요성을 보여주는 원자료

1.2 분석 필요성

과거 사용량 확인을 넘어 미래 수요와 절감 가능성을 함께 제시하여 설명하는 화면 설계

에너지 다소비 사업장은 업종·산업·기업규모에 따라 조업일과 설비구성, 냉난방 수요가 다르다. 전체 사업장의 평균만으로 비교하면 규모가 큰 업종과 특정 산업의 영향으로 결과가 왜곡될 수 있다. 전력사용량은 시간의 흐름에 따라 연속적으로 기록되며 요일과 계절, 휴일과 생산일정의 영향을 받는다. 이러한 반복패턴을 학습해 사업장별로 미래 사용량을 예측할 필요가 있었다.

예측값만 제공해서는 실제 수요관리로 이어지기 어렵다. 사용규모와 부하율, 매출·연면적·종업원 수 대비 전력사용량을 유사 집단과 비교하고, 절감이 필요한 지점을 함께 설명해야 했다. 한국에너지공단은 약 5,000개 다소비 사업장 가운데 데이터 활용이 가능한 사업장을 대상으로 모델을 구축하고, 공단과 기업이 결과를 확인할 수 있는 모듈형 대시보드와 보고서를 마련하고자 했다.

세부 분석은 이 질문에 답하면서 현장에서 우선 확인해야 할 대상을 구체화하는 방향으로 설계했다.

핵심 분석 질문

- ① 사업장의 사용패턴과 피크는 언제 나타나는가?
- ② 유사한 기업과 비교할 때 효율수준은 어떠한가?
- ③ 앞으로 90일 동안 전력수요는 어떻게 달라질 것인가?




그림 12-4. 사업장 데이터 분석과 수요관리 서비스의 전체 구성

1.3 데이터 목록

전력 시계열과 기업·기상정보를 사업장번호를 기준으로 결합

사업장별 15분·60분 단위 전력사용량을 수집하고 시간·일·주·연 단위로 집계했다. 단기 사용변화와 연간 계절성을 함께 분석할 수 있도록 일별 사용량과 7일·30일 이동평균, 변동성 등의 파생변수를 만들었다. 에너지 다소비 사업장 신고자료와 업체 추가정보를 활용해 업종, 산업, 기업구분, 소재지와 고객번호를 정비했다. 매출액과 종업원 수, 연면적 등의 기업·건물정보는 유사 집단 구성과 효율성 진단에 활용했다.

평균기온과 월·요일·주말 여부 등 외부·시간정보를 결합했다. 서로 다른 자료는 사업장 번호를 공통키로 매핑해 기업특성 분석용 데이터와 시계열 예측용 데이터로 각각 구축했다.

분석 대상과 범위

15분·60분 전력사용량에 업종·산업·기업규모·매출·종업원 수·연면적과 기상·시간정보를 결합하고, 조건을 충족한 3,286개 사업장을 분석했다.

영역	주요 데이터	활용
전력사용	15분·60분 사용량, 일·월·연 집계	사용패턴·피크·미래수요 예측
사업장 특성	업종·산업·기업규모·소재지	유사 집단 구성과 맞춤형 비교
기업·건물	매출·종업원 수·연면적·설비정보	전력집약도와 효율성 진단
기상·시간	기온·월·요일·주말·이동평균	계절성과 단기 변동 반영

표 12-1. 주요 활용 데이터

1.4 EDA : 사업장 현황 및 분포 분석

업종과 산업, 기업규모에 따라 사업장이 다르게 분포

2020~2024년 에너지 다소비 사업장 수를 살펴본 결과 산업과 건물 부문이 전체의 상당 부분을 차지했고, 수송 부문은 상대적으로 적었다. 제조업 기반의 에너지 다소비 구조가 지속되고 있음을 보여주는 분포였다. 5개년 추이에서는 모든 업종의 사업장 수가 증가하는 흐름이 나타났다. 사용량 변화를 해석할 때 개별 사업장의 효율 변화와 전체 사업장 수 증가의 영향을 구분할 필요가 있었다.

산업별 사업장 수는 특정 산업군에 집중되어 있었다. 단순 평균을 적용하면 사업장 수가 많은 산업의 특성이 전체 결과를 좌우할 수 있어, 동일 산업과 업종 안에서 상대적으로 비교하는 방식이 적합했다. 기업구분별로는 중견기업이 큰 비중을 차지했다. 대기업 뿐만 아니라 중소·중견기업의 에너지 수요를 세분화하고 사업장 특성에 맞는 관리기준을 적용해야 했다.




그림 12-5. 2020~2024년 업종별 에너지 다소비 사업장 분포

1.5 EDA : 전력사용 패턴과 기온 영향

업종별 계절성과 기온 민감도를 구분해 예측변수로 활용

업종별 일평균 전력사용량은 산업부문이 가장 높았고 건물, 발전, 수송 순으로 나타났다. 동일 업종 안에서도 기업규모와 생산공정에 따라 사용량의 분산이 크게 나타났다. 건물부문은 냉난방 영향으로 여름과 겨울에 사용량이 증가하는 경향을 보였다. 산업부문은 계절보다 조업일과 가동률, 생산계획에 따라 비교적 안정적인 흐름을 보이거나 특정 시점에 변화가 나타났다.

전력사용량과 기온은 단순 직선관계가 아니었다. 기온이 낮을 때는 난방, 높을 때는 냉방으로 사용량이 증가할 수 있어 다항회귀를 적용해 비선형 관계를 분석했다. 기온과 전력사용량의 설명력인 R^2 는 산업 0.088, 발전 0.109, 건물 0.420, 수송 0.348이었다. 건물과 수송부문에서 기온의 영향이 상대적으로 뚜렷하게 나타나 예측모델의 파생변수로 반영했다.




그림 12-6. 업종별 전력사용량과 기온의 상관관계

1.6 EDA : 유사 집단별 효율성 분석

전력사용량의 크기보다 비슷한 사업장과 비교한 효율 수준 진단

효율성 평가는 전력을 많이 또는 적게 사용했는지를 단순 비교하지 않고, 업종·산업·기업구분이 유사한 사업장 안에서 상대적인 수준을 판단하도록 설계했다. 부하율과 매출당·연면적당·종업원 수당 전력사용량을 공통 지표로 활용했다. 사용 가능한 지표 수가 사업장마다 다를 수 있어 효율점수와 함께 지표 신뢰도도 표시했다.

전력사용 규모와 비효율지수를 4분면으로 구분해 고사용·저효율, 고사용·고효율, 저사용·저효율, 저사용·고효율 사업장을 확인했다. 동일한 건물업종이라도 백화점과 병원, 아파트, 호텔은 운영시간과 설비밀도, 이용자 수가 달라 효율기준이 달랐다. 분석에서는 산업유형을 세분화해 비교의 공정성과 해석력을 높였다.




그림 12-7. 전력사용 규모와 효율성 지수를 활용한 사업장 유형 분석

1.7 빅데이터 모델링 : 후보모델 선정

장기 추세와 계절성을 따라가는 LSTM을 최종 예측모델로 선정

전력사용량 예측에는 XGBoost와 LSTM을 후보모델로 적용했다. XGBoost는 학습한 값의 범위 안에서 비선형 관계를 설명하는 데 강점이 있지만, 미래 값이 기존 범위를 벗어나면 상승·하강 추세를 따라가기 어려웠다. LSTM은 이전 시점의 중요한 정보를 장기간 기억하는 순환신경망 구조다. 최근 사용량과 계절성, 요일별 반복패턴을 시간순으로 학습해 장기 추세를 반영할 수 있었다.

비교 결과 LSTM은 MSE 10,459, RMSE 102.3, MAPE 0.125를 기록했다. XGBoost는 MSE 44,411, RMSE 210.7, MAPE 0.246으로 나타났다. 세 가지 오차지표에서 LSTM의 값이 모두 작았고 실제 시계열의 추세도 더 안정적으로 따라가 최종모델로 선정했다.

1.8 빅데이터 모델링 : 사업장별 90일 예측

최근 12개월을 학습하고 7일씩 반복해 다음 90일을 예측

사업장마다 업종과 규모, 조업일정과 설비운영 방식이 달라 하나의 범용모델을 적용하지 않았다. 데이터 조건을 충족한 각 사업장에 독립된 LSTM 모델을 구축하고 예측 시 전용모델을 불러오도록 했다. 가장 최근 12개월을 학습범위로 설정해 연간 계절성과 최신 사용패턴을 반영했다. 월과 요일은 주기성을 유지하도록 사인·코사인 값으로 변환하고 7일·30일 이동평균과 7일 이동표준편차를 추가했다.

긴 기간을 한 번에 예측할 때 평균값으로 수렴하는 현상을 줄이기 위해 7일을 먼저 예측하고, 그 결과를 다시 입력해 다음 7일을 계산했다. 이 과정을 반복해 총 90일의 전력사용량을 산출했다. 예측모델은 분기마다 최신자료로 갱신할 수 있도록 설계했다. 새로 등록된 사업장은 충분한 사용이력이 확보된 뒤 별도모델을 학습해 적용할 수 있다.




그림 12-8. 최근 전력사용 패턴을 이용한 90일 단계별 예측결과

1.9 모델 성능과 해석

자료 품질을 점검하고 미래 시점에서도 예측 흐름이 유지되는지 검증

전력사용량에 음수가 포함된 1개 사업장과 7일 이상 연속결측이 있는 48개 사업장은 학습에서 제외했다. 1년 이상 자료가 없는 970개와 2025년 최신자료가 없는 1,169개 사업장도 구분했다. 단기 1~2일 결측은 전후 시점의 평균값으로 보간했지만, 7일 이상 결측은 실제 주간패턴을 왜곡할 수 있어 임의로 채우지 않았다. 최종적으로 3,286개 사업장의 전용모델을 학습했다.

2024년 자료를 학습하고 2025년 사용량을 예측하는 연도 간 교차검증을 수행했다. 학습기간에만 맞는 모델이 아니라 실제 미래의 계절성과 요일별 흐름도 반영하는지 확인하기 위한 검증이었다. 결과적으로 LSTM은 평일과 주말의 반복주기, 조업일정에 따른 안정적인 사용패턴을 따라갔다. 일시적인 이상치보다 지속되는 추세와 규칙성을 중심으로 예측했다.

결과 해석 시 유의사항

예측값은 생산계획과 설비변경 같은 미래의 모든 변화를 알 수 없다. 효율성 지수와 피크위험도, 최근 운영정보를 함께 보며 수요관리 계획에 활용해야 한다.

구분	LSTM	XGBoost
MSE	10,459	44,411
RMSE	102.3	210.7
MAPE	0.125	0.246
해석	추세·계절성 반영에 유리	학습범위 밖 장기추세 반영에 한계

표 12-2. 모델 성능 및 해석

1.10 모델 시각화

예측값과 효율성, 피크위험을 사업장별 대시보드로 제공

사용자 화면은 사업장 코드를 입력하면 해당 기업의 업종과 기업구분, 산업분류, 소재지와 주요 에너지 지표를 확인할 수 있도록 구성했다. 핵심지표에는 효율성 지수와 전력사용 규모, 변동성, 피크위험도와 효율분석에 사용한 지표 수를 포함했다. 전년도 실적과 분기별 예측 값도 그래프로 비교했다.

전력사용 규모와 비효율지수는 4분면으로 표시하고, 부하율과 매출·연면적·종업원 수 대비 전력사용량은 레이더차트와 비교그래프로 제공했다. 관리자 화면은 공단이 전체 다소비 사업장의 효율성과 예측현황을 살펴보고 지원이 필요한 대상을 검토하도록 구성했다. 기업은 자신의 사업장 결과만 확인하도록 화면과 권한을 구분했다.




그림 12-9. 사업장 사용자·관리자 대시보드의 주요 화면 구성

1.11 분석모델 정책 활용 성과

공단의 수요관리 지원과 기업의 에너지경영을 함께 지원

현재 에너지 다소비 사업장의 에너지 소비현황을 파악하고 사업장별 효율 수준을 분석하는 업무에 대시보드를 활용하고 있다. 담당자는 사업장과 업종별 사용량, 예측 결과와 효율성 지표를 한 화면에서 확인해 수요관리와 에너지 진단이 필요한 대상을 검토할 수 있다.

한국에너지공단은 유사 집단 대비 효율이 낮거나 피크위험이 높은 사업장을 우선 검토해 에너지 진단과 수요관리 지원대상을 선정한다. 분기별 사용량 예측 분석 결과는 사업장과 업종별 전력수요를 미리 파악하고 에너지 사용 피크기간의 관리계획과 절감목표를 수립하는 참고자료로 활용된다.

개별 사업장에서는 예측값과 효율성 지표를 내부 에너지관리 보고서 및 ESG 자료 작성에 활용하고, 다른 유사 사업장과 비교해 설비와 운영방식의 개선 필요성을 점검할 수 있다. 분석결과는 시스템에 고정적으로 탑재하기보다 모듈과 대시보드, 필요시 출력할 수 있는 보고서 형태로 제공해 기존 업무와 연계할 수 있도록 했다.

향후 신고된 실제 사용량과 모델 예측값을 비교해 사업장별 절감 수준과 수요관리 효과를 점검하고, 그 결과를 모델 보완과 에너지 효율 정책의 고도화에 활용할 계획이다.



2025

공공부문 데이터 분석·활용

우수사례집

Part •

교통안전



5.1 운수종사자 인지적 특성에 기반한 교통사고 위험도 예측

한국교통안전공단

5.2 교통사고 위험 예측 및 실시간 안전정보 제공 지원 모델 개발

한국도로교통공단



5-1

운수종사자 인지적 특성에 기반한 교통사고 위험도 예측



Part 5-1

운수종사자 인지적 특성에 기반한 교통사고 위험도 예측

한국교통안전공단

교통사고 위험도 예측 모델을 활용한 인지 특성 기반 안전관리

분석 배경	분석 방법	분석 결과
사업용 차량은 차량 1만 대당 사망자가 전체 차량보다 약 3배 높아 운전자 인적요인 관리가 필요	운전적성정밀검사와 사고·행정처분 이력을 결합하고 여러 알고리즘을 비교해 위험확률 예측모델을 구축	확률 보정까지 거친 통합모델을 사고위험 관리와 검사제도 개선의 참고자료로 활용할 기반을 마련

과제 한눈에 보기

사업용 차량의 교통사고는 운수종사자뿐 아니라 승객과 다른 도로 이용자의 안전에도 큰 영향을 준다. 기존 관리는 사고 이후의 기록이나 차량·도로 요인을 중심으로 이루어져 운전적성검사에 나타난 인지·반응 특성을 사고예방에 충분히 활용하기 어려웠다. 개인별 위험을 믿을 만한 확률로 제시하는 체계가 필요했다.

이에 한국교통안전공단은 약 94만건의 운전적성정밀검사 결과와 교통사고·행정처분 이력을 활용했다. 반응속도와 주의력 등 인지적 특성을 활용해 사고위험확률을 산출하고, AUC와 Brier Score, ECE를 통해 판별력뿐 아니라 예측확률의 신뢰도까지 검증했다.

분석 결과는 운수종사자별 위험수준과 주요 영향요인을 확인하는 관리정보로 구현했다. 이를 통해 위험 가능성이 높은 종사자를 선제적으로 선별하고 맞춤형 교육·상담·정밀검사 대상을 정해 사업용 차량의 교통안전 관리를 강화할 기반을 마련했다.



그림 13-1. AI 운전자 위험 분석 대시보드 화면

💡 이렇게 바뀌었습니다!

정기점검 중심에서 복합위험을 고려한 선제 우선순위 관리 방법으로 개선

AS-IS	TO-BE
• 사고 이력과 도로·차량 요인 중심의 사후 관리, 운전적성검사의 인지 특성을 활용한 위험 예측의 한계 • 교통사고 발생 후 사후 대처 및 관리 • 단순 정확도 중심 평가에 따른 소수 위험군 식별의 어려움	• 검사·사고·행정처분 이력 기반 개인별 사고위험 확률 산출 • ·교통사고 발생 가능성을 사전에 확인 후 대처 및 관리 • 위험군 선별과 맞춤형 교육·검사 개선을 위한 보조지표 마련



1.1 현황 및 배경

사망자는 줄었지만 사업용 차량의 상대적 위험은 여전히 증가 추세

많은 승객의 안전을 책임지는 운수종사자에게는 사고 이후의 관리보다 위험 가능성을 조기에 발견하는 예방적 관리가 중요하다.

사업용 차량의 안전을 높이기 위해서는 사고 이후의 기록을 확인하는 사후관리에서 나아가, 운전자의 인지적 위험신호를 미리 살피는 예방적 관리가 필요했다. 2024년 국내 교통사고 사망자는 2,521명이었으며, 인구 10만 명당 사망자는 5.6명으로 OECD 국가와 비교할 때 교통안전 수준은 여전히 낮은 편이었다. 특히 전체 자동차의 차량 1만 대당 사망자는 1.1명이었지만, 사업용 차량은 3.3명으로 약 3배 높았다.

사업용 차량은 장시간 반복 운전과 승객 운송이라는 업무 특성을 지닌다. 사고가 발생하면 운전자뿐 아니라 승객과 다른 도로 이용자에게도 큰 피해로 이어질 수 있어 운수종사자의 인적요인을 체계적으로 관리할 필요가 있었다. 그러나 기존 교통안전 정책은 도로환경과 차량요인 개선에 집중해 운전자의 행동과 인지 특성을 반영한 맞춤형 예방관리에는 한계가 있었다.

이에 도로와 차량요인만으로 설명하기 어려운 사고위험을 보완하기 위해 운수종사자의 주의력과 반응 일관성, 검사 오류와 과거 사고·행정처분 이력을 함께 분석하고, 개인별 위험 가능성을 사전에 파악할 수 있는 데이터 기반 관리체계가 필요했다.




그림 13-2. 연도별 교통사고 사망자 현황

1.2 분석 필요성

의무검사 자료를 사고예방을 위한 인적요인 정보로 변경 필요

운전적성정밀검사는 운수종사자의 사고위험을 사전에 살펴볼 수 있는 중요한 자료였다. 신규검사와 자격유지검사에는 주의력과 반응시간, 변화탐지, 도형추리 등 운전자의 인지 특성이 담겨 있었다. 이러한 검사 결과를 사고이력과 연결하면 사고위험과 관련된 인지 특성은 무엇인지, 반복 응시자의 검사 결과가 시간에 따라 어떻게 달라지는지 확인할 수 있었다.

분석 대상을 정의할 때는 사고 발생 여부뿐 아니라 사고의 심각도도 함께 고려했다. 사망·중상사고를 의미하는 KSI와 사고유형별 가중치를 검토해 정책적으로 관리할 필요가 있는 위험군을 구분했다. 또한 검사 직후의 상태와 오랜 시간이 지난 뒤의 위험을 동일하게 다루지 않도록 검사일 이후 24개월을 사고 관측기간으로 설정했다.

위험군의 비율이 낮다는 점도 평가 과정에 반영해야 했다. 대부분을 비위험군으로 예측해도 단순 정확도는 높게 나타날 수 있기 때문이다. 이에 모델이 실제 위험군을 얼마나 잘 구분하는지와 함께 개인별 예측확률을 얼마나 신뢰할 수 있는지를 동시에 평가했다. 이를 바탕으로 현장에서 우선적인 교육과 검사, 예방관리가 필요한 운수종사자를 선별하고자 했다.

핵심 분석 질문

- ① 운전적성검사의 어떤 특성이 사고위험과 관련되는가?
- ② 개인별 위험을 믿을 만한 확률로 제시할 수 있는가?
- ③ 위험군을 교육·상담과 추가검사로 어떻게 연결할 것인가?

1.3 데이터 목록

검사 결과와 운수종사자 이력, 사고정보를 개인 기준으로 연결

운수종사자의 사고위험을 정확히 분석하려면 운전적성정밀검사 결과와 과거 검사이력, 사고·행정처분 정보를 개인 단위로 연결해야 했다. 이에 신규검사와 자격유지검사의 문항별 정오답, 반응시간, 시행순서 데이터를 수집하고 운수종사자 기본정보 및 사고·행정처분 이력과 결합했다. 사고위험은 검사 이후 일정 기간 안에서 비교할 수 있도록 관측기간을 24개월로 설정했다.

검사자료는 문항과 시행방식에 따라 A·B 유형으로 구분했다. 문항별 정오답과 반응시간뿐 아니라 검사가 진행된 순서도 유지했다. 이를 활용해 개인별 평균 수행수준과 검사 전반부·후반부의 변화, 반응의 일관성 등을 설명하는 변수를 만들었다. 또한 개인 식별키를 기준으로 과거 검사횟수, 이전 고위험 판정 비율과 직전 검사 이후 경과개월을 계산해 반복검사에 따른 변화를 반영했다.

최종 분석자료는 944,767건으로 구성되었다. 이 가운데 위험군은 2.89%에 불과해 비위험군과 약 33.6대 1의 불균형을 보였다. 따라서 모델 학습과 평가에서는 전체 정확도보다 소수 위험군을 얼마나 놓치지 않고 찾아내는지에 중점을 둘 필요가 있었다. 사고·행정처분 이력은 예측대상인 위험군을 정의하는 동시에, 검사 이전의 위험수준을 설명하는 정보로 활용했다.

분석 대상과 범위

약 94만 건의 운전적성정밀검사 결과와 사고·행정처분 이력을 활용하여 사고위험을 분석했다.

영역	주요 내용	활용
적성검사	주의·반응·변화탐지	인지 특성
개인이력	연령·반복검사·과거위험	누적 위험
사고자료	사고·행정처분 이력	위험군 정의
관측기준	검사 후 24개월	예측 시점 통일

표 13-1. 주요 활용 데이터

1.4 EDA : 위험군과 검사 분포

약 94만 건에서 위험군 2.89%의 구조를 우선적으로 확인

모델링에 앞서 검사자료의 시점별 분포와 중복 여부, 검사유형별 데이터 구성을 살펴보았다. 월별 검사건수와 대상자 수를 비교한 결과, 검사유형과 시행시점에 따라 자료량에 차이가 나타나 학습자료를 구성할 때 시기별 편종을 함께 고려해야 했다.

A검사와 B검사는 측정항목과 데이터 구조가 서로 달랐다. A검사는 신규 자격 검사이고, B검사는 자격 유지 검사이다. 이에 두 검사자료를 하나로 합쳐 분석하기 전에 유형별 특성을 구분해 확인했다. 이후 A검사 모델과 B검사 모델, 두 자료를 결합한 통합모델을 각각 구축하고 성능 차이를 비교하는 방향으로 분석을 설계했다.

전체 분석자료 944,767건 가운데 위험군은 약 2만 7,300건으로 2.89%에 불과했다. 이러한 불균형 자료에서는 모든 대상을 비위험군으로 예측해도 겉보기 정확도가 높게 나타날 수 있다. 따라서 단순 정확도보다 실제 위험군을 얼마나 찾아내는지를 보여주는 지표가 필요했다. 학습·검증자료를 나눌 때도 각 분할에서 위험군 비율이 유지되도록 층화 교차검증을 적용할 필요가 있었다.

탐색적 분석에서 확인한 시점별 자료량과 검사유형의 차이, 위험군의 불균형은 이후 변수선택과 모델구조, 성능평가 기준을 결정하는 근거가 되었다.




그림 13-3. A·B 검사유형별 클래스 불균형

1.5 EDA : 인지·반응 특성

평균분 아니라 변동성과 시간 흐름에서 위험 신호 확인

검사항목별로 위험군과 비위험군의 반응 특성을 비교한 결과, 항목에 따라 집단 간 차이가 다르게 나타났다. 단순반응시간은 두 집단의 차이가 크지 않았다. 반면 주의력과 간섭 과제에서는 위험군의 반응시간이 전반적으로 더 느린 경향을 보였다. A6·A7 도형추리는 단일 항목만으로도 비교적 뚜렷한 구분력을 보였으며, 두 집단의 정답률 차이는 약 10%였다.

개인의 수행 특성을 세밀하게 반영하기 위해 반응시간의 평균분 아니라 상·하위 분위수, 표준편차와 변동계수를 함께 산출했다. 평균값이 비슷하더라도 반응속도의 편차가 크거나 특정 문항에서 지나치게 늦게 반응하는 경우를 구분하기 위한 것이다. 정답률과 오류율, 연속오류 횟수도 파생변수로 구성해 검사 수행의 안정성을 나타냈다.

검사가 진행되는 동안 나타나는 변화도 분석에 반영했다. 문항의 시행순서를 유지한 뒤 전반부와 후반부의 반응시간 및 정답률을 비교해 후반부 성능 저하를 계산했다. 빠르게 응답했지만 오답이 많거나, 정확도를 유지하는 대신 반응이 지나치게 느린 경우를 확인하기 위해 속도와 정확도 간의 상충관계도 변수로 만들었다.

반복검사를 받은 운수종사자는 현재 검사와 과거 검사 결과의 차이를 추가로 계산했다. 이를 통해 한 시점의 검사점수만으로는 확인하기 어려운 인지기능의 변화와 반응 일관성을 모델이 학습하도록 했다.




그림 13-4. 반응시간·정확도와 위험군의 분포 차이

1.6 빅데이터 모델링 : 후보 비교

여러 알고리즘을 같은 검증기준으로 비교

운전적성정밀검사에는 정답률과 반응시간, 오류의 반복, 검사 전후의 수행 변화처럼 서로 다른 형태의 변수가 포함되어 있었다. 이러한 변수는 사고위험과 단순한 직선관계로 이어지기보다 여러 조건이 겹칠 때 영향을 줄 수 있었다. 이에 복잡한 비선형 관계와 변수 간 상호작용을 학습할 수 있는 모델을 중심으로 후보군을 구성했다.

후보모델로는 XGBoost, LightGBM, CatBoost 등 트리 부스팅 모델과 FT-Transformer를 검토했다. 트리 부스팅 모델은 정형데이터에서 변수별 기준을 단계적으로 나누며 사고 위험과 관련된 복합적인 패턴을 학습하는 데 강점이 있었다. FT-Transformer는 Attention 구조를 활용해 다수의 검사·이력 변수 사이에서 중요한 관계를 찾도록 설계했다.

모델 간 비교가 공정하게 이루어지도록 모든 후보에 동일한 학습자료와 데이터 분할, 평가산식을 적용했다. 위험군 비율이 2.89%에 불과한 점을 고려해 각 분할에 위험군과 비위험군의 비율이 유지되는 5개 구간 층화 교차검증을 수행했다. 이를 통해 특정 학습자료에서만 성능이 높게 나타나는지, 새로운 자료에서도 위험군을 안정적으로 구분하는지를 확인했다.




그림 13-5. 운수종사자 사고위험 예측모델 선정 과정

1.7 빅데이터 모델링 : 통합 고도화

상호보완적인 모델을 결합하고 확률 보정을 통한 모델 고도화

운수종사자의 사고위험은 현재 검사에서 나타난 인지·반응 특성뿐 아니라 과거 검사결과와 시간에 따른 변화에도 영향을 받을 수 있었다. 이에 현재 검사정보를 정밀하게 학습하는 트리 부스팅 모델과 반복검사의 시간순 이력을 반영하는 경량모델을 결합해 개인별 사고위험을 산출하도록 했다.

최종 통합모델은 A·B 검사자료를 바탕으로 538개 피처를 생성했다. 문항별 정오답과 반응시간, 오류율 등 현재 검사정보에 과거 검사횟수, 직전 검사 이후 경과 개월과 시퀀스 요약 값을 추가했다. 상관계수가 0.99 이상인 피처는 같은 정보를 중복해서 반영할 가능성이 높아 제거했다.

최종 예측값은 현재 검사정보를 세밀하게 반영한 모델에 0.7, 시간순 검사이력을 반영한 경량모델에 0.3의 가중치를 적용해 산출했다. 두 모델을 결합함으로써 한 시점의 검사결과에만 의존하지 않고 현재 수행수준과 과거 변화 흐름을 함께 고려했다. 이후 Isotonic 방식으로 확률을 보정해 모델이 제시한 개인별 위험확률과 실제 위험군 발생 수준의 차이를 줄였다.

모델 설정값은 학습자료와 검증자료를 7대 3으로 나누어 탐색했다. 실제 추론 단계에서도 학습 때 사용한 전처리 방식과 피처순서를 그대로 적용했다. 입력자료에 일부 피처가 없으면 해당 값을 0으로 채우고, A·B 검사유형에 맞는 결과를 결합하도록 구성해 데이터 구조 차이로 발생할 수 있는 운영오류를 줄였다.

이러한 통합과 보정 과정을 거쳐 현재 검사와 과거 이력을 균형 있게 반영하는 사고위험 예측체계를 마련했다. 다음 단계에서는 새로운 시점의 자료에서도 위험군 판별력과 예측확률의 신뢰도가 유지되는지 검증했다.

1.8 모델 성능과 해석 : 성능

최종 점수 0.140145로 확률예측의 정확성과 신뢰도 상승

운수종사자 사고위험 예측모델은 위험군을 정확히 구분하는 능력뿐 아니라, 개인별 예측확률을 얼마나 신뢰할 수 있는지도 중요하다. 이에 단계별 전처리와 피쳐 개선, 상위모델 결합과 확률 보정을 순차적으로 적용하고, 모든 개선 단계의 성능을 동일한 복합 평가산식으로 비교했다.

분석 결과, 최종모델의 평가점수는 0.140145까지 낮아졌다. 평가점수가 낮을수록 위험군 판별과 확률 예측의 오차가 작다는 의미다. 확률 보정에는 Isotonic 방식을 적용해 위험군의 예측순위를 유지하면서도, 모델이 산출한 확률이 실제 위험군 발생률에 가까워지도록 조정했다.

모델이 학습자료에 지나치게 맞춰지는 것을 방지하기 위해 조기종료도 적용했다. 검증점수가 50회 연속으로 개선되지 않으면 학습을 중단하도록 설정해 불필요한 반복을 줄이고 과적합을 방지했다. 이를 통해 학습자료뿐 아니라 새로운 자료에서도 성능이 안정적으로 유지되도록 했다.



판별력·확률 신뢰도·운영 안정성을 함께 검증한 사고위험 예측체계

그림 13-6. 사고위험 예측모델의 성능 개선과 운영 안정화

1.9 모델 성능과 해석 : 주요 요인

연령·검사시점·과거 위험이력·반응 변동이 사고 위험을 설명하는 주요 요인으로 확인

A·B·통합모델의 변수중요도와 SHAP 값을 비교한 결과, 연령과 검사시점, 과거 검사的高위험 이력이 공통적인 주요 변수로 나타났다. 특히 과거 고위험 이력률이 높을수록 현재 위험확률도 높아지는 경향을 보였다.

인지검사에서는 평균 오류율과 반응시간, 반응시간 및 정답률의 변동성이 위험확률에 영향을 주었다. 기여도가 낮은 항목은 향후 검사절차 조정과 항목 간소화를 검토하는 참고자료로 활용할 수 있다.

다만 변수중요도와 SHAP 값은 인지 특성과 사고의 인과관계를 의미하지 않는다. 따라서 개인에게 불이익을 주는 단독 근거가 아니라 과거 이력과 검사결과, 전문가 판단을 함께 확인하는 보조정보로 활용해야 한다.

결과 해석 시 유의사항

위험확률은 운전자의 자격을 단정하는 점수가 아니다. AUC와 Brier Score, ECE로 판별력과 확률의 신뢰도를 함께 확인하고 예방적 지원에 활용해야 한다.




그림 13-7. 인지검사 항목별 분포와 영향요인

1.10 모델 시각화

검사자료가 위험확률과 설명정보로 이어지도록 구성

분석결과를 실제 안전관리에 활용할 수 있도록 검사자료 수신부터 결과 제공까지 하나의 흐름으로 구현했다. 시스템은 검사자료 적재, 전처리, 피쳐 생성, 모델 추론과 결과 저장을 순차적으로 수행하도록 구성했다.

담당자는 화면에서 개인별 사고위험 확률과 위험구간별 인원 규모, 주요 영향요인을 함께 확인할 수 있다. 이를 통해 우선적인 교육과 상담, 추가검사가 필요한 대상을 검토하고 후속조치의 순서를 정할 수 있다.

모델과 시스템은 기능별 모듈로 분리했다. 새로운 자료가 추가되거나 모델을 재학습할 때도 동일한 전처리와 추론 절차를 반복해서 사용할 수 있어 데이터 최신화와 운영·관리의 효율성을 높였다.



그림 13-8. 모델 운영 프로세스

1.11 분석모델 정책 활용 성과

운수종사자 사고위험 관리와 검사제도 개선의 보조지표 마련

현재 택시·버스 운수업체와 향만 특장차 운전직 종사자 관리업체 등에서 교통사고 위험분석 리포트를 채용과 안전관리 업무의 참고자료로 활용하고 있다. 총 21개 업체에서 981명의 위험분석을 신청했으며, 이 가운데 398건의 위험분석 리포트를 발행했다. 이를 통해 운수종사자의 인지적 특성과 과거 이력을 종합적으로 살펴보고, 안전관리가 필요한 대상을 사전에 검토할 수 있는 기반을 마련했다.

확률 보정을 거친 예측값은 정책대상의 규모와 우선순위를 정하는 데 활용할 수 있다. 담당자는 분석결과를 위험수준에 따라 구분해 확인하고, 업체의 안전관리 여건과 대상자의 특성을 고려해 교육, 상담 등 적절한 예방조치를 검토할 수 있다.

모델의 변수중요도와 반복검사 분석 결과는 운전적성정밀검사 개선에도 활용할 수 있다. 사고위험을 구분하는 데 효과적인 문항과 기여도가 낮은 문항을 확인하고, 반응시간과 정답률의 변화로 검사 과정의 피로효과를 검토할 수 있다. 다만 문항을 조정하거나 제외할 때는 별도의 타당성 검증이 필요하다.


최신 검사자료와 사고·행정처분 이력을 주기적으로 연계해 모델의 성능을 지속적으로 평가할 예정이다. 교육·상담 이후의 사고와 재검사 결과를 데이터로 축적하면 정책효과를 확인하고 모델을 지속적으로 개선할 수 있다. 위험군 적중률과 교육·상담 참여율, 사고 감소율과 현장 활용실적을 함께 관리하면 데이터 기반 교통안전정책의 성과를 체계적으로 확인할 수 있다.





5-2

교통사고 위험 예측 및 실시간 안전정보 제공 지원 모델 개발



Part 5-2

교통사고 위험 예측 및 실시간 안전정보 제공 지원 모델 개발

한국도로교통공단

사고 전 위험 신호를 도로 위험 예측 모델로 읽다

분석 배경	분석 방법	분석 결과
사고건수 중심의 분석은 사고가 아직 나지 않은 잠재위험구간과 복합요인을 찾기 어려움	839만여 링크·시점 자료에 사고·도로·교통·기상·유동인구·DTG를 결합해 XGBoost로 위험을 예측	모델을 통해 도출된 결과를 기반으로 도로 시설개선 우선도로 제시

과제 한눈에 보기

교통안전사업은 주로 사고가 많이 발생한 지점을 중심으로 추진되었다. 이 방식은 이미 사고가 발생한 장소를 개선하는 데 효과적이지만, 사고이력은 적어도 도로구조와 교통량·기상·위험운전 요인이 누적된 잠재위험 구간을 먼저 찾는 데 한계가 있었다. 도로별 위험원인까지 설명하는 선제적 분석체계가 필요했다.

이에 한국도로교통공단은 경기도의 교통사고 15만 8,307건과 세분화도로링크 36만 4,590개에 도로구조, 교통량, 기상, 시설물, DTG 위험운전 정보를 결합했다. 링크별 사고위험을 예측하고 고위험 구간을 놓치지 않도록 모델을 최적화했으며, Local SHAP을 활용해 개별 도로의 주요 위험요인을 설명했다.

분석 결과는 도로구간별 위험도와 위험원인을 지도와 시각화 화면으로 구현했다. 이를 통해 사고 건수뿐 아니라 잠재위험을 기준으로 안전사업 후보지를 우선 검토하고, 도로전광표지와 내비게이션 등 실시간 안전정보 제공에 활용할 수 있는 기반을 마련했다.



💡 이렇게 바뀌었습니다!

사고지점 통계 중심의 정책을 링크별 위험요인 예측 중심으로 확장

AS-IS	TO-BE
• 단순히 사고건수가 많은 지점을 중심으로 도로시설 개선사업지를 선정 • 도로 분석 시, 시간·날씨·교통량·위험운전을 함께 반영하기 어려움 • 사고가 없지만 위험이 누적된 도로를 찾기 어려움	• 세분화 도로 링크별 위험도를 예측하여 사고 건수 외에 다른 요인도 고려한 사업지 선정 • 고위험 도로 링크의 누락률을 최소화하여 안전한 도로환경 마련 • 각 도로의 위험원인을 설명할 수 있어 정책활용의 근거를 마련

[단계 1] 기준점 생성

- 세분화도로링크 라인 위에 여러 개의 기준점 생성
- 양 끝 제외, 중앙부 중심으로 분포

[단계 2] 근거거리 후보 탐색

- 각 기준점 주변 일정 거리 이내의 도로중심선 탐색
- 기준점별로 여러 후보 허용

[단계 3] 방향성 필터링

- 세분화도로링크와 도로중심선의 진행 방향 비교
- 방향 차이가 큰 후보는 제거

[단계 4] 형상 유사도 평가

- 남은 후보에 대해기준점-도로중심선 간 평균 거리 계산
- 평균 거리가 짧을수록 형상 유사도가 높다고 판단

[단계 5] 최종 매칭 결정

- 방향 조건을 만족하고 평균 거리가 가장 짧은 도로중심선을 최종 매칭 결과로 선택

(세분화도로링크)

(도로중심선)

(세분화도로링크)

(도로중심선)

(도로중심선)

(도로중심선)

(세분화도로링크)

(도로중심선)

(도로중심선)

(세분화도로링크)

(도로중심선)

(세분화도로링크)

(도로중심선)

그림 14-1. 도로구간별 위험도와 주요 원인을 보여주는 시각화 과정

2.1 현황 및 배경

보호구역과 사고건수만으로 취약계층 위험에 대한 충분한 설명 부족

도로의 위험은 사고가 발생한 후에 드러나는 것이 아니라 도로구조와 교통흐름, 날씨와 위험운전이 겹치며 쌓인다.

노인보호구역의 98.7%는 노인복지시설 인근에 설치되었지만 실제 노인 보행사고는 약국·시장·지하철역 주변에서도 발생했다. 즉, 노인과 어린이 교통사고의 약 96%는 보호구역 밖에서 발생했다. 보호구역 중심 정책만으로 잠재위험을 포괄하기 어려웠다. 경기도 시군의 사업대상지는 사고건수 중심 통계로 선정되어 시간·환경·위험운전 변화를 반영하기 어려웠다.

이러한 배경은 기존 업무를 보완할 새로운 분석체계가 왜 필요한지를 보여주었다.



그림 14-2. 교통안전정책과 위험도로 분석의 필요성

2.2 분석 필요성

사고가 없었던 도로의 누적위험과 잠재위험원인을 함께 탐색 필요

교통사고 예방정책은 사고가 많이 발생한 도로를 정비하는 것에서 출발해 왔다. 그러나 사고기록만 따라가면 아직 사고가 발생하지 않았더라도 위험요인이 누적된 구간을 발견하기 어렵다. 운이 좋아 사고로 이어지지 않았던 도로와 새롭게 통행환경이 달라진 도로까지 살피려면, 과거 사고건수보다 넓은 기준으로 잠재위험을 설명해야 했다.

교통사고는 하나의 원인으로 발생하지 않았다. 차로 수와 도로폭 같은 구조적 조건, 횡단보도와 교통안전시설, 시간대별 교통량과 유동인구, 기온·습도·상습결빙, 급가속·급감속 등 위험운전이 같은 시간과 공간에서 겹치며 위험을 높였다. 따라서 사고·도로·시설·교통·인구·기상·DTG 자료를 동일한 도로링크와 시간기준으로 결합해 복합적인 위험을 분석할 필요가 있었다.

정책의 목적도 평균적인 예측오차를 줄이는 데만 있지 않았다. 제한된 시설개선 예산을 효과적으로 사용하려면 실제 고위험 도로를 후보군에서 빠뜨리지 않아야 했다. 이에 고위험 링크를 얼마나 찾아내는지 보여주는 Recall을 우선하고, 위험구간을 정상으로 판단하는 누락오류인 FNR을 낮추는 방향으로 평가기준을 설정했다. 동시에 지자체가 결과를 검토할 수 있도록 각 도로에서 어떤 변수가 위험점수에 영향을 주었는지도 함께 제시해야 했다.

이러한 요구를 반영해 사고지점을 도로망상의 연속적인 위험강도로 변환하고, 세분화도로링크별 구조·시설·환경과 월별 교통특성을 연결하는 분석체계를 설계했다. 모델은 고위험 후보를 우선 선별하고, 설명가능한 분석기법으로 도로별 주요 위험요인을 제시하도록 구성했다. 분석결과가 단순한 순위표에 머물지 않고 현장점검과 시설개선 대상 선정의 근거로 이어지도록 한 것이다.

핵심 분석 질문

- ① 사고이력이 적어도 잠재위험이 높은 도로는 어디인가?
- ② 고위험 구간을 놓치지 않으려면 어떤 기준이 필요한가?
- ③ 각 도로의 위험을 높인 요인은 무엇인가?

2.3 데이터 목록

사고·도로·교통·사람·날씨 정보를 링크와 시간으로 통합

2022~2024년 경기도 사고 158,307건과 표준도로링크 102,631건, 세분화도로링크 364,590건을 활용했다. 도로구조와 교통시설, 교량·터널·지하차도·상습결빙구간을 링크에 연결했다.

세분화도로링크 단위 도로위험도 예측을 위해 교통사고 발생 이력과 사고위험에 영향을 미칠 수 있는 다양한 외생 데이터를 수집·활용하였다. 한국도로교통공단, 경기교통정보센터 등의 기관과 공공데이터플랫폼을 통해 20종의 데이터를 수집하였다. 수집 데이터는 공간적 요인, 시간적 요인, 도로·교통 환경 요인, 주변 활동 요인을 종합적으로 반영할 수 있도록 구하였고 이는 단일 데이터에 의존하지 않고, 사고 발생의 공간적·시간적·환경적 요인을 함께 고려하기 위함이다.

세부적으로 구간속도·교통량·지체시간, VDS와 교차로 관측, 통신사 유동인구를 월·주중/주말 기준으로 집계했다. 기온·습도·강수와 DTG의 과속·급가감속·급회전, 차종비율을 결합했다.

분석 대상과 범위

경기도 사고 15만 8,307건과 세분화도로링크 36만 4,590개를 기준으로 교통량·기상·시설·DTG 위험 운전 정보를 결합했다.

영역	주요 데이터	활용
교통사고	158,307건, 피해심각도	도로위험도 산정
도로정보	링크·구조·시설·결빙	공간 위험요인
교통·활동	속도·교통량·유동인구	시간대 노출수준
환경·행동	기상·DTG 위험운전	동적 위험요인

표 14-1. 주요 활용 데이터

2.4 EDA : 분석자료와 결측

839만여 링크·시점 자료의 품질과 희소성 확인

도로위험도 모델은 방대한 자료를 학습하지만, 데이터의 양이 곧 품질을 뜻하지는 않는다. 특정 장비가 설치된 도로에 관측이 집중되거나 사고가 일부 구간에만 나타나면 모델이 실제 위험보다 수집 여건을 학습할 수 있다. 이에 모델링에 앞서 분석단위와 결합상태, 자료군별 결측과 분포의 치우침을 순서대로 점검했다.

경기도 일반도로망을 세분화도로링크 단위로 나누고, 각 링크를 월과 주중·주말 기준으로 펼쳐 8,394,264건의 분석 레코드를 구축했다. 사고·도로구조·교통시설·유동인구·기상·교통량·DTG 위험운전 등 서로 다른 자료는 ‘세분화도로링크ID×월×주중·주말’ 공통 키로 정렬했다. 병합 이후에는 중복키와 필수 메타정보를 다시 확인했으며, 키 불일치로 인한 누락 레코드는 나타나지 않았다.

총 54개 수치형 변수의 관측치 수와 평균, 표준편차, 최솟값·최댓값, 중앙값, 결측률과 왜도를 산출했다. 도로구조·교통시설·기상 등 기초자료의 결측률은 대체로 7% 미만이었다. 반면 DTG 위험운전 변수는 약 13.9%가 비어 있었고, 특정 구간과 시간대에 관측이 집중되면서 최대 왜도 95.8의 강한 우측 편향이 나타났다. 교통량은 장비가 설치된 지점에서만 수집되는 특성 때문에 링크별 결측률이 96~99%에 달했다.

결측은 자료의 의미에 맞춰 다르게 처리했다. 기상자료는 관측지점별 월·시간대 평균으로 먼저 보완하고, 남은 값은 인접 관측소와 거리기반 공간보간으로 링크에 연결했다. 교통량은 표준도로링크의 관측값을 세분화도로링크 길이 비율에 따라 배분한 뒤 월·주중/주말 대표값으로 집계했다. 관측장비가 없는 구간은 교통량 0으로 단정하지 않고, 전 구간에서 확보할 수 있는 유동인구를 함께 활용해 도로 이용강도의 공간적 공백을 보완했다. DTG는 25m 이내의 최근접 링크에 매핑하고 시간평균으로 집계해 일부 지점의 과도한 관측이 그대로 반영되지 않도록 했다.

결측을 읽는 기준

교통량 결측은 ‘통행이 없음’이 아니라 ‘관측장비가 없음’을 의미했다. 따라서 임의의 0으로 채우지 않고 관측범위와 보완자료를 함께 기록했다. 이러한 점검 결과는 변수 변환과 가중치 설정, 고위험 구간의 누락을 줄이는 모델 평가기준을 정하는 근거가 되었다.

2.5 EDA : 위험도 분포와 지역 차이

위험은 일부 링크와 시점에 집중되어 있음을 확인

모델을 만들기 전에는 데이터의 분포와 차이, 결측과 이상값을 충분히 살펴야 한다. 이 탐색과정은 모델의 방향을 정하는 기초가 된다.

전체 레코드 중 도로위험도가 양수인 비율은 약 14.58%였다. 다른 분석구성에서는 0값 비율이 92.73%로 나타나 매우 불균형했다. 월별 위험도는 주중과 주말에서 서로 다른 변동을 보였다. 같은 도로도 계절과 이용행태에 따라 위험이 달라졌다.

시군별 도로구조·교통시설·유동인구와 위험운전 분포가 달라 단일 평균만으로 지역의 위험을 비교하기 어려웠다. 고위험구간의 정책 중요도가 높아 모델평가는 Recall과 False Negative Rate 최소화에 초점을 두었다.

확인된 분포와 차이는 변수선정과 모델구조, 평가방법을 결정하는 근거로 이어졌다.




그림 14-3. 양성·비양성 링크와 위험도 분포 비교

2.6 EDA : 도로 위험도 분포

시기별 도로 위험도는 뚜렷한 차이 확인

모델을 만들기 전에는 데이터의 분포와 차이, 결측과 이상값을 충분히 살펴야 한다. 이 탐색과정은 모델의 방향을 정하는 기초가 된다.

도로위험도는 뚜렷한 시간적 변동성이 있으며, 2월에 가장 낮고 5월과 10~11월에 상대적으로 높은 값을 보였다. 도로 반경 500m 기준 유동인구는 월별로 뚜렷한 계절적 변동성을 보이며, 주중·주말 간 패턴 차이가 명확하게 나타났다. 또한, 급가속 등 위험운전 비율은 1~2월 상대적으로 낮은 수준이나 5월 이후 본격적으로 상승하고 11~12월에 가장 높은 값을 나타냈다.




그림 14-4. 도로위험도, 유동인구, 버스비율, 급가속비율의 월별·주중·주말별 변동 양상 그래프

2.7 EDA : 기온과 습도에 따른 도로 위험도

지역 및 기온과 습도에 따라 도로 위험도가 다른 양상 확인

실제 사고가 발생한 적이 없는 상황에서의 도로위험도(0값 제외)와 모든 상황에서의 도로위험도(0값 포함)가 서로 양상이 다르나, 두가지 경우 모두 위험도가 높은 지역은 안양시, 오산시, 광명시로 나타났다. 평균 도로위험도 상위 5개 시군은 오산시, 광명시, 안양시, 부천시, 하남시이고, 하위 5개 시군은 연천군, 양평군, 안성시, 의왕시, 과천시이다.




그림 14-5. 시군별 평균 도로위험도

또한, 기온이 높을수록, 습도가 낮을수록 평균적으로 도로위험도가 높아지는 경향이 있다.




그림 14-6. 시군별 기온 및 습도와 도로위험도 분포

2.8 빅데이터 모델링 : 도로위험도

사고건수와 피해심각도를 링크 주변으로 분산해 위험도 도출

탐색 결과를 토대로 실제 업무의 판단과정을 모델 구조에 옮겼다. 성능뿐 아니라 현장에서 설명하고 운영할 수 있는지도 함께 고려했다.

사고위치는 직접매핑과 최근접 링크 탐색으로 도로망에 연결했다. NKDE로 인접 링크까지 사고영향을 공간적으로 분배했다. 사망·중상·경상 등 피해수준을 반영한 EPDO와 사고건수를 종합해 링크별 도로위험도를 구성했다. 모델 입력은 링크×월×주중/주말 단위로 통일했다. 링크ID 기반 GroupShuffleSplit으로 보지 못한 도로에 대한 일반화 성능을 검증했다. 도로구조 같은 정적변수와 교통·기상·DTG 같은 시간변수를 함께 사용했다.

이렇게 구축한 모델은 다음 단계에서 실제 자료를 얼마나 안정적으로 설명하는지 성능과 오류를 함께 검증했다.

2.9 빅데이터 모델링 : FNR 제어 XGBoost

평균오차보다 고위험 링크 누락을 감소하도록 직접 모델링

탐색 결과를 토대로 실제 업무의 판단과정을 모델 구조에 옮겼다. 성능뿐 아니라 현장에서 설명하고 운영할 수 있는지도 함께 고려했다. MLP 등 여러 구조와 불균형 보정방식을 단계적으로 실험을 통해 XGBoost기반 단일 회귀 모델과 Local SHAP 기반 추론 구조를 결합한 최종 적용 모델을 확정하였다. 본 최종 모델은 고위험 도로링크를 놓치지 않는 예측 성능과 개별 도로의 위험 원인을 설명할 수 있는 추론 구조를 동시에 충족하였고, 이에 따라 단순 예측 모델을 넘어, 고위험 도로 선별·원인 진단·정책 개입까지 연계할 수 있는 통합 분석 모델로 활용이 가능하였다.

이렇게 구축한 모델은 다음 단계에서 실제 자료를 얼마나 안정적으로 설명하는지 성능과 오류를 함께 검증했다.

2.10 모델 성능과 해석 : 탐지성능

고위험 링크의 누락을 사실상 최소화

도로위험도 모델의 목적은 위험점수를 소수점 단위까지 정확히 맞추는 데 있지 않았다. 제한된 시설개선 예산으로 우선 점검할 도로를 정하려면 실제 고위험 링크가 후보군에서 빠지지 않아야 했다. 이에 절대적 수치 예측력인 R^2 보다 고위험군 식별 성능을 중심으로 모델을 평가하고, 학습·중단·저장 단계에서 링크 단위 누락률인 FNR_link 를 가장 먼저 낮추도록 설계했다.

최종 8차 XGBoost 모델은 링크 기준 Recall 99.9%, FNR 0.004%를 기록해 고위험 도로의 누락을 사실상 최소화했다. 링크 기준 ROC-AUC는 0.85, PR-AUC는 0.92로 나타나 고위험 링크와 비위험 링크를 구분하는 능력도 안정적으로 확보했다. 평균 손실이 일시적으로 줄더라도 FNR이 악화되면 해당 모델을 저장하지 않도록 해, 정책 목적과 모델 선택기준이 흔들리지 않게 했다.

전체 링크·시점 샘플에서는 ROC-AUC 0.792, PR-AUC 0.423을 기록했다. 이는 위험도가 0인 관측이 대부분을 차지하고 일부 고위험 값이 길게 분포하는 영과잉·장꼬리 자료에서도 위험구간을 구분할 수 있는 신호를 확보했다는 의미다. 동일한 모델이라도 평가단위를 링크로 집계하면 지표가 높아졌는데, 월별 변동을 개별 행으로 판단하기보다 정책 대상인 도로링크의 최대 위험을 기준으로 판단한 결과였다.

성능은 하나의 수치로 단정하지 않았다. Recall과 FNR은 고위험 링크의 누락 여부를, ROC-AUC는 전반적인 순위 구분력을, PR-AUC는 희소한 고위험군을 얼마나 정확하게 찾는지를 보여주었다. 따라서 모델 결과는 자동 판정값이 아니라 현장점검 대상을 넓게 선별하는 스크리닝 자료로 활용하고, 위험등급과 주요 영향요인을 함께 확인해 시설개선 후보를 정하도록 했다.

탐지성능 해석 시 유의사항

높은 Recall은 실제 고위험 링크를 폭넓게 포함했다는 뜻이지만 모든 후보가 곧바로 시설개선 대상이라는 의미는 아니다. 현장에서는 위험원인과 도로여건을 추가로 검토하고, 운영자료가 축적되면 임계값과 성능을 주기적으로 다시 점검해야 한다.

2.11 모델 시각화

위험도로·시설·사고이력·원인을 지도에서 함께 표출

복잡한 분석결과가 현장에서 쓰이려면 사용자가 다음 행동을 바로 결정할 수 있는 화면으로 바뀌어야 한다.

전체 시각화 화면은 시군구, 사고유형, 교통시설물을 필터를 통해 선택할 수 있고, 지도상에 세분화도로링크별 위험도를 색깔구분으로 표시 가능하도록 구성하였다.

경기도 전체와 시군을 선택하고 세분화도로링크별 위험등급을 지도에서 조회하면 선택한 도로의 과거 사고건수, 고령운전자·음주운전 사고와 주변 교통안전시설을 함께 표시했다.

추가로, 레이더 차트 형식으로 도로 위험도에 영향을 끼치는 요인들을 보여주며, 요인별 상세한 영향도도 제공하여 시설개선 방향을 검토할 수 있었다. 미래값을 다시 예측하는 이종오차를 피하고 과거·현재 자료에 기반한 위험경향과 원인설명 중심으로 화면을 구성했다.

화면은 분석결과를 보여주는 데 그치지 않고 담당자가 우선순위를 정하고 후속조치를 선택하도록 구성했다.




그림 14-7. 경기도 위험도로 예측 상황판

2.12 분석모델 정책 활용 성과

교통사고 잦은 곳 개선사업 대상지점을 데이터로 제시

한국도로교통공단은 AI모델을 활용하여 487만 건의 교통사고 위험 예측정보를 활용해 사고가 잦은 대상지점을 도출하였다. 이를 통해 사고가 잦은 곳을 개선할 예정이다. 과거 사고이력뿐 아니라 도로별 잠재위험 정보를 함께 비교함으로써 현장 확인과 개선사업 검토가 필요한 구간을 폭넓게 살펴볼 수 있도록 했다.

또한, AI 모델을 활용하여 위험예측 대상인 경기도 내 약 36만개 도로링크 가운데 위험도가 높은 상위 약 1,250개 도로링크와 위험노출이 높은 상위 약 440개 도로링크를 선별하였다. 선별된 데이터를 바탕으로 교통사고 잦은 곳 개선사업 후보지점과 교차 분석한 결과, AI 위험예측 지점과 중첩된 8개소(총 22개소)를 2026년 사업 대상지로 선정하였다. 이를 통해 기존의 교통사고 발생자료 뿐만 아니라, AI를 통해 예측된 잠재적 위험정보까지 함께 검토함으로써, 사업 대상지 선정 시 도로의 위험요인을 보다 폭 넓게 고려할 수 있었다.

앞으로는 위험도 예측스코어 활용과 함께 AI모델에 활용된 다양한 변수들의 영향도를 분석하여 도로별 잠재위험 정보를 함께 비교 분석해 좀 더 세밀한 다양한 교통사고 예방 대책에 활용하고 또한 AI 산출결과를 누구나 쉽게 활용할 수 있도록 공단에서 운영중인 교통사고분석시스템(TAAS)의 지도기반 서비스에 탑재, 지자체·유관기관 등에서 활용할 수 있도록 할 예정이다.



2025 공공부문 데이터 분석 · 활용 우수사례집

발 행 처 | 행정안전부 공공데이터분석관리과, 한국지능정보사회진흥원

엮 은 이 | 행정안전부 공공데이터분석관리과

과장 유대준

팀장 김정훈

주무관 최지현

한국지능정보사회진흥원 지능데이터기반행정팀

팀장 강경훈

수석 곽성일

선임 최다영

선임 박소현

발 행 일 | 2026년 8월 28일

© 행정안전부, 한국지능정보사회진흥원, 2026

본 사례집 내용의 무단 전재를 금하며, 가공 및 인용 시 반드시 출처를 명기해주시기 바랍니다.





행정안전부

NIA 한국지능정보사회진흥원



9 773022 263005
ISSN 3022-263X